




**Universidad Nacional de Río Cuarto**

**Facultad de Ciencias Económicas**

# *Usos empresariales de inteligencia artificial y productividad laboral: evidencia país–sector para la Unión Europea*

| | |
|---|---|
| Alumno: | Facundo Díaz Larrarte |
| DNI: | 43.475.555 |
| Registro Universitario: | *[completar]* |
| Email: | fdiazlarrarte@mail.com |
| Director: | Miguel Bosch |
| Codirectora: | Ana Vianco |
| Fecha de presentación: | *[completar]* |

**Trabajo Final de Grado**

**Licenciatura en Economía**

Ciudad de Río Cuarto, Argentina

# Índice

**Resumen** **5**

**1. Introducción** **6**
1.1. Planteo del problema . . . 6
1.2. Delimitación del tema y del área de estudio . . . 6
1.3. Objetivo general . . . 7
1.4. Objetivos específicos . . . 7
1.5. Hipótesis de trabajo . . . 7
1.6. Importancia del estudio . . . 8
1.7. Limitaciones del estudio . . . 8

**2. Marco teórico y antecedentes** **8**
2.1. Adopción tecnológica, enfoque de tareas y heterogeneidad funcional . . . 8
2.2. Tecnologías de propósito general, costos de ajuste y desfases temporales . . . 9
2.3. Fundamentos teóricos y medición econométrica de la productividad: el marco de Berndt y Eurostat . . . 10
2.4. Evidencia empírica sobre IA y productividad en Europa . . . 11
2.5. Margen extensivo, intensidad de uso y brecha de realización . . . 12
2.6. Desafíos econométricos en datos de panel: de Efectos Aleatorios a Efectos Fijos . . . 12
2.7. Aporte específico de este trabajo . . . 13

**3. Datos y metodología** **14**
3.1. Fuentes de información y muestra analítica . . . 14
3.2. Ficha metodológica de la encuesta y representatividad de la muestra . . . 14
3.3. Sectores considerados . . . 16
3.4. Variables . . . 16
3.5. Estrategia descriptiva . . . 17
3.6. Estrategia econométrica: de Pooled OLS y Efectos Aleatorios a Efectos Fijos 17
3.7. Heterogeneidad sectorial . . . 18
3.8. Robustez . . . 18

**4. Resultados** **18**
4.1. Evolución agregada . . . 18
4.2. Heterogeneidad sectorial descriptiva . . . 19
4.3. Correlaciones en niveles y cambios . . . 21
4.4. Modelo de panel . . . 23
4.5. Heterogeneidad sectorial en el modelo de panel . . . 24

4.6. Robustez de la especificación principal . . . . . 26
4.7. Validación de especificación: Efectos Aleatorios y Contraste de Hausman . 27

**5. Discusión** **27**
5.1. El desacople entre niveles transversales y variaciones temporales . . . . . 28
5.2. Mecanismos económicos de la heterogeneidad sectorial . . . . . 28
5.3. La brecha de realización productiva y las fricciones de optimización . . . . 29
5.3.1. De la adopción de herramientas genéricas a la resolución de cuellos de botella específicos . . . . . 30
5.4. Límites metodológicos y cautela interpretativa . . . . . 31

**6. Conclusiones** **31**

**7. Bibliografía** **34**

**Anexos** **36**

# Índice de tablas


1. Sectores incluidos en el análisis . . . . . 16
2. Evolución de productividad e indicadores seleccionados de IA . . . . . 19
3. Adopción general de IA y productividad media por sector . . . . . 20
4. Correlaciones entre IA y productividad . . . . . 22
5. Modelo M3: efectos fijos país–sector y país–año . . . . . 24
6. Pendientes sectoriales del modelo de panel con efectos fijos (M3) . . . . . 25
7. Robustez del modelo M3 para adopción general de IA . . . . . 26
8. Diccionario de variables de la base analítica . . . . . 37
9. Comparación de modelos M1, M2 y M3 para todos los indicadores de IA . 38
10. Estados miembros de la Unión Europea incluidos en el análisis . . . . . 39
11. Modelos de Efectos Aleatorios y contraste de Hausman por indicador de IA 41

# Índice de figuras

1. Adopción y usos de IA por año . . . . . 19
2. Adopción general de IA por sector . . . . . 20
3. Relación transversal entre adopción de IA y log-productividad laboral por país y sector (2024) . . . . . 21
4. Matriz de correlaciones entre productividad e indicadores de IA . . . . . 23

# Resumen

El presente Trabajo Final de Grado analiza la relación entre los usos empresariales de inteligencia artificial y la productividad laboral aparente en sectores económicos de la Unión Europea. A partir de información secundaria de Eurostat, se construye una base país–sector–año que combina indicadores de adopción y usos de inteligencia artificial con datos de valor agregado y personas ocupadas provenientes de estadísticas estructurales empresariales. El objetivo es estudiar la heterogeneidad sectorial de la adopción tecnológica y estimar su asociación con la productividad, distinguiendo entre correlaciones en niveles y variaciones dentro de cada unidad país–sector.

El enfoque es cuantitativo, longitudinal, observacional y no experimental. La estrategia empírica propuesta utiliza modelos de datos de panel con efectos fijos, manteniendo una interpretación asociativa y evitando inferencias causales no respaldadas por el diseño. Los resultados muestran una asociación positiva entre adopción de inteligencia artificial y productividad en niveles, pero esa relación se debilita al controlar por diferencias permanentes entre unidades país–sector y shocks país–año. Esta diferencia sugiere la necesidad de distinguir entre adopción tecnológica y realización productiva, así como de considerar la heterogeneidad sectorial, los activos complementarios y las limitaciones de medición.



**Palabras clave:** inteligencia artificial; productividad laboral; adopción tecnológica; datos de panel; Unión Europea.

# 1. Introducción

## 1.1. Planteo del problema

La difusión reciente de tecnologías de inteligencia artificial (IA) ha reactivado el debate sobre su capacidad para modificar procesos productivos, reducir costos, mejorar la calidad de las decisiones empresariales y elevar la productividad. Sin embargo, la adopción de una tecnología y la obtención de resultados económicos observables son fenómenos diferentes. Una empresa puede declarar el uso de IA sin que ello implique necesariamente una transformación profunda de sus procesos, una mejora inmediata de eficiencia o un aumento medible de la productividad.

Desde la perspectiva económica, la incorporación de IA puede entenderse como una decisión de adopción tecnológica cuyo impacto depende de las tareas afectadas, la organización interna, las capacidades del personal, la infraestructura digital, la calidad de los datos, los costos de implementación y el horizonte temporal de maduración. La literatura sobre tecnologías de propósito general y difusión tecnológica sostiene que los beneficios de ciertas innovaciones complejas suelen observarse con demora, requiriendo inversiones complementarias, aprendizaje y reorganización de procesos internos antes de materializarse en ganancias observables de productividad (Bresnahan et al., 2002; Brynjolfsson et al., 2021).

La pregunta principal de este trabajo es: *¿cómo varían la adopción y los usos empresariales de inteligencia artificial entre los sectores económicos de la Unión Europea, y en qué medida esas diferencias se asocian con distintos niveles y variaciones de productividad laboral?*

Esta pregunta no busca demostrar que la IA cause por sí sola aumentos de productividad. El propósito es más acotado: reconstruir evidencia empírica comparable, estudiar patrones de adopción y usos funcionales, y evaluar si la asociación positiva que puede observarse entre unidades estructuralmente distintas se mantiene al analizar variaciones dentro de cada país–sector.

## 1.2. Delimitación del tema y del área de estudio

El trabajo se inscribe en la microeconomía aplicada, la economía de la empresa y la economía del cambio tecnológico. El análisis utiliza información secundaria de Eurostat para los 27 Estados miembros de la Unión Europea (UE-27), nueve sectores de actividad definidos según la Nomenclatura Estadística de Actividades Económicas en la Comunidad Europea (NACE Rev. 2) y los años 2021, 2023 y 2024.

La unidad de observación es la combinación país–sector–año. La adopción de IA se mide

mediante el porcentaje de empresas de diez o más personas ocupadas que declara utilizar al menos una tecnología de IA. Además, se consideran indicadores de intensidad y usos funcionales, tales como IA en organización de procesos o toma de decisiones, producción, logística, marketing y ventas, y seguridad informática.

La productividad laboral aparente se calcula como el cociente entre valor agregado y personas ocupadas:

$$\text{Productividad}_{cst} = \frac{\text{Valor agregado}_{cst}}{\text{Personas ocupadas}_{cst}}, \tag{1}$$

donde $c$ identifica al país, $s$ al sector y $t$ al año. Este indicador no mide productividad total de los factores ni permite aislar por sí solo la contribución causal de la IA.

## 1.3. Objetivo general

Analizar cómo varían la adopción y los usos empresariales de inteligencia artificial entre sectores de la Unión Europea y estimar su asociación con la productividad laboral aparente, utilizando la adopción general como referencia y considerando la heterogeneidad productiva sectorial.

## 1.4. Objetivos específicos

- Integrar en una base país–sector–año indicadores de IA, valor agregado y personas ocupadas de Eurostat.
- Describir la evolución y heterogeneidad de la adopción de IA por país, sector y año.
- Calcular y comparar la productividad laboral aparente entre las unidades analizadas.
- Estimar una asociación de referencia entre adopción general de IA y productividad mediante modelos de datos de panel.
- Comparar la adopción general con usos empresariales específicos de IA.
- Examinar si la relación entre IA y productividad presenta heterogeneidad sectorial.
- Evaluar la sensibilidad de los resultados frente a especificaciones alternativas, ponderaciones y exclusión de valores extremos.
- Explicitar las limitaciones de medición e interpretación del diseño empírico.

## 1.5. Hipótesis de trabajo

La hipótesis de referencia sostiene que una mayor adopción empresarial de IA se asocia con una mayor productividad laboral aparente. La primera hipótesis central plantea que

dicha asociación no es uniforme entre funciones empresariales: los usos vinculados con procesos internos, decisiones, producción y logística podrían relacionarse más estrechamente con productividad que la adopción general o que usos de apoyo y comercialización. La segunda hipótesis central sostiene que la asociación entre IA y productividad es heterogénea entre sectores debido a diferencias en tareas, tecnologías productivas y capacidades complementarias.

Estas hipótesis son asociativas. No se formulan como afirmaciones causales ni como resultados garantizados.

### 1.6. Importancia del estudio

El aporte del trabajo reside en construir una base reproducible con fuentes oficiales, distinguir entre adopción general y usos específicos de IA, comparar correlaciones en niveles con variaciones dentro de cada unidad país–sector y discutir la heterogeneidad sectorial de la relación IA–productividad. En una tesina de grado, la contribución esperada no consiste en resolver de manera definitiva la identificación causal, sino en presentar un análisis empírico transparente, metodológicamente defendible y prudente en su interpretación.

### 1.7. Limitaciones del estudio

El diseño permite estudiar asociaciones, pero no identifica de manera concluyente el efecto causal de la IA. Entre las principales limitaciones se encuentran el reducido número de años comparables, el nivel agregado país–sector, la posible causalidad inversa, la omisión de capacidades organizacionales no observadas y la medición de productividad mediante valor agregado monetario corriente.

Los datos no permiten determinar si una empresa concreta eligió la herramienta adecuada, si implementó bien la IA, cuánto gastó, cuánto ahorró o cuál fue su retorno económico. Por lo tanto, una combinación de elevada adopción y débil crecimiento de productividad puede sugerir una brecha de realización productiva compatible con distintos mecanismos, pero no demuestra por sí sola un uso incorrecto de la tecnología.

## 2. Marco teórico y antecedentes

### 2.1. Adopción tecnológica, enfoque de tareas y heterogeneidad funcional

La incorporación de inteligencia artificial en el ámbito empresarial se inscribe dentro de los procesos de adopción tecnológica analizados por la teoría económica. Desde la perspectiva de la firma, la decisión de adoptar una tecnología responde a una optimización inter-

temporal bajo incertidumbre, donde se contrastan los costos de adquisición, instalación, aprendizaje y reingeniería con los flujos de beneficios esperados derivados de ganancias de eficiencia o reducción de costos operativos.

En consonancia con la literatura contemporánea de economía laboral y del cambio tecnológico, la producción puede descomponerse en una secuencia de tareas cognitivas y manuales, rutinarias y no rutinarias (Acemoglu and Restrepo, 2018). Las herramientas de IA interactúan de forma diferenciada con tareas específicas: algunas son automatizables directamente (sustituyendo la intervención humana en procesos estandarizados), mientras que en otras la tecnología complementa o aumenta las capacidades de los trabajadores, incrementando la calidad o velocidad de ejecución.

Esta especificidad fundamenta la necesidad de examinar la heterogeneidad funcional de la adopción. No es esperable que cualquier uso de IA ejerza el mismo efecto sobre el desempeño productivo. En particular, conviene distinguir entre:

1. **Usos en el núcleo operativo (procesos, decisiones, producción y logística):** herramientas integradas en la optimización de flujos de trabajo, control de calidad y mantenimiento predictivo, que presentan un vínculo directo con la reducción de tiempos muertos y costos de coordinación.
2. **Usos periféricos o de apoyo (marketing, ventas y seguridad):** aplicaciones orientadas a la diferenciación comercial o a estándares básicos de TIC que no transforman necesariamente la eficiencia estructural interna.

## 2.2. Tecnologías de propósito general, costos de ajuste y desfases temporales

Diversos autores conceptualizan a la inteligencia artificial como una tecnología de propósito general (*General Purpose Technology* o GPT), caracterizada por su potencial difusión multisectorial y su capacidad para inducir innovaciones complementarias.

Una propiedad central de las tecnologías de propósito general es la desconexión temporal entre su difusión inicial y su impacto medible en las estadísticas agregadas de productividad. La literatura sobre adopción tecnológica enfatiza que la incorporación efectiva de innovaciones complejas no opera de manera instantánea ni automática: requiere cuantiosas inversiones en activos complementarios intangibles, rediseño de procesos organizacionales, capacitación del capital humano, acumulación de datos interoperables y transformaciones sustantivas en las prácticas de gestión empresarial (Bresnahan et al., 2002; Brynjolfsson et al., 2021).

Durante las fases iniciales de difusión, una proporción sustantiva del tiempo y de los recursos empresariales se desvía hacia la reconfiguración organizativa y el aprendizaje

técnico. Como advierte la literatura sobre desfases de productividad (Brynjolfsson et al., 2021), dado que las convenciones contables registran habitualmente estos esfuerzos como gastos corrientes de operación y no como acumulación de activos de capital intangible, la productividad aparente observada puede estancarse o declinar transitoriamente durante el período de ajuste. Solo cuando este proceso de aprendizaje madura y se articula plenamente con la operativa diaria pueden materializarse las mejoras de productividad esperadas. Este marco conceptual advierte que la ausencia de una asociación contemporánea positiva de corto plazo entre adopción y productividad no implica ineficacia tecnológica, sino que resulta enteramente compatible con costos de ajuste, reorganización de procesos y desfases temporales en la maduración de las innovaciones.

## 2.3. Fundamentos teóricos y medición econométrica de la productividad: el marco de Berndt y Eurostat

La delimitación conceptual de la variable dependiente reviste una importancia metodológica capital en este trabajo. Como advierte Berndt (1991, Caps. 2 y 9) en su obra canónica sobre econometría aplicada (*The Practice of Econometrics: Classic and Contemporary*), la medición de la productividad exige distinguir con rigor entre medidas de productividad multifactorial o total de los factores (PTF) y medidas de **productividad parcial de factores** (*partial factor productivity*).

En la teoría de la producción, una función de producción sectorial relaciona el producto con los factores primarios e intermedios: $Y = F(K, L, M, A)$, donde $K$ representa el capital, $L$ el trabajo, $M$ los insumos intermedios y $A$ el estado de la tecnología. La productividad laboral se define como una medida parcial que relaciona el producto con el insumo de trabajo:

$$PMe_L = \frac{VAB}{L}, \tag{2}$$

donde $VAB$ es el Valor Agregado Bruto y $L$ el personal ocupado.

Siguiendo a Berndt (1991, Cap. 2), la elección del Valor Agregado en lugar de la Producción Bruta total ($Y$) es obligada en el análisis sectorial: el producto bruto comete el error de la doble contabilización al incorporar insumos intermedios adquiridos a otros sectores. El Valor Agregado ($VAB = Y - M$), en cambio, aísla la riqueza neta generada en el interior de las empresas del sector mediante la combinación de sus factores propios.

Asimismo, Berndt (1991) enfatiza que la productividad laboral es una medida "aparente". Al relacionar todo el valor generado con el insumo de trabajo, el cociente $VAB/L$ no mide exclusivamente la destreza o eficiencia intrínseca de los trabajadores, sino que absorbe de manera preponderante la **intensidad de capital** (*capital deepening*, $K/L$)

y las complementariedades tecnológicas organizacionales. Un sector intensivo en capital o infraestructura digital exhibirá niveles sistemáticamente más elevados de $VAB/L$ con independencia de la productividad marginal pura del trabajo.

En estricta consonancia con estos fundamentos, la oficina estadística de la Unión Europea (Eurostat) establece el estándar de **Productividad Laboral Aparente** (*Apparent Labour Productivity*, en las Estadísticas Estructurales Empresariales (*Structural Business Statistics*, SBS; código oficial `V91110`) (Eurostat, 2026b), bajo el Reglamento UE 2019/2152. Eurostat la calcula formalmente como:

$$\text{Productividad}_{cst} = \frac{\text{Valor Agregado a costo de factores}_{cst}}{\text{Personas ocupadas}_{cst}}, \tag{3}$$

expresada en miles de euros corrientes por persona ocupada.

Un punto metodológico crucial discutido extensamente por Berndt (1991, Caps. 2 y 9) refiere al tratamiento de los precios. El autor advierte sobre los severos sesgos y errores de medición (*measurement errors*) que se inducen al intentar deflactar variables empresariales utilizando índices de precios agregados inadecuados o construidos bajo universos metodológicos divergentes. En particular, la aplicación de deflactores macroeconómicos de Cuentas Nacionales (que cubren toda la economía, incluidas administraciones públicas y microempresas) sobre datos SBS de empresas de 10 o más ocupados generaría un descalce muestral e introduciría perturbaciones espurias.

Por este motivo, este trabajo adopta la variable oficial de Eurostat en términos nominales y resuelve el control de precios en el plano de la **estrategia econométrica**: en virtud del teorema de Frisch–Waugh–Lovell (Wooldridge, 2010), la inclusión de efectos fijos país–año ($\gamma_{ct}$) en los modelos de panel absorbe la inflación agregada y los shocks macroeconómicos anuales comunes a todos los sectores de cada país, aislando la variación sectorial relativa dentro de cada economía nacional.

## 2.4. Evidencia empírica sobre IA y productividad en Europa

La literatura empírica sobre IA y productividad se divide entre estudios a nivel de empresa (*firm-level*) y análisis agregados sectoriales. En el plano microeconómico, Czarnitzki et al. (2023) constatan en Alemania que las firmas que incorporan IA exhiben mayores niveles de productividad laboral, aunque condicionado por dotaciones previas de TIC y personal calificado. Asimismo, Aldasoro et al. (2026) (BIS) hallan heterogeneidad sustancial en empresas europeas, con ganancias concentradas en organizaciones con transformaciones profundas de gobernanza y gestión.

A nivel sectorial en la Unión Europea, Kádárová et al. (2026) documentan marcadas dis-

paridades entre países miembros en digitalización y productividad. Por su parte, Yilmaz (2026) formula el concepto de la brecha de atribución de la IA (*AI attribution wedge*), evidenciando que la aceleración en las tasas de adopción no encuentra un correlato contemporáneo inmediato en la productividad sectorial. Esta disonancia obedece a un fenómeno clásico de selección y agregación: las encuestas microeconómicas capturan el desempeño de firmas pioneras en la frontera (*frontier firms*), mientras que los datos sectoriales consolidan el desempeño conjunto de líderes y rezagadas, amortiguando el impacto agregado si la difusión aún no alcanza una masa crítica profunda.

## 2.5. Margen extensivo, intensidad de uso y brecha de realización

Las encuestas estadísticas oficiales capturan predominantemente el **margen extensivo** de la adopción: un indicador binario sobre si la firma utiliza al menos una tecnología de IA. Sin embargo, la literatura sobre tecnologías de información (Bresnahan et al., 2002) y automatización (Acemoglu and Restrepo, 2018) indica que el acceso formal no garantiza mejoras productivas si no se profundiza el **margen intensivo** (volumen de tareas automatizadas e integración procedimental).

Esta distinción delimita el alcance de las métricas disponibles y permite formalizar una cadena de transmisión conceptual:

$$\text{Adopción nominal (Eurostat)} \longrightarrow \text{Intensidad de uso} \longrightarrow \text{Integración en procesos} \longrightarrow \text{Realización productiva}$$

Las estadísticas de Eurostat capturan el primer eslabón del esquema. La realización efectiva de ganancias de productividad requiere transitar los eslabones intermedios de intensidad y reingeniería organizacional, lo que explica por qué la adopción general no exhibe necesariamente una correlación contemporánea positiva con el valor agregado por trabajador en el corto plazo.

## 2.6. Desafíos econométricos en datos de panel: de Efectos Aleatorios a Efectos Fijos

La estimación de la relación entre adopción de IA y productividad enfrenta desafíos clásicos de identificación (Wooldridge, 2010; Berndt, 1991):

1. **Endogeneidad por selección y causalidad inversa:** las empresas y sectores estructuralmente más productivos y con mayores recursos financieros enfrentan con mayor facilidad los costos fijos y el riesgo de experimentar con IA. Una regresión simple de mínimos cuadrados agrupados (*Pooled OLS*) exhibirá un sesgo positivo

severo por selección.

2. **Inconsistencia del modelo de Efectos Aleatorios:** el estimador de Efectos Aleatorios (*Random Effects*) descansa en el supuesto crucial de que la heterogeneidad no observada de cada unidad ($\alpha_i$) no está correlacionada con los regresores de adopción ($\text{Cov}(\alpha_i, IA_{it}) = 0$). Teóricamente, este supuesto resulta insostenible: las características estructurales permanentes de cada unidad país–sector (infraestructura digital histórica, capital humano) determinan simultáneamente su nivel de productividad y su tasa de adopción. Por ende, el modelo de efectos aleatorios es inconsistente, lo que exige aplicar formalmente el **contraste de Hausman** para contrastar la hipótesis nula de exogeneidad de los efectos individuales.

3. **Identificación mediante Efectos Fijos:** ante el rechazo empírico de los efectos aleatorios, la literatura econométrica prescribe recurrir al estimador dentro de entidad (*within estimator*). La inclusión de efectos fijos país–sector ($\alpha_{cs}$) elimina por completo cualquier factor no observable invariable en el tiempo. Complementariamente, los efectos fijos país–año ($\gamma_{ct}$) absorben los shocks macroeconómicos y las variaciones agregadas del nivel general de precios comunes a cada país. De este modo, el parámetro de interés identifica la asociación a partir de cambios temporales dentro de cada unidad país–sector, condicional a dichos shocks comunes.

## 2.7. Aporte específico de este trabajo

En el marco de la literatura expuesta, la presente tesina de grado se define como una replicación y extensión metodológica transparente. Su contribución se articula en cuatro elementos:

- Reconstrucción abierta y reproducible de una base de panel país–sector–año no balanceada ($N = 667$) para la UE-27 a partir de fuentes oficiales armonizadas de Eurostat (SBS y TIC).
- Desagregación funcional de los indicadores de IA, evaluando la adopción general frente a usos en procesos, producción, logística, comercialización y seguridad.
- Contraste econométrico riguroso: comparación sistemática entre corte transversal en niveles (Pooled OLS), Efectos Aleatorios (RE) con contraste de Hausman, y modelos de Efectos Fijos (FE) con controles estrictos por heterogeneidad permanente y shocks país–año.
- Análisis explícito de la heterogeneidad sectorial y pruebas de robustez predefinidas (ponderación por empleo y sensibilidad a extremos).

La discusión se estructura alrededor de la **brecha de realización productiva**: un patrón descriptivo compatible con costos de ajuste y maduración de intangibles, manteniendo una

estricta cautela interpretativa y evitando inferir causalidad individual a partir de datos agregados sectoriales.

# 3. Datos y metodología

## 3.1. Fuentes de información y muestra analítica

El trabajo utiliza datos secundarios oficiales de la oficina estadística de la Unión Europea (Eurostat). Las fuentes principales son la base `isoc_eb_ai`, referida a la adopción empresarial de inteligencia artificial (Eurostat, 2026c); la base `isoc_eb_ain2`, con indicadores complementarios de usos específicos de IA (Eurostat, 2026a); y las Estadísticas Estructurales Empresariales (*Structural Business Statistics* - SBS), utilizadas para obtener valor agregado y personas ocupadas (Eurostat, 2026b).

La grilla teórica de cobertura comprende 27 países de la UE, nueve sectores NACE Rev. 2 y tres olas temporales (2021, 2023 y 2024), totalizando $27 \times 9 \times 3 = 729$ combinaciones país–sector–año. En los registros oficiales de Eurostat, 62 celdas presentan datos faltantes en origen debido al secreto estadístico o a la no disponibilidad del relevamiento en determinados Estados miembros (53 observaciones sin datos de SBS y 15 sin datos de encuesta TIC, con 6 omisiones simultáneas).

Por lo tanto, la **muestra analítica central de este trabajo corresponde a la totalidad de las observaciones reales disponibles ($n = 667$), estructuradas como un panel no balanceado de 233 unidades país–sector**. Forzar un balanceo artificial de la muestra exigiría descartar 40 observaciones plenamente válidas sólo para retener entidades observadas en las tres olas temporales del panel ($n = 627$), lo que reduciría la potencia estadística e induciría un riesgo innecesario de sesgo de atrición. Los estimadores modernos de datos de panel operan de forma nativa sobre paneles desbalanceados, utilizándose la muestra balanceada exclusivamente como control de sensibilidad.

## 3.2. Ficha metodológica de la encuesta y representatividad de la muestra

Para comprender la naturaleza de las variables explicativas es fundamental precisar el diseño metodológico de la encuesta europea de uso de TIC en empresas (*Community survey on ICT usage and e-commerce in enterprises*):

- **Unidad de relevamiento:** la unidad estadística es la **empresa** (*enterprise*), no el trabajador individual ni el hogar.
- **Informante clave:** el cuestionario es respondido formalmente a nivel corporativo por el responsable del área de Sistemas/TIC (CIO/CTO) o la dirección general de

la firma, capturando adopción institucional en los procesos de negocio y no usos personales esporádicos.

- **Módulo temático y delimitación conceptual de la IA:** si bien el relevamiento marco de Eurostat monitorea anualmente el uso de tecnologías de la información y la comunicación (TIC) en sentido amplio, este trabajo explota exclusivamente el **módulo específico y armonizado de Inteligencia Artificial** introducido en las olas 2021, 2023 y 2024 (series oficiales `isoc_eb_ai` e `isoc_eb_ain2`). Dicho módulo adopta la definición internacional de IA de la OCDE y la Comisión Europea, indagando el uso productivo de tecnologías avanzadas tales como aprendizaje automático (*machine learning*), redes neuronales, procesamiento de lenguaje natural y minería de texto, visión artificial, reconocimiento de voz y automatización inteligente de flujos de trabajo. Esta delimitación conceptual excluye explícitamente paquetes ofimáticos genéricos, software administrativo tradicional o herramientas de gestión estándar sin algoritmos de inferencia o aprendizaje.

- **Población objetivo y métrica (`PC_ENT`):** cubre a empresas formales con 10 o más personas ocupadas. Los institutos nacionales de estadística aplican un diseño probabilístico estratificado por sector y tramo de tamaño (10–49, 50–249, 250+ empleados), incorporando factores de expansión muestral (*sampling weights*). Por ende, el indicador `ai_any_pct` mide el porcentaje del universo total de empresas de ese sector y país que ha adoptado la tecnología.

- **Tratamiento de la heterogeneidad de escala y dispersión de tamaño:** un desafío metodológico recurrente en paneles internacionales radica en la disparidad de escala física entre economías de gran dimensión (como Alemania, Francia o Italia) y economías de menor escala demográfica o insular (como Malta, Chipre o Luxemburgo). Este desafío se neutraliza formalmente en tres niveles complementarios:

    1. *Normalización matemática por variables intensivas:* el modelo econométrico no compara volúmenes agregados absolutos (como valor agregado bruto total o número absoluto de empresas con IA), sino ratios intensivos normalizados: el valor agregado por persona ocupada ($VAB/L$) y la tasa porcentual de empresas adoptantes sobre el universo del sector (`PC_ENT`). Al dividir por el empleo y el universo empresarial de cada entidad, se atenúa el efecto mecánico del tamaño bruto del mercado sobre los niveles de las variables, si bien subsisten posibles diferencias estructurales en composición.

    2. *Identificación intra-unidad mediante Efectos Fijos:* el estimador *within* con efectos fijos de entidad ($\alpha_{cs}$) garantiza que la identificación no compare a Malta contra Alemania en corte transversal, sino a cada sector contra su propia trayectoria temporal. Toda diferencia estructural permanente vinculada al ta-

maño del mercado interno o la escala geográfica queda absorbida por $\alpha_{cs}$.

3. *Tratamiento inferencial de la heterocedasticidad y prueba WLS:* en el plano inferencial, los errores estándar se agrupan por conglomerados a nivel de entidad (*cluster-robust*) para absorber heterocedasticidad residual por tamaño de celda. Además, en la muestra empírica ninguna celda carece de masa crítica (el sector más pequeño supera los 1.000 empleados y la mediana muestral es de 140.000 ocupados). Complementariamente, como análisis de sensibilidad frente a diferencias de tamaño relativo entre celdas, se reestima la especificación principal mediante Mínimos Cuadrados Ponderados (*Weighted Least Squares* - WLS) ponderando por personas ocupadas, evaluando si el estimando se modifica al otorgar mayor peso a las observaciones con mayor masa laboral.

## 3.3. Sectores considerados

El análisis empírico abarca nueve secciones de actividad económica clasificadas según la nomenclatura NACE Rev. 2, presentadas en la Tabla 1. Estas ramas representan el núcleo del sector empresarial no financiero cubierto por las estadísticas estructurales armonizadas de Eurostat.

Tabla 1: Sectores incluidos en el análisis

| **Código** | **Sector** |
|---|---|
| C | Industria manufacturera |
| F | Construcción |
| G | Comercio mayorista y minorista |
| H | Transporte y almacenamiento |
| I | Alojamiento y servicios de comida |
| J | Información y comunicación |
| L | Actividades inmobiliarias |
| M | Actividades profesionales, científicas y técnicas |
| N | Actividades administrativas y servicios auxiliares |

## 3.4. Variables

La variable dependiente es el logaritmo natural de la productividad laboral aparente nominal, expresada en miles de euros corrientes por persona ocupada ($\ln(VAB/L)$). La transformación logarítmica estabiliza la varianza, mitiga la influencia de valores atípicos y permite interpretar los coeficientes aproximadamente como semi-elasticidades porcentuales.

Las variables explicativas de IA se expresan como porcentaje de empresas adoptantes. La adopción general se mide con `ai_any_pct`. Como indicadores complementarios se consideran la intensidad tecnológica (adopción de dos o más y tres o más herramientas) y los usos funcionales en procesos y decisiones, producción, logística, marketing y ventas, y seguridad informática. Cada variable se evalúa en modelos separados para evitar multicolinealidad.

## 3.5. Estrategia descriptiva

La primera etapa del análisis examina la evolución temporal de la adopción y de la productividad nominal por año y rama de actividad sobre el panel no balanceado. Asimismo, compara las correlaciones en niveles con las correlaciones de variaciones entre 2021 y 2024 para las entidades con información en ambas olas, contrastando la dimensión de corte transversal frente a la dinámica temporal intra-unidad.

## 3.6. Estrategia econométrica: de Pooled OLS y Efectos Aleatorios a Efectos Fijos

La estrategia econométrica se articula en una secuencia metodológica progresiva:

1. **MCO Agrupado (*Pooled OLS*):** estima la asociación en niveles como punto de referencia transversal:

$$\ln(\text{Productividad}_{cst}) = \beta_0 + \beta_1 \text{IA}_{cst} + \varepsilon_{cst}. \tag{4}$$

2. **Efectos Aleatorios (*Random Effects* - RE):** asume que la heterogeneidad no observada de cada unidad país–sector ($\alpha_{cs}$) es ortogonal a los regresores, cumpliéndose $\text{Cov}(\alpha_{cs}, \text{IA}_{cst}) = 0$. Se estima mediante Mínimos Cuadrados Generalizados (GLS) con errores agrupados por entidad.

3. **Contraste de Hausman:** evalúa formalmente la hipótesis de exogeneidad de los efectos individuales mediante la regresión auxiliar de Mundlak (1978) y Wooldridge (2010), contrastando si la media temporal de entidad $\bar{\text{IA}}_{cs}$ es nula en un modelo RE robusto.

4. **Modelos de Efectos Fijos (*Fixed Effects*):** ante el rechazo empírico de RE, se estiman tres especificaciones dentro de entidad:

$$\text{M1 (País + Sector + Año):} \quad \ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \mu_c + \eta_s + \lambda_t + \varepsilon_{cst}, \tag{5}$$

$$\text{M2 (Entidad + Año):} \quad \ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \alpha_{cs} + \lambda_t + \varepsilon_{cst}, \tag{6}$$

$$\text{M3 (Entidad + País–Año):} \quad \ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}. \tag{7}$$

El modelo M3 constituye la especificación principal preferida. En virtud del teorema de Frisch–Waugh–Lovell (Wooldridge, 2010), los efectos fijos país–sector ($\alpha_{cs}$) absorben las diferencias estructurales permanentes, mientras que los efectos fijos país–año ($\gamma_{ct}$) neutralizan la inflación agregada y los shocks macroeconómicos anuales comunes a todos los sectores de cada país. Los errores estándar se agrupan por conglomerados a nivel de entidad país–sector en todos los modelos.

### 3.7. Heterogeneidad sectorial

La heterogeneidad sectorial se examina descriptivamente y mediante un modelo con interacciones completas sobre la especificación M3:

$$\ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \sum_{s \neq C} \delta_s (\text{IA}_{cst} \times \text{Sector}_s) + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}, \tag{8}$$

donde la Industria Manufacturera ($C$) actúa como categoría base y la pendiente sectorial específica se obtiene como $\beta + \delta_s$.

### 3.8. Robustez

Las pruebas de robustez incluyen: (i) contrastar la muestra principal no balanceada ($n = 667$) con la muestra balanceada ($n = 627$); (ii) ponderar por personas ocupadas (*Weighted Least Squares* - WLS); (iii) excluir valores extremos en los percentiles p1–p99 de productividad; y (iv) validar las estimaciones con algoritmos econométricos estándar (`linearmodels.iv.AbsorbingLS`).

## 4. Resultados

### 4.1. Evolución agregada

La exploración inicial indica que la adopción general media de IA en la muestra principal no balanceada ($n = 667$) aumenta de 9,2 % en 2021 a 17,0 % en 2024. En el mismo período, la productividad laboral aparente nominal media pasa de 62,0 a 72,1 miles de

euros corrientes por persona ocupada (y la mediana de 44,2 a 54,3 miles de euros). La Tabla 2 resume estos indicadores.

Tabla 2: Evolución de productividad e indicadores seleccionados de IA

| Año | Obs. | Prod. media | Prod. mediana | IA general | Procesos | Producción | Marketing |
|---|---|---|---|---|---|---|---|
| 2021 | 220 | 62,0 | 44,2 | 9,2 | 3,9 | 1,9 | 2,6 |
| 2023 | 224 | 67,3 | 51,8 | 9,9 | 3,9 | 2,3 | 2,8 |
| 2024 | 223 | 72,1 | 54,3 | 17,0 | 6,1 | 3,9 | 6,2 |

Nota: productividad en miles de euros corrientes por persona ocupada. Indicadores de IA en porcentaje de empresas. Muestra principal no balanceada ($n = 667$, 233 entidades).

La Figura 1 ilustra la evolución temporal agregada de estos indicadores, evidenciando que el incremento en la adopción general en 2024 estuvo acompañado por una difusión simultánea en usos de gestión, producción y comercialización.

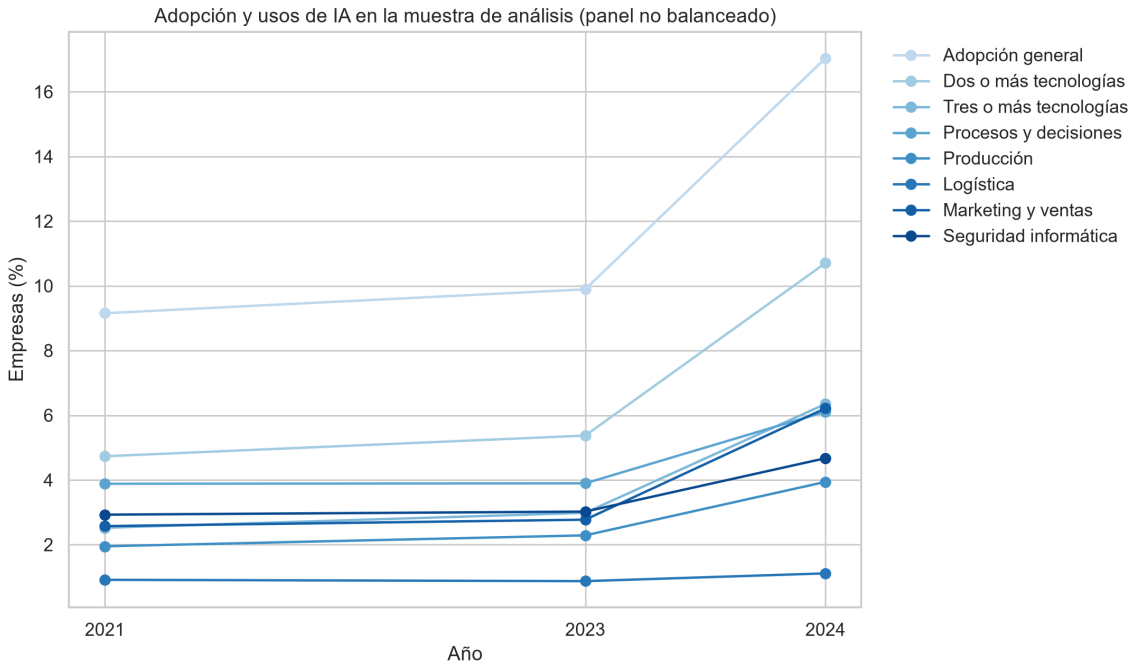



Figura 1: Adopción y usos de IA por año

## 4.2. Heterogeneidad sectorial descriptiva

La adopción de IA presenta diferencias claras entre sectores. Información y comunicación muestra el mayor promedio de adopción general, seguido por actividades profesionales, científicas y técnicas. En el extremo opuesto se ubican alojamiento y servicios de comida, construcción y transporte. La Tabla 3 y la Figura 2 resumen esta heterogeneidad.

Tabla 3: Adopción general de IA y productividad media por sector

| Código | Sector | IA general | Prod. media |
|---|---|---|---|
| J | Información y comunicación | 33,6 | 118,6 |
| M | Actividades profesionales, científicas y técnicas | 18,5 | 67,0 |
| L | Actividades inmobiliarias | 11,0 | 110,6 |
| N | Actividades administrativas y servicios auxiliares | 10,3 | 35,4 |
| C | Industria manufacturera | 8,9 | 94,2 |
| G | Comercio mayorista y minorista | 8,5 | 53,0 |
| H | Transporte y almacenamiento | 7,6 | 61,0 |
| F | Construcción | 4,7 | 52,4 |
| I | Alojamiento y servicios de comida | 4,6 | 28,0 |

Nota: IA general en porcentaje de empresas; productividad en miles de euros corrientes por persona ocupada. Promedios de la muestra principal no balanceada ($n = 667$, 233 entidades).

La Figura 1 ilustra la evolución temporal agregada de estos indicadores, evidenciando que el incremento en la adopción general en 2024 estuvo acompañado por una difusión simultánea en usos de gestión, producción y comercialización.

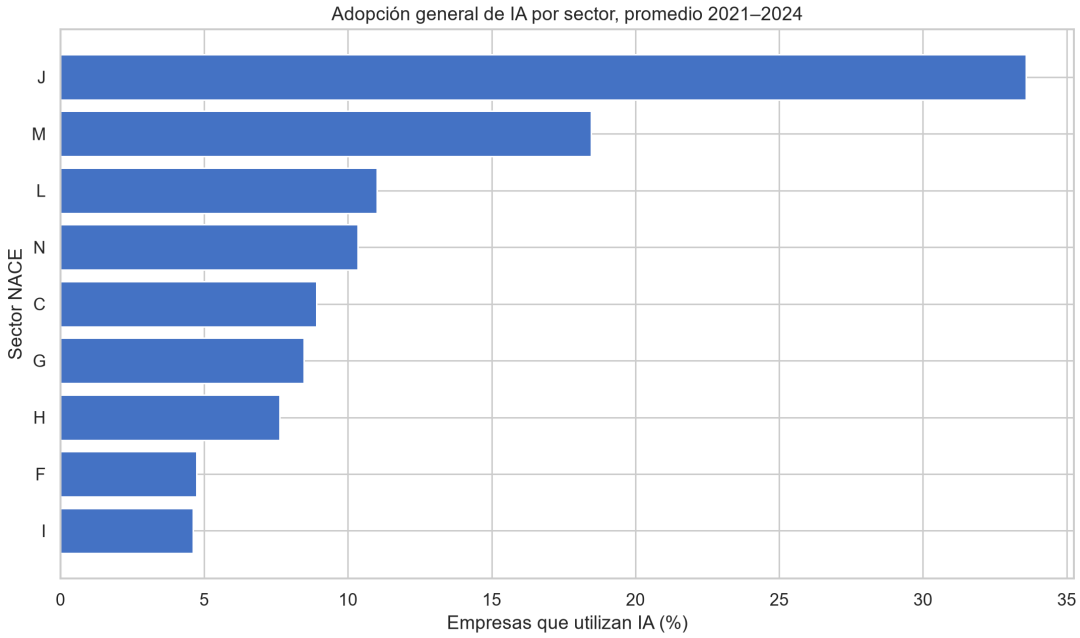



Figura 2: Adopción general de IA por sector

La heterogeneidad en niveles también se hace visible al examinar la dispersión entre adopción y log-productividad para cada país y sector en el corte transversal de 2024 (Figura 3). El uso de log-productividad reduce la influencia visual de valores extremos y mantiene consistencia con las correlaciones y modelos econométricos reportados. En este gráfico se aprecia con nitidez la fuerte correlación positiva transversal: las unidades país–

sector con mayor productividad laboral aparente (ubicadas en el sector de Información y Comunicación o en países de mayores ingresos) tienden a situarse sistemáticamente hacia la derecha en tasas de adopción, mientras que sectores tradicionales o de servicios personales se concentran en el cuadrante inferior izquierdo.

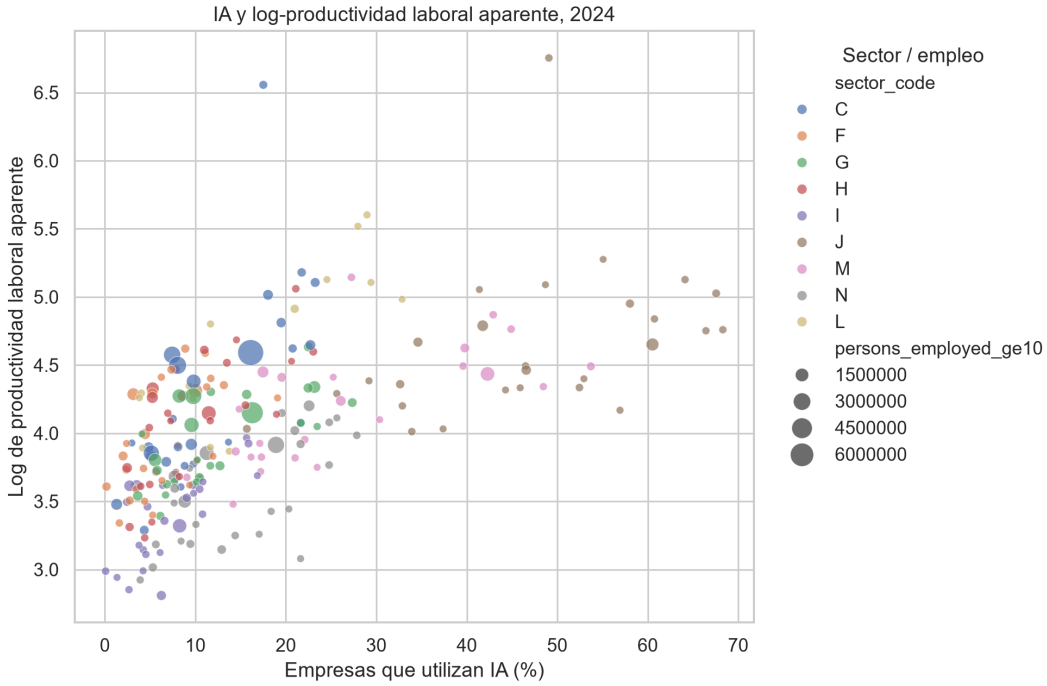



Figura 3: Relación transversal entre adopción de IA y log-productividad laboral por país y sector (2024)

## 4.3. Correlaciones en niveles y cambios

Las correlaciones en niveles entre indicadores de IA y log-productividad son marcadamente positivas ($r = 0,558$ para adopción general). Sin embargo, las correlaciones entre cambios de IA y cambios de log-productividad entre 2021 y 2024 son débiles o negativas ($r = -0,229$, $p < 0,001$ para adopción general). Esta discrepancia sugiere que los sectores o países más productivos adoptan más IA en promedio, sin que los aumentos recientes de adopción se traduzcan contemporáneamente en mayor crecimiento de productividad dentro de cada unidad observada.

Tabla 4: Correlaciones entre IA y productividad

| **Indicador** | **Obs.** | $r$ **niveles** | $p$ | $r$ **cambios** | $p$ |
|---|---|---|---|---|---|
| Adopción general | 667 | 0,558 | <0,001 | -0,229 | <0,001 |
| Dos o más tecnologías | 662 | 0,489 | <0,001 | -0,226 | 0,001 |
| Tres o más tecnologías | 653 | 0,457 | <0,001 | -0,215 | 0,002 |
| Procesos y decisiones | 662 | 0,522 | <0,001 | -0,073 | 0,291 |
| Producción | 631 | 0,499 | <0,001 | -0,145 | 0,043 |
| Logística | 627 | 0,416 | <0,001 | 0,015 | 0,831 |
| Marketing y ventas | 640 | 0,412 | <0,001 | -0,274 | <0,001 |
| Seguridad informática | 626 | 0,439 | <0,001 | -0,131 | 0,069 |

Nota: las correlaciones en niveles usan log-productividad ($n = 626$–$667$). Las correlaciones de cambios corresponden a variaciones 2021–2024 ($n = 193$–$213$ entidades).

La Figura 1 ilustra la evolución temporal agregada de estos indicadores, evidenciando que el incremento en la adopción general en 2024 estuvo acompañado por una difusión simultánea en usos de gestión, producción y comercialización.

La estructura de interdependencia lineal entre todas las variables analizadas se resume visualmente en la matriz de correlaciones de la Figura 4, donde se destaca la elevada correlación interna entre los diferentes indicadores de intensidad y funciones de IA.

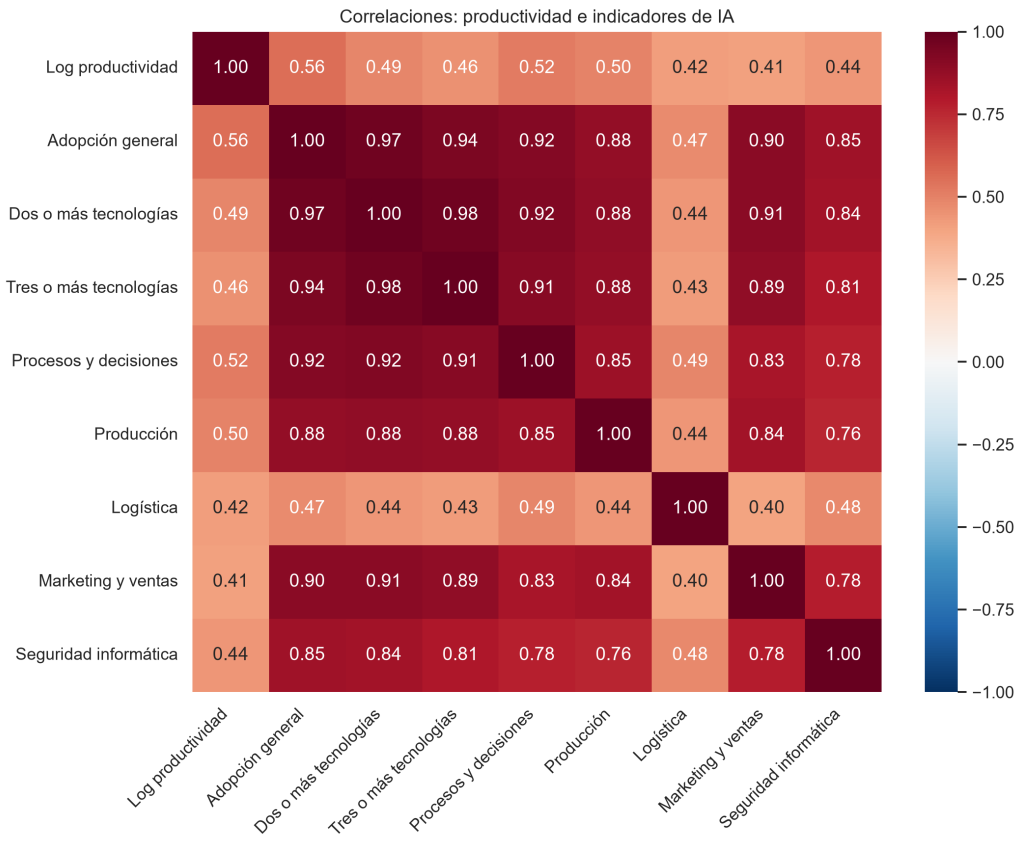



Figura 4: Matriz de correlaciones entre productividad e indicadores de IA

## 4.4. Modelo de panel

La especificación con efectos fijos de país–sector y país–año (M3) sobre la muestra principal no balanceada ($n = 667$, 233 clusters país–sector) no arroja coeficientes estadísticamente significativos para los indicadores de IA a niveles convencionales. La Tabla 5 reporta el modelo preferido. Para adopción general, el coeficiente estimado por un punto porcentual es $\beta = -0,0013$ ($EE = 0,0009$, $p = 0,154$). Interpretado para un aumento de 10 puntos porcentuales, el efecto estimado equivale a $-1,3\,\%$, no siendo estadísticamente distinguible de cero.

Tabla 5: Modelo M3: efectos fijos país–sector y país–año

| **Indicador** | $\beta$ **1 pp** | **EE** | $p$ | **Efecto 10 pp** | **Obs.** |
|---|---|---|---|---|---|
| Adopción general | -0,0013 | 0,0009 | 0,154 | -1,3 | 667 |
| Dos o más tecnologías | -0,0017 | 0,0010 | 0,083 | -1,6 | 662 |
| Tres o más tecnologías | -0,0020 | 0,0013 | 0,120 | -2,0 | 653 |
| Procesos y decisiones | -0,0007 | 0,0016 | 0,660 | -0,7 | 662 |
| Producción | -0,0014 | 0,0016 | 0,385 | -1,4 | 631 |
| Logística | -0,0011 | 0,0077 | 0,888 | -1,1 | 627 |
| Marketing y ventas | -0,0038 | 0,0020 | 0,054 | -3,8 | 640 |
| Seguridad informática | -0,0019 | 0,0023 | 0,412 | -1,8 | 626 |

Nota: variable dependiente: logaritmo de productividad laboral aparente. Muestra principal no balanceada ($n = 667$, 233 clusters país–sector). Errores estándar agrupados por entidad país–sector. Estimado con `linearmodels.iv.AbsorbingLS`. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

Este resultado no debe interpretarse como evidencia de que la IA reduzca productividad ni como prueba de que la IA sea ineficaz. Indica que, bajo controles exigentes y con el horizonte temporal disponible, no se observa una asociación temporal positiva robusta. El patrón es compatible con diferencias estructurales, costos de ajuste, maduración lenta, inversiones complementarias, causalidad inversa, shocks sectoriales o limitaciones de medición.

## 4.5. Heterogeneidad sectorial en el modelo de panel

Para evaluar si la relación temporal entre adopción y productividad difiere según la estructura productiva de cada actividad, se estimó la especificación con interacciones sectoriales definida en la metodología, tomando a la Industria Manufacturera ($C$) como sector base de referencia:

$$\ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \sum_{s \neq C} \delta_s (\text{IA}_{cst} \times \text{Sector}_s) + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}. \tag{9}$$

La pendiente específica de cada sector $s$ se obtiene calculando la combinación lineal $\beta_s = \beta + \delta_s$, cuyos errores estándar se derivan mediante el método delta agrupado por entidad país–sector. La Tabla 6 presenta las estimaciones de las pendientes sectoriales resultantes.

Tabla 6: Pendientes sectoriales del modelo de panel con efectos fijos (M3)

| **Código** | **Sector** | $\beta$ **total** | **EE** | $t$ | $p$ | **Efecto 10 pp** |
|---|---|---|---|---|---|---|
| C | Industria manufacturera (ref.) | -0,0098 | 0,0026 | -3,81 | <0,001 | -9,4 % |
| G | Comercio mayorista y minorista | -0,0136 | 0,0021 | -6,39 | <0,001 | -12,8 % |
| M | Actividades profesionales y científicas | -0,0029 | 0,0011 | -2,70 | 0,007 | -2,8 % |
| H | Transporte y almacenamiento | -0,0025 | 0,0033 | -0,76 | 0,449 | -2,5 % |
| J | Información y comunicación | -0,0011 | 0,0009 | -1,18 | 0,237 | -1,1 % |
| N | Actividades administrativas y auxiliares | -0,0012 | 0,0019 | -0,61 | 0,541 | -1,2 % |
| F | Construcción | -0,0008 | 0,0040 | -0,20 | 0,842 | -0,8 % |
| L | Actividades inmobiliarias | 0,0040 | 0,0071 | 0,56 | 0,574 | +4,1 % |
| I | Alojamiento y servicios de comida | 0,0110 | 0,0044 | 2,48 | 0,013 | +11,6 % |

Nota: variable dependiente: logaritmo de productividad laboral aparente. Estimado con `linearmodels.iv.AbsorbingLS` sobre la muestra principal no balanceada ($n = 667$, 233 entidades). Errores estándar agrupados por entidad país–sector. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

La estimación con interacciones sugiere heterogeneidad sectorial que quedaba encubierta en el coeficiente agregado del modelo sin interacciones. Dado el panel corto, estos resultados deben leerse como exploratorios:

- En sectores con cadenas logísticas complejas e intensivos en capital físico, como la Industria Manufacturera ($C$) y el Comercio ($G$), las pendientes dentro de entidad son negativas y estadísticamente significativas al 1 % ($\beta = -0,0098$ y $\beta = -0,0136$, respectivamente). Este comportamiento es compatible, entre otras interpretaciones, con la presencia de costos de ajuste, reorganización de procesos y desvíos transitorios de recursos asociados a la adopción temprana; sin embargo, el diseño observacional no mide esos costos directamente ni permite separar ese mecanismo de shocks sectoriales concurrentes (como perturbaciones energéticas o cuellos de botella en insumos industriales).
- En el sector de Información y Comunicación ($J$), donde la penetración de herramientas de software y ciencia de datos es nativa y más extendida, el coeficiente es muy próximo a cero ($\beta = -0,0011$) y estadísticamente no significativo. Este coeficiente próximo a cero indica que, en la ventana temporal analizada, no se observa una asociación contemporánea estadísticamente significativa entre aumentos de adopción

y productividad dentro de las unidades país–sector correspondientes a Información y Comunicación. Una posible interpretación, consistente con su elevada intensidad digital previa, es que los costos de ajuste sean menores, aunque este mecanismo no puede identificarse directamente con los datos disponibles.

- En Actividades Profesionales, Científicas y Técnicas ($M$), se observa un coeficiente negativo leve pero significativo al 1 % ($\beta = -0,0029$, $p = 0,007$), un patrón compatible, entre otras explicaciones, con tiempos de aprendizaje y adaptación en servicios intensivos en conocimiento.
- En Alojamiento y Servicios de Comida ($I$), el coeficiente resulta positivo y significativo ($\beta = 0,0110$, $p = 0,013$). Si bien este comportamiento podría estar influido por selección entre empresas adoptantes en un sector con baja adopción basal (4,6 % de empresas en promedio), su interpretación requiere especial cautela por coincidir con la fase de reapertura y normalización post-pandemia del turismo europeo entre 2021 y 2024.
- En Construcción ($F$), Inmobiliarias ($L$), Transporte ($H$) y Servicios Administrativos ($N$), las pendientes no son estadísticamente distinguibles de cero.

## 4.6. Robustez de la especificación principal

Como prueba de sensibilidad de la especificación principal (M3), se reestimó el modelo para adopción general bajo cuatro criterios metodológicos alternativos: la muestra principal no balanceada sin ponderar ($n = 667$), la muestra principal ponderada por personas ocupadas (WLS), la muestra principal excluyendo valores extremos en los percentiles p1–p99 de productividad ($n = 653$), y la muestra restringida a entidades balanceadas en los tres períodos ($n = 627$). La Tabla 7 resume estos resultados.

Tabla 7: Robustez del modelo M3 para adopción general de IA

| **Escenario** | $\beta$ **1 pp** | **EE** | $p$ | **Efecto 10 pp** | **Obs.** |
|---|---|---|---|---|---|
| Muestra principal no balanceada, sin ponderar | -0,0013 | 0,0009 | 0,154 | -1,3 % | 667 |
| Muestra principal, ponderada por empleo (WLS) | -0,0016 | 0,0007 | 0,032 | -1,6 % | 667 |
| Muestra principal, sin extremos p1–p99 | -0,0010 | 0,0008 | 0,250 | -1,0 % | 653 |
| Sensibilidad a balanceo: muestra balanceada | -0,0011 | 0,0009 | 0,250 | -1,1 % | 627 |

Nota: variable dependiente: logaritmo de productividad laboral aparente. Todos los modelos incluyen efectos fijos país–sector y país–año. Errores estándar agrupados por entidad país–sector. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

El signo del coeficiente de adopción general se mantiene negativo en los cuatro escenarios de robustez. No obstante, se observa un cambio relevante en la inferencia estadística:

mientras que en las especificaciones no ponderadas el coeficiente no es estadísticamente significativo a niveles convencionales ($p = 0,154$ en la muestra principal y $p = 0,250$ en la balanceada), bajo la ponderación por personas ocupadas (WLS) el coeficiente resulta estadísticamente significativo al 5 % ($\beta = -0,0016$, $EE = 0,0007$, $p = 0,032$). Este resultado evidencia que, al asignar mayor peso relativo a las ramas que concentran la mayor masa de empleo (donde predominan actividades manufactureras y comerciales tradicionales con elevados costos de reestructuración), la pendiente negativa contemporánea dentro de cada unidad se vuelve más pronunciada. En ningún escenario se detecta una asociación contemporánea positiva.

### 4.7. Validación de especificación: Efectos Aleatorios y Contraste de Hausman

Para contrastar formalmente la idoneidad del estimador de Efectos Fijos frente a un modelo de Efectos Aleatorios (*Random Effects* - RE), se estimó la especificación RE por mínimos cuadrados generalizados (GLS) y se evaluó el test de Hausman mediante la formulación de regresión auxiliar de Mundlak (1978) y Wooldridge (2010).

En la estimación de Efectos Aleatorios sobre la muestra completa ($n = 667$), la adopción general exhibe un coeficiente positivo y altamente significativo ($\beta_{RE} = 0,0111$, $EE = 0,0009$, $p < 0,001$), reflejando que los sectores con mayor adopción media presentan simultáneamente mayores niveles de productividad. Sin embargo, el contraste de Wald de Mundlak arroja un estadístico $\chi^2(1) = 69,10$ ($p = 1,11 \times 10^{-16}$), rechazando categóricamente la hipótesis nula de exogeneidad de los efectos individuales ($\text{Cov}(\alpha_i, IA_{it}) = 0$). Asimismo, al incorporar controles temporales en la regresión auxiliar para evaluar su sensibilidad frente a perturbaciones de período, la hipótesis nula se rechaza con mayor intensidad estadística ($\chi^2(1) = 108,98$, $p < 0,001$). Como se documenta en el Anexo 7 para la totalidad de los indicadores de IA analizados, la correlación entre la heterogeneidad no observada permanente y la propensión sectorial a adoptar tecnología invalida la consistencia de los efectos aleatorios, corroborando que la inferencia temporal debe sustentarse en el estimador de Efectos Fijos (M3).

## 5. Discusión

Los resultados obtenidos en este trabajo ofrecen elementos analíticos de relevancia para la discusión contemporánea sobre la difusión de la inteligencia artificial y su impacto económico, estructurándose en torno a cuatro ejes interpretativos.

## 5.1. El desacople entre niveles transversales y variaciones temporales

El hallazgo central radica en el marcado contraste entre la dimensión de corte transversal y la dimensión temporal dentro de cada unidad. En niveles, la correlación entre adopción de IA y productividad laboral aparente es sistemáticamente positiva y robusta ($r = 0,558$). No obstante, al explotar la variación temporal dentro de cada país–sector mediante efectos fijos que absorben factores estructurales invariables y perturbaciones macroeconómicas comunes por país y año, la asociación contemporánea deja de ser estadísticamente significativa y el parámetro estimado pasa a ser levemente negativo y no distinguible de cero.

Este patrón resulta conceptualmente consistente con la literatura sobre costos de ajuste y desfases en la maduración de tecnologías de propósito general (Bresnahan et al., 2002; Brynjolfsson et al., 2021), si bien debe enfatizarse que un diseño observacional con datos agregados no permite medir de forma contable los costos de transición ni el capital intangible a nivel de firma. La correlación en niveles captura que las economías y sectores más desarrollados y productivos (con mayor stock de capital humano, mejor infraestructura digital y mayor capacidad financiera) son precisamente los que lideran la adopción de tecnologías complejas. Sin embargo, en una ventana de observación corta (2021–2024), el incremento contemporáneo en el porcentaje de firmas que declaran adoptar IA no se traduce de manera mecánica en un aumento del valor agregado por persona. La literatura sugiere que la fase inicial de adopción exige destinar recursos empresariales a la reorganización de procesos, la redefinición de tareas y la formación de capacidades internas, gastos que la contabilidad nacional registra como costos corrientes y no como inversión en capital intangible, manteniendo transitoriamente deprimida la productividad observada.

## 5.2. Mecanismos económicos de la heterogeneidad sectorial

El análisis exploratorio de interacciones sectoriales profundiza la interpretación económica al revelar que la respuesta productiva no es homogénea entre actividades, si bien estos parámetros deben interpretarse con cautela debido a la reducida ventana temporal del panel ($T = 3$):

- **Sectores de alta inercia física y coordinación:** en la Industria Manufacturera y el Comercio Mayorista y Minorista, la adopción de IA puede requerir rediseñar cadenas de abastecimiento, integrar sistemas ciberfísicos o sincronizar almacenes automatizados. En el corto plazo, esos procesos podrían generar costos de aprendizaje y desajustes operativos temporales, lo que ofrece una hipótesis explicativa plausible para las pendientes negativas observadas. Asimismo, estos sectores enfrentaron de forma asimétrica presiones en costos energéticos y disrupciones logísticas durante el

período 2022–2023, factores que también pudieron incidir en la dinámica del valor agregado nominal.

- **Sectores intensivos en información:** en Información y Comunicación, una posible explicación del coeficiente próximo a cero es que la infraestructura digital y las capacidades tecnológicas preexistentes reduzcan los costos de ajuste asociados a nuevas herramientas de IA. Esta interpretación es compatible con el patrón estimado, pero no puede distinguirse empíricamente de otros mecanismos con los datos disponibles.
- **Servicios con baja penetración basal:** en Alojamiento y Comida, el coeficiente positivo podría estar asociado tanto a patrones de selección entre adoptantes en un sector con baja penetración basal como a la fuerte recuperación cíclica posterior a la pandemia. Con el diseño observacional disponible no es posible separar ambos mecanismos.

## 5.3. La brecha de realización productiva y las fricciones de optimización

La evidencia reunida es consistente con la noción de una **brecha de realización productiva**: mientras la adopción declarada de IA aumenta con rapidez en las empresas europeas (alcanzando el 17,0 % en 2024), no se observa en la ventana temporal analizada una asociación contemporánea positiva con la productividad laboral aparente una vez absorbidas las diferencias estructurales permanentes y los shocks macroeconómicos anuales comunes a cada país. Este desacople se verifica de forma sistemática tanto en el panel no balanceado como en el balanceado, así como bajo especificaciones ponderadas por empleo.

Desde una perspectiva microeconómica, adoptar una tecnología no equivale a optimizar su uso dentro de la función de producción. Las empresas a menudo enfrentan fricciones sustanciales para reestructurar sus flujos de trabajo tradicionales:

1. **Inercia organizacional y capacitación:** la fuerza laboral requiere tiempo y entrenamiento continuo para incorporar eficazmente herramientas algorítmicas en sus tareas cotidianas. Sin capacitación adecuada, la adopción de software avanzado puede generar duplicación de tareas o resistencia al cambio en lugar de ahorro de tiempo.
2. **Asimetría de información y selección tecnológica:** muchas firmas adquieren licencias comerciales o soluciones estandarizadas por presión competitiva o imitación, sin contar con el diagnóstico técnico interno para acoplar la herramienta a sus cuellos de botella operativos reales.
3. **La necesidad de intermediación y gestión del cambio:** la materialización efectiva de ganancias de productividad demanda frecuentemente servicios especiali-

zados de consultoría, rediseño de procesos y gobernanza de datos que ayuden a las empresas a transitar la fase de aprendizaje.

Este resultado dialoga directamente con la evidencia de Aldasoro et al. (2026) y Yilmaz (2026), reforzando la conclusión de que la IA es una tecnología complementaria: su rendimiento depende críticamente de la calidad de gestión y de las inversiones intangibles que la acompañan.

Asimismo, es relevante destacar que la hipótesis de que los usos funcionales orientados al núcleo operativo (procesos y toma de decisiones, producción o logística) exhibirían una asociación más estrecha con la productividad que la adopción general no encuentra respaldo empírico en las estimaciones del modelo principal M3. Ninguno de estos coeficientes funcionales resulta estadísticamente significativo en la especificación preferida (con $p$-valores de $0,660$ para procesos, $0,385$ para producción y $0,888$ para logística). Este hallazgo empírico refuerza que, en el horizonte de corto plazo analizado, la penetración de herramientas algorítmicas en tareas operativas aún no se traduce en incrementos observables de valor agregado por persona ocupada.

### 5.3.1. De la adopción de herramientas genéricas a la resolución de cuellos de botella específicos

Una dimensión analítica de relevancia para la teoría de la firma radica en la naturaleza de las soluciones de software adoptadas. Históricamente, la difusión tecnológica en el tejido empresarial se ha canalizado predominantemente a través de modelos estandarizados de software como servicio (*Software as a Service*, SaaS). Si bien estas soluciones comerciales horizontales reducen las barreras de entrada y facilitan un acceso masivo, operan en la práctica como insumos tecnológicos homogéneos que rara vez generan ventajas competitivas sostenibles o resuelven las ineficiencias idiosincrásicas de cada unidad productiva.

La literatura sobre complementariedades organizacionales y tecnologías de propósito general (Bresnahan et al., 2002) y los desarrollos recientes en la frontera algorítmica destacan que la productividad no emerge del uso pasivo de herramientas genéricas no integradas, sino del rediseño adaptativo de los procesos productivos orientado a cuellos de botella específicos de la función de producción. En manufactura y logística, esto abarca el mantenimiento predictivo, la planificación dinámica de inventarios o la sincronización ciberfísica; en servicios, la automatización analítica de operaciones complejas o la reducción de tiempos en flujos documentales críticos. Cuando la adopción empresarial se limita a contratar licencias de software sin acoplar los modelos a los cuellos de botella reales de la firma, la literatura económica predice que la tecnología puede incrementar los costos operativos corrientes sin traducirse en mejoras observables del valor agregado por persona. Este mecanismo se propone aquí como una hipótesis interpretativa y agenda de investigación

microeconómica futura, dado que los datos de Eurostat registran la incidencia de adopción pero no la profundidad ni la personalización técnica de la implementación en cada empresa.

## 5.4. Límites metodológicos y cautela interpretativa

Es imperativo subrayar los límites del diseño econométrico implementado:

1. **Nivel de agregación y supuestos normativos:** la unidad de análisis es la entidad país–sector. Por consiguiente, los resultados no permiten diagnosticar si una empresa individual específica obtuvo un retorno de inversión positivo o negativo, ni evaluar la calidad técnica de sus decisiones de implementación. La presencia de costos de ajuste o fricciones organizativas constituye una hipótesis teórica compatible con los datos agregados, no una medición contable directa a nivel firma.

2. **Horizonte temporal:** con sólo tres olas comparables (2021, 2023 y 2024), la capacidad para identificar efectos dinámicos rezagados es limitada. Si los retornos productivos de la IA maduran con rezagos de varios años, el diseño actual podría estar capturando una etapa inicial compatible con costos de transición, pero el número reducido de períodos impide modelar estructuras complejas de rezagos distribuidos.

3. **Precios relativos y shocks sectoriales específicos:** la productividad laboral se mide en términos nominales estandarizados por Eurostat SBS. Si bien los efectos fijos país–año neutralizan la inflación agregada y las perturbaciones macroeconómicas a escala nacional mediante el teorema de Frisch–Waugh–Lovell, no absorben posibles divergencias en precios relativos entre sectores dentro de un mismo país en un período condicionado por perturbaciones en costos de insumos e hidrocarburos. Como fundamenta Berndt (1991), la separación rigurosa de variaciones de precios y cantidades a nivel desagregado requeriría deflactores construidos sobre los mismos microdatos de empresa, una vía que excede el alcance de las series agregadas oficiales disponibles.

4. **Inferencia estadística con panel corto ($T = 3$):** al disponer de sólo tres períodos temporales, la variación intra-unidad proviene de fluctuaciones en el corto plazo. Por ello, las estimaciones sectoriales desagregadas deben concebirse como patrones exploratorios de heterogeneidad y no como parámetros estructurales definitivos de la función de producción de cada rama económica.

# 6. Conclusiones

Este Trabajo Final de Grado se propuso analizar cómo varían la adopción y los usos empresariales de inteligencia artificial entre sectores económicos de la Unión Europea y en

qué medida dichas diferencias se asocian con niveles y variaciones de productividad laboral aparente, mediante la construcción de una base de panel país–sector–año reproducible a partir de datos agregados oficiales de Eurostat para los años 2021, 2023 y 2024.

Los resultados alcanzados permiten extraer tres conclusiones principales:

1. **Divergencia entre corte transversal y dinámica temporal (hallazgo empírico central):** este resultado es consistente con que la fuerte asociación positiva observada en niveles responde preponderantemente a diferencias estructurales permanentes entre sectores y países, y pone de relieve que no se detecta una asociación temporal contemporánea positiva entre aumentos de adopción y productividad laboral aparente en el conjunto de la UE-27 ($r = 0,558$ en niveles transversales frente a $\beta = -0,0013$, $p = 0,154$, en el modelo preferido con efectos fijos M3 sobre la muestra principal no balanceada de $n = 667$ observaciones). Este contraste se corrobora formalmente mediante el rechazo contundente del modelo de Efectos Aleatorios en el test de Hausman ($\chi^2 = 69,10$, $p < 0,001$).
2. **Heterogeneidad estructural sectorial (evidencia exploratoria):** las estimaciones exploratorias muestran heterogeneidad sectorial en las asociaciones temporales observadas. Las actividades con alta complejidad física y de coordinación (manufactura y comercio) exhiben pendientes temporales negativas compatibles con costos de ajuste iniciales u otros shocks sectoriales concurrentes, mientras que en los servicios informáticos se observa una asociación contemporánea cercana a cero.
3. **La necesidad de activos complementarios:** en la ventana temporal analizada, la adopción formal de IA no se asocia de forma automática con mejoras contemporáneas de productividad. Si bien el diseño observacional no mide de manera directa la capacitación ni la reingeniería interna, la literatura económica sugiere como mecanismos teóricos plausibles que la realización de beneficios productivos requiere activos complementarios e inversiones organizacionales que maduran con rezago.

En términos de implicancias de política económica y empresarial, estos hallazgos sugieren que las estrategias de digitalización no deben concentrarse exclusivamente en incentivar la adopción nominal o la adquisición acelerada de licencias de software, sino en fortalecer los activos complementarios: programas de formación continua en habilidades analíticas, apoyo a la reingeniería de procesos internos y modernización de la gobernanza de datos.

Como agenda futura, una vez que Eurostat consolide nuevas olas comparables de SBS y de la encuesta de TIC empresarial, resultará fundamental extender el horizonte temporal del panel para estimar estructuras de rezagos distribuidos que permitan verificar empíricamente en qué momento y bajo qué condiciones sectoriales comienzan a materializarse retornos positivos de productividad en el tejido productivo europeo. Una extensión

especialmente relevante para el contexto nacional consistiría en adaptar este enfoque al caso argentino, combinando información sectorial o empresarial sobre adopción digital e inteligencia artificial con indicadores de valor agregado, empleo y productividad. Este tipo de ejercicio permitiría evaluar si las restricciones de capacidades complementarias, escala, financiamiento, infraestructura digital y volatilidad macroeconómica modifican la relación entre adopción tecnológica y productividad en economías emergentes como la Argentina.

# 7. Bibliografía


Acemoglu, D. and Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. *American Economic Review*, 108(6):1488–1542.

Aldasoro, I., Gambacorta, L., Pal, R., Revoltella, D., Weiss, C., and Wolski, M. (2026). Ai adoption, productivity and employment: Evidence from european firms. BIS Working Papers 1325, Bank for International Settlements. Consultado el 23 de septiembre de 2026.

Berndt, E. R. (1991). *The Practice of Econometrics: Classic and Contemporary*. Addison-Wesley, Reading, MA.

Bresnahan, T. F., Brynjolfsson, E., and Hitt, L. M. (2002). Information technology, workplace organization, and the demand for skilled labor: Firm-level evidence. *The Quarterly Journal of Economics*, 117(1):339–376.

Brynjolfsson, E., Rock, D., and Syverson, C. (2021). The productivity j-curve: How intangibles complement general purpose technologies. *American Economic Journal: Macroeconomics*, 13(1):333–372.

Czarnitzki, D., Fernández, G. P., and Rammer, C. (2023). Artificial intelligence and firm-level productivity. *Journal of Economic Behavior & Organization*, 211:188–205.

Eurostat (2026a). Artificial intelligence: Additional enterprise indicators. https://ec.europa.eu/eurostat/databrowser/view/isoc_eb_ain2/default/table. Base de datos consultada para indicadores complementarios de inteligencia artificial; consultada el 23 de septiembre de 2026.

Eurostat (2026b). Structural business statistics. https://ec.europa.eu/eurostat/web/structural-business-statistics/database. Fuente de valor agregado y personas ocupadas; consultada el 23 de septiembre de 2026.

Eurostat (2026c). Use of artificial intelligence in enterprises. https://ec.europa.eu/eurostat/databrowser/view/isoc_eb_ai/default/table. Base de datos consultada para indicadores de adopción empresarial de inteligencia artificial; consultada el 23 de septiembre de 2026.

Kádárová, J., Fiľo, M., Sukopová, D., and Dúlová, M. (2026). Artificial intelligence adoption and labour productivity in slovakia and the eu27: Implications for sustainable economic growth. *Sustainability*, 18(4):2135.

Mundlak, Y. (1978). On the pooling of time series and cross section data. *Econometrica*, 46(1):69–85.

Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*. MIT Press, Cambridge, MA, 2 edition.

Yilmaz, E. (2026). Ai adoption velocity, productivity and labour outcomes in europe: A country-sector dataset with the ai attribution wedge, 2021–2025. Consultado el 23 de septiembre de 2026.

# Anexos

## Anexo A: Diccionario de variables y fuentes de información

La Tabla 8 detalla las variables que componen la base de datos analítica, su definición conceptual, el código oficial de flujo en Eurostat y su rol en la estrategia empírica.

Tabla 8: Diccionario de variables de la base analítica

| Variable | Definición | Tipo / Unidad | Fuente Eurostat | Nota metodológica |
|---|---|---|---|---|
| country_code | Código geográfico oficial | Texto | Eurostat | 27 Estados miembros de la UE (Grecia utiliza EL). |
| sector_code | Sección de actividad NACE Rev. 2 | Texto | Eurostat | 9 sectores seleccionados: C, F, G, H, I, J, L, M y N. |
| year | Año de referencia | Entero | Eurostat | Olas comparables del panel: 2021, 2023 y 2024. |
| ai_any_pct | Empresas con al menos una tecnología de IA | % de empresas | isoc_eb_ain2: E_AI_TANY | Variable explicativa principal (adopción general). |
| ai_ge2_pct | Empresas con dos o más tecnologías de IA | % de empresas | isoc_eb_ain2: E_AI_TGE2 | Medida de amplitud o intensidad tecnológica media. |
| ai_ge3_pct | Empresas con tres o más tecnologías de IA | % de empresas | isoc_eb_ain2: E_AI_TGE3 | Medida de intensidad tecnológica alta. |
| ai_workflow_pct | IA en organización de procesos y decisiones | % de empresas | isoc_eb_ain2: E_AI_TPA | Uso funcional de gestión interna y flujos de trabajo. |
| ai_production_pct | IA aplicada a procesos productivos | % de empresas | isoc_eb_ain2: E_AI_PPP | Uso funcional en control y ejecución de producción. |
| ai_logistics_pct | IA aplicada a logística y suministros | % de empresas | isoc_eb_ain2: E_AI_PLOG | Uso funcional en transporte interno y cadena de valor. |
| ai_marketing_pct | IA aplicada a marketing y ventas | % de empresas | isoc_eb_ain2: E_AI_PMS | Uso comercial y perfilado de clientes. |
| ai_security_pct | IA aplicada a seguridad de TIC | % de empresas | isoc_eb_ain2: E_AI_PITS | Uso de soporte preventivo en ciberseguridad. |
| value_added_meur_ge10 | Valor agregado a costo de factores | Millones de EUR | SBS: sbs_sc_ovw (AV_MEUR) | Agregado para empresas de 10 o más personas ocupadas. |
| persons_employed_ge10 | Personas ocupadas totales | Personas | SBS: sbs_sc_ovw (EMP_NR) | Agregado para empresas de 10 o más personas ocupadas. |
| labour_productivity_keur | Productividad laboral aparente | Miles EUR / pers. | Construcción propia | (Valor agregado × 1000) / Personas ocupadas. |
| core_complete | Completitud de variables centrales | Indicador binario | Filtro analítico | Exige información conjunta de IA general y productividad. |
| balanced_entity | Entidad balanceada en los 3 años | Indicador binario | Filtro analítico | 209 entidades observadas en las tres olas temporales del panel (2021, 2023 y 2024). |

Fuente: elaboración propia sobre la base de metadatos de Eurostat (isoc_eb_ai, isoc_eb_ain2 y sbs_sc_ovw).

## Anexo B: Comparación completa de especificaciones econométricas (M1, M2 y M3)

La Tabla 9 compara los resultados de estimar las tres especificaciones alternativas de datos de panel sobre la muestra principal no balanceada ($n = 667$ observaciones y 233 entidades):

- **Modelo M1:** mínimos cuadrados ordinarios agrupados con efectos fijos aditivos de país, sector y año. Compara niveles controlando por heterogeneidad observable media.
- **Modelo M2:** estimador intra-entidad con efectos fijos de país–sector ($\alpha_{cs}$) y efectos fijos temporales comunes de año ($\gamma_t$).
- **Modelo M3 (preferido):** estimador intra-entidad con efectos fijos de país–sector ($\alpha_{cs}$) y efectos fijos país–año ($\gamma_{ct}$), absorbiendo shocks macroeconómicos, inflación y perturbaciones específicas de cada país en cada año.

Tabla 9: Comparación de modelos M1, M2 y M3 para todos los indicadores de IA

| Modelo | Indicador de IA | $\beta$ 1 pp | EE agrup. | $t$ | $p$-valor | Efecto 10 pp | $R^2$ |
|---|---|---|---|---|---|---|---|
| **Panel A: Modelo M1 (Efectos fijos de País + Sector + Año)** | | | | | | | |
| M1 | Adopción general | 0,0032 | 0,0019 | 1,69 | 0,091 | +3,2 % | 0,853 |
| M1 | Dos o más tecnologías | 0,0004 | 0,0020 | 0,19 | 0,851 | +0,4 % | 0,850 |
| M1 | Tres o más tecnologías | -0,0016 | 0,0029 | -0,56 | 0,579 | -1,6 % | 0,851 |
| M1 | Procesos y decisiones | 0,0107 | 0,0046 | 2,35 | 0,019 | +11,3 % | 0,855 |
| M1 | Producción | 0,0037 | 0,0049 | 0,75 | 0,452 | +3,7 % | 0,846 |
| M1 | Logística | 0,0403 | 0,0177 | 2,28 | 0,023 | +49,7 % | 0,849 |
| M1 | Marketing y ventas | -0,0012 | 0,0036 | -0,34 | 0,732 | -1,2 % | 0,851 |
| M1 | Seguridad informática | 0,0070 | 0,0055 | 1,29 | 0,198 | +7,3 % | 0,849 |
| **Panel B: Modelo M2 (Efectos fijos de Entidad País–Sector + Año)** | | | | | | | |
| M2 | Adopción general | -0,0020 | 0,0010 | -1,97 | 0,050 | -1,9 % | 0,985 |
| M2 | Dos o más tecnologías | -0,0025 | 0,0011 | -2,31 | 0,021 | -2,5 % | 0,985 |
| M2 | Tres o más tecnologías | -0,0039 | 0,0015 | -2,50 | 0,013 | -3,8 % | 0,985 |
| M2 | Procesos y decisiones | 0,0002 | 0,0018 | 0,10 | 0,921 | +0,2 % | 0,985 |
| M2 | Producción | -0,0044 | 0,0020 | -2,14 | 0,033 | -4,3 % | 0,985 |
| M2 | Logística | 0,0039 | 0,0085 | 0,46 | 0,643 | +4,0 % | 0,985 |
| M2 | Marketing y ventas | -0,0047 | 0,0019 | -2,54 | 0,011 | -4,6 % | 0,986 |
| M2 | Seguridad informática | -0,0024 | 0,0024 | -1,00 | 0,317 | -2,4 % | 0,985 |
| **Panel C: Modelo M3 (Efectos fijos de Entidad País–Sector + País–Año)** | | | | | | | |
| M3 | Adopción general | -0,0013 | 0,0009 | -1,43 | 0,154 | -1,3 % | 0,990 |
| M3 | Dos o más tecnologías | -0,0017 | 0,0010 | -1,74 | 0,083 | -1,6 % | 0,990 |
| M3 | Tres o más tecnologías | -0,0020 | 0,0013 | -1,56 | 0,120 | -2,0 % | 0,990 |
| M3 | Procesos y decisiones | -0,0007 | 0,0016 | -0,44 | 0,660 | -0,7 % | 0,990 |
| M3 | Producción | -0,0014 | 0,0016 | -0,87 | 0,385 | -1,4 % | 0,990 |
| M3 | Logística | -0,0011 | 0,0077 | -0,14 | 0,888 | -1,1 % | 0,990 |
| M3 | Marketing y ventas | -0,0038 | 0,0020 | -1,93 | 0,054 | -3,8 % | 0,990 |
| M3 | Seguridad informática | -0,0019 | 0,0023 | -0,82 | 0,412 | -1,8 % | 0,990 |

Nota: variable dependiente: logaritmo de productividad laboral aparente. Muestra principal no balanceada ($n = 667$, 233 entidades). Errores estándar agrupados por entidad país–sector. Estimado con `linearmodels.iv.AbsorbingLS`.

Esta tabla pone de manifiesto el hallazgo econométrico metodológico central: en el Modelo M1, los procesos y la logística exhiben coeficientes positivos y estadísticamente significativos al 5 %, mientras que la adopción general lo hace únicamente al 10 % ($p = 0,091$). No obstante, tan pronto como se incorporan los efectos fijos de entidad ($\alpha_{cs}$) en M2 y M3 para eliminar la heterogeneidad no observable permanente, dichos coeficientes se disipan y se vuelven no significativos. Este patrón indica que la correlación inicial es consistente con la presencia de factores estructurales preexistentes entre países y sectores, más que con una asociación temporal robusta dentro de cada unidad.

## Anexo C: Cobertura geográfica (Estados miembros de la UE-27)

La Tabla 10 detalla los 27 Estados miembros de la Unión Europea que integran el panel empírico analizado.

Tabla 10: Estados miembros de la Unión Europea incluidos en el análisis

| **Código Eurostat** | **País** | **Código Eurostat** | **País** |
|---|---|---|---|
| AT | Austria | IE | Irlanda |
| BE | Bélgica | IT | Italia |
| BG | Bulgaria | LT | Lituania |
| CY | Chipre | LU | Luxemburgo |
| CZ | Chequia | LV | Letonia |
| DE | Alemania | MT | Malta |
| DK | Dinamarca | NL | Países Bajos |
| EE | Estonia | PL | Polonia |
| EL | Grecia | PT | Portugal |
| ES | España | RO | Rumania |
| FI | Finlandia | SE | Suecia |
| FR | Francia | SI | Eslovenia |
| HR | Croacia | SK | Eslovaquia |
| HU | Hungría | | |

Nota: los códigos corresponden a la nomenclatura oficial de Eurostat (basada en ISO 3166-1 alfa-2, excepto para Grecia, que utiliza el identificador oficial comunitario `EL` en lugar de `GR`).

## Anexo D: Protocolo de reproducibilidad y código abierto

Con el propósito de asegurar la plena transparencia científica y reproducibilidad de los resultados, la totalidad de los datos procesados, scripts de estimación y rutinas de validación econométrica se encuentran disponibles en el repositorio público de GitHub:

https://github.com/Facundo-Diaz-Larrarte/TFG_Facundo_Diaz_Larrarte

El entorno analítico se ejecuta bajo Python 3.12 o superior utilizando las bibliotecas científicas estándar `pandas` (v2.3), `numpy` (v2.5), `scipy` (v1.18), `statsmodels` (v0.15) y `linearmodels` (v7.0).

El pipeline completo de reproducción se ejecuta desde la raíz del proyecto mediante el comando maestro:

```
python analysis/00_reproducir_todo.py
```

Este script ejecuta de manera secuencial:

1. `01_descriptivo.py`: genera las estadísticas descriptivas, tablas de cambios 2021–2024, matrices de correlación y las figuras de adopción y dispersión.
2. `02_modelos_panel.py`: realiza las estimaciones de panel por mínimos cuadrados agrupados con errores robustos.
3. `03_validacion_linearmodels.py`: replica y valida el modelo preferido M3 utilizando el algoritmo `AbsorbingLS`, verificando la coincidencia de los coeficientes a nivel de precisión de máquina.
4. `04_robustez_panel.py`: estima los cuatro escenarios de sensibilidad de muestra, ponderaciones por empleo y filtros de valores extremos.

## Anexo E: Estimación de Efectos Aleatorios y Contraste de Hausman

La Tabla 11 presenta las estimaciones del modelo de Efectos Aleatorios (*Random Effects* - RE) con errores estándar agrupados por entidad país–sector y el contraste formal de especificación de Hausman basado en la regresión auxiliar de Mundlak (1978) y Wooldridge (2010). En todos los indicadores de IA analizados, la hipótesis nula de exogeneidad de los efectos individuales ($\mathrm{Cov}(\alpha_i, IA_{it}) = 0$) se rechaza contundentemente al 1 % de significatividad ($p < 0,001$). Este resultado confirma empíricamente que la heterogeneidad no observada de cada sector está correlacionada con la propensión a adoptar IA, invalidando la consistencia de los efectos aleatorios y justificando de manera concluyente la adopción del estimador de Efectos Fijos (*within*) como especificación principal de este trabajo.

Tabla 11: Modelos de Efectos Aleatorios y contraste de Hausman por indicador de IA

| **Indicador** | $\beta_{RE}$ | **EE** | $p_{RE}$ | **Hausman** $\chi^2$ | $p$**-valor** | **Obs.** |
|---|---|---|---|---|---|---|
| Adopción general | 0,0111 | 0,0009 | <0,001 | 69,10 | <0,001 | 667 |
| Dos o más tecnologías | 0,0121 | 0,0011 | <0,001 | 56,86 | <0,001 | 662 |
| Tres o más tecnologías | 0,0152 | 0,0017 | <0,001 | 48,97 | <0,001 | 653 |
| Procesos y decisiones | 0,0194 | 0,0024 | <0,001 | 44,31 | <0,001 | 662 |
| Producción | 0,0190 | 0,0029 | <0,001 | 76,28 | <0,001 | 631 |
| Logística | 0,0375 | 0,0084 | <0,001 | 35,92 | <0,001 | 627 |
| Marketing y ventas | 0,0153 | 0,0016 | <0,001 | 43,73 | <0,001 | 640 |
| Seguridad informática | 0,0237 | 0,0033 | <0,001 | 20,44 | <0,001 | 626 |

Nota: variable dependiente: logaritmo de productividad laboral aparente. Modelo estimado por Mínimos Cuadrados Generalizados (GLS) con efectos aleatorios y errores estándar agrupados por entidad país–sector. El contraste de Hausman se evaluó mediante el estadístico de Wald sobre los promedios temporales de entidad $\bar{X}_i$ siguiendo la formulación robusta de Mundlak (1978) y Wooldridge (2010), distribuido asintóticamente como $\chi^2(1)$. Como control de robustez, la especificación con controles temporales arroja un rechazo aún más concluyente ($\chi^2 = 108,98$, $p < 0,001$ para adopción general). En todos los casos se rechaza la consistencia de RE a favor del estimador de Efectos Fijos.