

Universidad Nacional de Río Cuarto
Facultad de Ciencias Económicas

*Usos empresariales de inteligencia artificial y productividad
laboral: evidencia país–sector para la Unión Europea*

Alumno:	Facundo Díaz Larrarte
DNI:	43.475.555
Registro Universitario:	[completar]
Email:	fdiazlarrarte@mail.com
Director:	Miguel Bosch
Codirectora:	Ana Vianco
Fecha de presentación:	[completar]

Trabajo Final de Grado
Licenciatura en Economía

Ciudad de Río Cuarto, Argentina

Índice

Resumen	5
1. Introducción	6
1.1. Planteo del problema	6
1.2. Delimitación del tema y del área de estudio	6
1.3. Objetivo general	7
1.4. Objetivos específicos	7
1.5. Hipótesis de trabajo	7
1.6. Importancia del estudio	8
1.7. Limitaciones del estudio	8
2. Marco teórico y antecedentes	8
2.1. Adopción tecnológica, enfoque de tareas y complementariedades	8
2.2. Tecnologías de propósito general y la curva J de productividad	10
2.3. Evidencia empírica sobre IA y productividad en Europa	11
2.4. De la adopción extensiva a la integración agéntica: evidencia de frontera (2024–2026)	12
2.5. Desafíos econométricos e interpretación en datos de panel	13
2.6. Aporte específico de este trabajo	14
3. Datos y metodología	14
3.1. Fuentes de información	14
3.2. Sectores considerados	15
3.3. Variables	15
3.4. Estrategia descriptiva	16
3.5. Estrategia econométrica	16
3.6. Heterogeneidad sectorial	16
3.7. Robustez	17
4. Resultados	17
4.1. Evolución agregada	17
4.2. Heterogeneidad sectorial descriptiva	18
4.3. Correlaciones en niveles y cambios	20
4.4. Modelo de panel	21
4.5. Heterogeneidad sectorial en el modelo de panel	22
4.6. Robustez de la especificación principal	24
5. Discusión	25
5.1. El desacople entre niveles transversales y variaciones temporales	25

5.2. Mecanismos económicos de la heterogeneidad sectorial	25
5.3. La brecha de realización productiva y las fricciones de optimización	26
5.3.1. De la adopción de herramientas genéricas a la resolución de cuellos de botella específicos	27
5.4. Límites metodológicos y cautela interpretativa	28
6. Conclusiones	28
7. Bibliografía	30
Anexos	32

Índice de tablas

1.	Sectores incluidos en el análisis	15
2.	Evolución de productividad e indicadores seleccionados de IA	17
3.	Adopción general de IA y productividad media por sector	18
4.	Correlaciones entre IA y productividad	20
5.	Modelo M3: efectos fijos país-sector y país-año	22
6.	Pendientes sectoriales del modelo de panel con efectos fijos (M3)	23
7.	Robustez del modelo M3 para adopción general de IA	24
8.	Diccionario de variables de la base analítica	33
9.	Comparación de modelos M1, M2 y M3 para todos los indicadores de IA .	34
10.	Estados miembros de la Unión Europea incluidos en el análisis	35

Índice de figuras

1.	Adopción y usos de IA por año	18
2.	Adopción general de IA por sector	19
3.	Relación transversal entre adopción de IA y productividad laboral por país y sector (2024)	20
4.	Matriz de correlaciones entre productividad e indicadores de IA	21

Resumen

El presente Trabajo Final de Grado analiza la relación entre los usos empresariales de inteligencia artificial y la productividad laboral aparente en sectores económicos de la Unión Europea. A partir de información secundaria de Eurostat, se construye una base país–sector–año que combina indicadores de adopción y usos de inteligencia artificial con datos de valor agregado y personas ocupadas provenientes de estadísticas estructurales empresariales. El objetivo es estudiar la heterogeneidad sectorial de la adopción tecnológica y estimar su asociación con la productividad, distinguiendo entre correlaciones en niveles y variaciones dentro de cada unidad país–sector.

El enfoque es cuantitativo, longitudinal, observacional y no experimental. La estrategia empírica propuesta utiliza modelos de datos de panel con efectos fijos, manteniendo una interpretación asociativa y evitando inferencias causales no respaldadas por el diseño. Los resultados muestran una asociación positiva entre adopción de inteligencia artificial y productividad en niveles, pero esa relación se debilita al controlar por diferencias permanentes entre unidades país–sector y shocks país–año. Esta diferencia sugiere la necesidad de distinguir entre adopción tecnológica y realización productiva, así como de considerar la heterogeneidad sectorial, los activos complementarios y las limitaciones de medición.

Palabras clave: inteligencia artificial; productividad laboral; adopción tecnológica; datos de panel; Unión Europea.

1. Introducción

1.1. Planteo del problema

La difusión reciente de tecnologías de inteligencia artificial (IA) ha reactivado el debate sobre su capacidad para modificar procesos productivos, reducir costos, mejorar la calidad de las decisiones empresariales y elevar la productividad. Sin embargo, la adopción de una tecnología y la obtención de resultados económicos observables son fenómenos diferentes. Una empresa puede declarar el uso de IA sin que ello implique necesariamente una transformación profunda de sus procesos, una mejora inmediata de eficiencia o un aumento medible de la productividad.

Desde la perspectiva económica, la incorporación de IA puede entenderse como una decisión de adopción tecnológica cuyo impacto depende de las tareas afectadas, la organización interna, las capacidades del personal, la infraestructura digital, la calidad de los datos, los costos de implementación y el horizonte temporal de maduración. La literatura sobre tecnologías de propósito general y curva J de productividad sostiene que los beneficios de ciertas innovaciones pueden observarse con demora, luego de inversiones complementarias y reorganización empresarial ([Brynjolfsson et al., 2021](#)).

La pregunta principal de este trabajo es: *¿cómo varían la adopción y los usos empresariales de inteligencia artificial entre los sectores económicos de la Unión Europea, y en qué medida esas diferencias se asocian con distintos niveles y variaciones de productividad laboral?*

Esta pregunta no busca demostrar que la IA cause por sí sola aumentos de productividad. El propósito es más acotado: reconstruir evidencia empírica comparable, estudiar patrones de adopción y usos funcionales, y evaluar si la asociación positiva que puede observarse entre unidades estructuralmente distintas se mantiene al analizar variaciones dentro de cada país-sector.

1.2. Delimitación del tema y del área de estudio

El trabajo se inscribe en la microeconomía aplicada, la economía de la empresa y la economía del cambio tecnológico. El análisis utiliza información secundaria de Eurostat para los 27 países de la Unión Europea, nueve sectores de actividad definidos según NACE Rev. 2 y los años 2021, 2023 y 2024.

La unidad de observación es la combinación país-sector-año. La adopción de IA se mide mediante el porcentaje de empresas de diez o más personas ocupadas que declara utilizar al menos una tecnología de IA. Además, se consideran indicadores de intensidad y usos funcionales, tales como IA en organización de procesos o toma de decisiones, producción,

logística, marketing y ventas, y seguridad informática.

La productividad laboral aparente se calcula como el cociente entre valor agregado y personas ocupadas:

$$Productividad_{cst} = \frac{Valor\ agregado_{cst}}{Personas\ ocupadas_{cst}}, \quad (1)$$

donde c identifica al país, s al sector y t al año. Este indicador no mide productividad total de los factores ni permite aislar por sí solo la contribución causal de la IA.

1.3. Objetivo general

Analizar cómo varían la adopción y los usos empresariales de inteligencia artificial entre sectores de la Unión Europea y estimar su asociación con la productividad laboral aparente, utilizando la adopción general como referencia y considerando la heterogeneidad productiva sectorial.

1.4. Objetivos específicos

- Integrar en una base país–sector–año indicadores de IA, valor agregado y personas ocupadas de Eurostat.
- Describir la evolución y heterogeneidad de la adopción de IA por país, sector y año.
- Calcular y comparar la productividad laboral aparente entre las unidades analizadas.
- Estimar una asociación de referencia entre adopción general de IA y productividad mediante modelos de datos de panel.
- Comparar la adopción general con usos empresariales específicos de IA.
- Examinar si la relación entre IA y productividad presenta heterogeneidad sectorial.
- Evaluar la sensibilidad de los resultados frente a especificaciones alternativas, ponderaciones, valores extremos y tratamiento de precios.
- Explicitar las limitaciones de medición e interpretación del diseño empírico.

1.5. Hipótesis de trabajo

La hipótesis de referencia sostiene que una mayor adopción empresarial de IA se asocia con una mayor productividad laboral aparente. La primera hipótesis central plantea que dicha asociación no es uniforme entre funciones empresariales: los usos vinculados con procesos internos, decisiones, producción y logística podrían relacionarse más estrechamente con productividad que la adopción general o que usos de apoyo y comercialización. La

segunda hipótesis central sostiene que la asociación entre IA y productividad es heterogénea entre sectores debido a diferencias en tareas, tecnologías productivas y capacidades complementarias.

Estas hipótesis son asociativas. No se formulan como afirmaciones causales ni como resultados garantizados.

1.6. Importancia del estudio

El aporte del trabajo reside en construir una base reproducible con fuentes oficiales, distinguir entre adopción general y usos específicos de IA, comparar correlaciones en niveles con variaciones dentro de cada unidad país-sector y discutir la heterogeneidad sectorial de la relación IA-productividad. En una tesina de grado, la contribución esperada no consiste en resolver de manera definitiva la identificación causal, sino en presentar un análisis empírico transparente, metodológicamente defendible y prudente en su interpretación.

1.7. Limitaciones del estudio

El diseño permite estudiar asociaciones, pero no identifica de manera concluyente el efecto causal de la IA. Entre las principales limitaciones se encuentran el reducido número de años comparables, el nivel agregado país-sector, la posible causalidad inversa, la omisión de capacidades organizacionales no observadas y la medición de productividad mediante valor agregado monetario corriente.

Los datos no permiten determinar si una empresa concreta eligió la herramienta adecuada, si implementó bien la IA, cuánto gastó, cuánto ahorró o cuál fue su retorno económico. Por lo tanto, una combinación de elevada adopción y débil crecimiento de productividad puede sugerir una brecha de realización productiva compatible con distintos mecanismos, pero no demuestra por sí sola un uso incorrecto de la tecnología.

2. Marco teórico y antecedentes

2.1. Adopción tecnológica, enfoque de tareas y complementariedades

La incorporación de inteligencia artificial en el ámbito empresarial se inscribe dentro de los procesos de adopción y difusión tecnológica analizados tradicionalmente por la teoría económica. Desde la perspectiva de la empresa, la decisión de adoptar una nueva tecnología responde a un cálculo de optimización intertemporal bajo incertidumbre, en el cual se comparan los costos esperados de adquisición, instalación, aprendizaje y reorganización

con los flujos de beneficios derivados de mejoras en eficiencia, reducción de costos operativos, mayor velocidad de procesamiento de información o generación de nuevos productos y servicios.

Sin embargo, las tecnologías digitales complejas no operan en el vacío ni sustituyen automáticamente sectores o actividades en su totalidad. En consonancia con la literatura contemporánea de economía laboral y del cambio tecnológico, la producción puede descomponerse analíticamente en una secuencia de tareas cognitivas y manuales, rutinarias y no rutinarias. Las herramientas de IA interactúan directamente con tareas específicas: algunas son susceptibles de automatización directa (cuando los algoritmos reemplazan la intervención humana en procesos estandarizados), mientras que en otras la tecnología actúa como un factor de asistencia o aumento de las capacidades de los trabajadores, incrementando la calidad de las decisiones o la velocidad de ejecución.

Esta especificidad de las tareas fundamenta la necesidad de examinar la heterogeneidad funcional de la adopción de IA. No es esperable que cualquier uso empresarial de IA genere el mismo tipo de impacto sobre el valor agregado por trabajador. En particular, conviene distinguir analíticamente entre:

1. **Usos de gestión y toma de decisiones:** herramientas aplicadas a la organización de procesos internos, planificación operativa, análisis predictivo de demanda y soporte analítico a la dirección estratégica.
2. **Usos en producción directa y logística:** algoritmos orientados al control de calidad en tiempo real, mantenimiento predictivo de maquinaria, optimización de flujos de cadena de suministro y gestión automatizada de inventarios.
3. **Usos periféricos o de comercialización:** aplicaciones orientadas a marketing, perfilado y segmentación de clientes, publicidad dirigida o soporte inicial de seguridad informática.

Desde el punto de vista de la teoría de la producción, los usos integrados en el núcleo operativo de las empresas (procesos, decisiones, producción física y logística) presentan un vínculo teórico más directo con la reducción sustantiva de tiempos muertos, desperdicios y costos de coordinación, lo que debería traducirse con mayor probabilidad en incrementos mensurables de productividad laboral. Por el contrario, los usos periféricos o auxiliares pueden responder a exigencias competitivas de diferenciación comercial o cumplimiento de estándares básicos de TIC sin transformar necesariamente la eficiencia estructural de los procesos centrales.

2.2. Tecnologías de propósito general y la curva J de productividad

Diversos autores conceptualizan a la inteligencia artificial como una tecnología de propósito general (*General Purpose Technology* o GPT), caracterizada por su omnipresencia potencial en múltiples sectores de la economía, su dinamismo innovativo intrínseco y su capacidad para desencadenar innovaciones complementarias en las organizaciones usuarias.

Una característica fundamental de las tecnologías de propósito general es la desconexión temporal entre su difusión inicial y su impacto agregado en las estadísticas económicas. En su formulación teórica sobre la paradoja de la productividad de las nuevas tecnologías, [Brynjolfsson et al. \(2021\)](#) desarrollan el marco de la **curva J de productividad**. Este modelo postula que la adopción efectiva de una GPT requiere acumular cuantiosas inversiones en activos complementarios intangibles, entre los que se destacan:

- el rediseño profundo de los flujos de trabajo organizacionales;
- el desarrollo de nuevas habilidades y capacitación del capital humano;
- la acumulación, saneamiento e interoperabilidad de grandes volúmenes de datos;
- el cambio cultural y la adaptación de las prácticas de gestión empresarial.

Durante las fases iniciales de difusión de una tecnología como la IA, una proporción considerable del tiempo de trabajo y de los recursos de las empresas se desvía hacia la creación y ajuste de este capital intangible. Dado que las convenciones de contabilidad nacional registran con frecuencia estos esfuerzos como gastos corrientes de operación y no como acumulación formal de activos, la productividad aparente medida puede estancarse o incluso caer transitoriamente, dibujando la parte descendente de la “J”. Solo cuando el stock de intangibles complementarios alcanza un umbral crítico de maduración y se articula eficazmente con los procesos productivos, la empresa comienza a cosechar los retornos tangibles, permitiendo que la productividad medida crezca con celeridad.

Este marco teórico reviste una importancia metodológica central para este trabajo: advierte que la ausencia de una asociación temporal positiva y contemporánea entre aumentos de adopción de IA y crecimiento de la productividad aparente en el corto plazo no constituye evidencia de ineficacia tecnológica, sino que resulta enteramente compatible con la presencia de costos de ajuste e inversiones complementarias no observadas en plena fase de gestación.

2.3. Evidencia empírica sobre IA y productividad en Europa

La literatura empírica sobre la relación entre IA y productividad ha proliferado en los últimos años, dividiéndose entre estudios a nivel de empresa (*firm-level*) y análisis agregados a escala sectorial o macroeconómica.

En el plano microeconómico, [Czarnitzki et al. \(2023\)](#) examinan una muestra representativa de empresas en Alemania y constatan que aquellas firmas que incorporan soluciones de IA exhiben niveles sistemáticamente más elevados de productividad laboral frente a empresas similares no adoptantes. Sin embargo, los autores enfatizan que esta prima de productividad no es automática: está fuertemente condicionada por la intensidad en tecnologías de información preexistentes y por la disponibilidad de trabajadores altamente calificados capaces de interactuar con dichas tecnologías. Por su parte, el trabajo de [Al-dasoro et al. \(2026\)](#), elaborado para el Banco de Pagos Internacionales (BIS) a partir de una amplia encuesta de empresas europeas, halla una heterogeneidad sustancial en las respuestas productivas de las firmas. Concluyen que los efectos positivos en valor agregado se concentran en aquellas organizaciones que acompañan la adopción tecnológica con transformaciones profundas en sus prácticas de gobernanza y gestión corporativa.

A nivel agregado y sectorial, los estudios empíricos para la Unión Europea son más recientes y se sustentan en los datos armonizados de Eurostat. [Kádárová et al. \(2026\)](#) analizan la adopción de IA en comparación entre Eslovaquia y el promedio de la UE-27, destacando la marcada disparidad estructural entre países miembros y la correlación positiva existente entre indicadores agregados de digitalización y niveles de productividad laboral. Asimismo, [Yilmaz \(2026\)](#) construye una base país-sector para el período 2021–2025 y formula el concepto de la brecha de atribución de la IA (*AI attribution wedge*), evidenciando que la rápida aceleración en las tasas de adopción reportadas por las empresas no encuentra un correlato inmediato en la dinámica de crecimiento de la productividad sectorial.

La coexistencia de resultados positivos en estudios microeconómicos y resultados moderados o nulos en agregaciones sectoriales obedece a un fenómeno clásico de selección y agregación: las encuestas microeconómicas capturan el desempeño de firmas pioneras o más productivas en la frontera (*frontier firms*), mientras que los datos sectoriales consolidan el desempeño conjunto de líderes y rezagadas, amortiguando cualquier impacto agregado si la tecnología aún no alcanza una difusión profunda en la mediana de las unidades productivas.

2.4. De la adopción extensiva a la integración agéntica: evidencia de frontera (2024–2026)

Una limitación estructural de las encuestas estadísticas oficiales, como las operaciones sobre uso de TIC de Eurostat, radica en que capturan fundamentalmente el **margen extensivo** de la adopción tecnológica: una variable binaria que indica si la empresa declara utilizar al menos una tecnología de IA en sus actividades. Sin embargo, los relevamientos empíricos corporativos más recientes de la frontera tecnológica (2024–2026) evidencian que el acceso formal a herramientas algorítmicas no es un predictor suficiente de transformación económica ni de ganancias de productividad. La literatura industrial emergente demuestra que la materialización del valor agregado depende críticamente de la profundidad de integración y de la transición desde modelos consultivos hacia arquitecturas de ejecución agéntica.

En su informe corporativo de telemetría empresarial, [OpenAI \(2026a\)](#) documentan una marcada divergencia entre empresas que adoptan IA de forma periférica y aquellas que profundizan su integración en procesos operativos (*frontier firms*, definidas como el decil superior de intensidad de uso). Para mediados de 2026, las firmas de frontera generaban 8,3 veces más tokens de salida por usuario activo que las firmas promedio (frente a una brecha de 2,6 veces a comienzos de año), polarización que se explica por la integración de los modelos con herramientas corporativas, datos contextuales propios y flujos de trabajo repetibles. Asimismo, el uso agéntico y de ejecución autónoma de tareas complejas —medido a través de sistemas como Codex— alcanzó a representar el 64 % de los tokens de salida empresariales combinados, evidenciando un desplazamiento desde la interacción conversacional básica hacia la delegación y ejecución automatizada de tareas.

En una dirección convergente, el *Economic Index* de [Anthropic \(2026\)](#) detecta una mutación metodológica en los patrones de uso empresarial: las interacciones tradicionales de diálogo usuario–asistente han comenzado a ceder terreno frente a flujos de trabajo agénticos prolongados y autónomos (tales como Claude Code o herramientas colaborativas de desarrollo), lo que obligó a reconstruir los índices económicos para capturar la cadencia de tareas computacionales complejas y no meras consultas textuales aisladas. Complementariamente, [OpenAI \(2026b\)](#) estudian la recomposición laboral microeconómica denominada cruce de tareas (*task crossing*), documentando cómo los trabajadores emplean herramientas de IA para asumir responsabilidades y funciones operativas que históricamente correspondían a ocupaciones especializadas distintas, alterando la asignación del tiempo de trabajo y la estructura de tareas postulada en el marco teórico de [Acemoglu and Restrepo \(2018\)](#).

Esta evidencia reciente aporta una clarificación conceptual decisiva para interpretar los resultados de este trabajo, estableciendo una cadena de transmisión que delimita el alcance

de las métricas disponibles:

Adopción nominal (Eurostat) $\longrightarrow$ Intensidad y contexto $\longrightarrow$ Integración en procesos
 $\longrightarrow$ Ejecución agéntica $\longrightarrow$ Realización productiva.

Mientras que las estadísticas de Eurostat analizadas en este panel capturan prioritariamente el primer eslabón (la adopción declarada o nominal durante el trienio 2021–2024), la realización efectiva de productividad demanda el tránsito por los eslabones intermedios de integración y reingeniería organizacional. Esta divergencia conceptual ofrece un sustento adicional para comprender por qué un indicador agregado como `ai_any_pct` no exhibe una correlación contemporánea inmediata con el valor agregado por trabajador en una ventana de observación corta.

2.5. Desafíos econométricos e interpretación en datos de panel

El estudio de la relación entre adopción tecnológica y productividad enfrenta serios desafíos de identificación que condicionan la estrategia empírica:

1. **Causalidad inversa y endogeneidad por selección:** las empresas y sectores que presentan mayores niveles de productividad, mayor rentabilidad y mayores recursos de capital poseen simultáneamente mayores facilidades para afrontar los costos fijos y el riesgo que implica experimentar con tecnologías emergentes de IA. Por ende, una asociación positiva observada en un corte transversal no demuestra que la IA cause productividad, sino que puede reflejar que las unidades más productivas eligen adoptar más tecnología.
2. **Heterogeneidad estructural no observada:** las diferencias institucionales, los regímenes regulatorios, las dotaciones iniciales de capital físico e intangibles y la composición del capital humano varían fuertemente entre países y sectores de actividad en la Unión Europea.
3. **Shocks nominales y macroeconómicos:** el período reciente (2021–2024) estuvo signado por perturbaciones exógenas severas en Europa, incluyendo disrupciones en cadenas de suministro globales, presiones inflacionarias y la crisis energética derivada de la guerra en Ucrania, fenómenos que afectaron de modo heterogéneo a los deflatores y al valor agregado nominal entre sectores y países.

Para mitigar estos problemas, la literatura econométrica estándar de datos de panel ([Wooldridge, 2010](#)) recomienda recurrir al estimador dentro de entidad (*within estimator*). La inclusión de efectos fijos de entidad país–sector (α_{cs}) permite eliminar por completo cualquier factor no observable invariable en el tiempo que diferencie estructuralmente a una combinación país–sector de otra. Complementariamente, la incorporación de efectos fijos

país-año (γ_{ct}) absorbe todos los shocks macroeconómicos y variaciones de precios comunes a todos los sectores de un determinado país en un año específico. De esta manera, el parámetro de interés estima la asociación entre cambios temporales en la tasa de adopción de IA y cambios contemporáneos en el logaritmo de la productividad laboral dentro de cada unidad país-sector, netos de los efectos fijos especificados.

2.6. Aporte específico de este trabajo

En el marco de la literatura expuesta, la presente tesina de grado se define como una **replicación y extensión metodológica** acotada y transparente. El trabajo no pretende implementar una estrategia de identificación cuasi-experimental exhaustiva que resuelva definitivamente la endogeneidad, sino aportar rigor analítico y claridad empírica a través de cuatro elementos distintivos:

- Reconstrucción abierta y plenamente reproducible de una base de panel país-sector-año para la UE-27 a partir de estadísticas oficiales armonizadas de Eurostat (SBS y TIC).
- Desagregación funcional de los indicadores de IA, evaluando de forma independiente la adopción general frente a usos concretos en procesos internos, decisiones, producción, logística, comercialización y seguridad.
- Contraste metodológico sistemático entre la correlación transversal en niveles y la estimación de efectos temporales con controles estrictos por heterogeneidad fija y shocks anuales.
- Análisis explícito de la heterogeneidad sectorial mediante interacciones econométricas y pruebas de robustez predefinidas.

La discusión de los resultados se estructura alrededor del concepto de **brecha de realización productiva**: la constatación descriptiva de una disonancia entre la velocidad de adopción tecnológica y el ritmo de generación de valor agregado medido. Esta brecha se interpreta como un patrón compatible con costos de ajuste, maduración de intangibles y complementariedades pendientes, manteniendo una estricta cautela interpretativa y evitando extrapolar juicios normativos sobre la eficiencia de empresas individuales a partir de información agregada sectorial.

3. Datos y metodología

3.1. Fuentes de información

El trabajo utiliza datos secundarios de Eurostat. Las fuentes principales son la base `isoc_eb_ai`, referida al uso de inteligencia artificial en empresas ([Eurostat, 2026c](#)); la

base `isoc_eb_ain2`, con indicadores complementarios sobre usos y características de la adopción (Eurostat, 2026a); y las estadísticas estructurales empresariales de Eurostat, utilizadas para obtener valor agregado y personas ocupadas (Eurostat, 2026b).

La cobertura principal comprende 27 países de la Unión Europea, nueve sectores NACE Rev. 2 y tres años: 2021, 2023 y 2024. La base analítica contiene 729 combinaciones teóricas de país, sector y año. De ellas, 667 cuentan con información central completa. La muestra balanceada contiene 209 unidades país-sector observadas en los tres años, equivalentes a 627 observaciones.

3.2. Sectores considerados

Tabla 1: Sectores incluidos en el análisis

Código	Sector
C	Industria manufacturera
F	Construcción
G	Comercio mayorista y minorista
H	Transporte y almacenamiento
I	Alojamiento y servicios de comida
J	Información y comunicación
L	Actividades inmobiliarias
M	Actividades profesionales, científicas y técnicas
N	Actividades administrativas y servicios auxiliares

3.3. Variables

La variable dependiente es el logaritmo de la productividad laboral aparente, expresada inicialmente en miles de euros por persona ocupada. La transformación logarítmica reduce la influencia de valores extremos y permite interpretar aproximadamente los coeficientes como variaciones porcentuales.

Las variables explicativas de IA se expresan como porcentaje de empresas. La adopción general se mide con `ai_any_pct`. Como indicadores adicionales se consideran medidas de intensidad (dos o más y tres o más tecnologías) y usos funcionales en procesos, producción, logística, marketing y ventas, y seguridad informática. Cada indicador se analiza inicialmente en modelos separados para evitar combinar variables superpuestas o altamente correlacionadas sin justificación previa.

3.4. Estrategia descriptiva

La primera etapa del análisis describe la evolución de la adopción de IA y de la productividad laboral aparente por año y sector. También compara correlaciones en niveles con correlaciones de cambios entre 2021 y 2024. Esta distinción es central porque una asociación transversal positiva puede estar impulsada por diferencias estructurales persistentes entre países y sectores, mientras que las variaciones internas capturan otra dimensión del fenómeno.

3.5. Estrategia econométrica

La especificación principal propuesta es:

$$\ln(Productividad_{cst}) = \beta IA_{cst} + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}, \quad (2)$$

donde c representa el país, s el sector y t el año. El término α_{cs} corresponde a efectos fijos de la unidad país-sector, que absorben diferencias permanentes de cada combinación. El término γ_{ct} representa efectos fijos país-año, que capturan shocks comunes a todos los sectores de un país en un año determinado. Los errores estándar se agrupan por entidad país-sector. En virtud del teorema de Frisch-Waugh-Lovell (Wooldridge, 2010), esta estructura de efectos fijos absorbe las variaciones nominales comunes a todos los sectores dentro de un mismo país-año. Por lo tanto, el parámetro $\hat{\beta}$ se identifica a partir de diferencias sectoriales dentro de cada país-año y de cambios dentro de cada entidad país-sector, aunque la especificación no corrige variaciones de precios relativos entre sectores ni shocks sectoriales específicos.

También se estiman especificaciones comparativas con efectos fijos de país, sector y año, y con efectos fijos de país-sector y año. La estimación e interpretación de modelos de panel se apoya en criterios habituales de econometría aplicada (Wooldridge, 2010).

3.6. Heterogeneidad sectorial

La heterogeneidad sectorial se analiza descriptivamente y, como extensión econométrica, mediante interacciones entre el indicador de IA y sectores:

$$\ln(Productividad_{cst}) = \beta IA_{cst} + \sum_{s \neq s_0} \delta_s (IA_{cst} \times Sector_s) + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}. \quad (3)$$

El sector s_0 funciona como categoría de referencia. La pendiente estimada para cada sector se obtiene como $\beta + \delta_s$. Dado que sólo se dispone de tres olas comparables, estos resultados deben interpretarse como evidencia exploratoria de heterogeneidad asociativa.

3.7. Robustez

Las pruebas de robustez incluyen comparar muestra balanceada y no balanceada, ponderar por personas ocupadas, examinar sensibilidad a valores extremos, utilizar efectos fijos alternativos, evaluar el tratamiento de precios o deflatores, estimar indicadores de IA por separado y validar los modelos con bibliotecas econométricas estándar. Estas pruebas se reportan para documentar sensibilidad de signo, magnitud y significatividad, no para elegir la especificación más favorable.

4. Resultados

4.1. Evolución agregada

La exploración inicial indica que la adopción general media de IA en la muestra balanceada aumenta de 9,2 % en 2021 a 17,2 % en 2024. En el mismo período, la productividad laboral aparente nominal media pasa de 61,8 a 72,8 miles de euros corrientes por persona ocupada. La Tabla 2 resume estos indicadores.

Tabla 2: Evolución de productividad e indicadores seleccionados de IA

Año	Obs.	Prod. media	Prod. mediana	IA general	Procesos	Producción	Marketing
2021	209	61,8	44,4	9,2	4,0	2,0	2,6
2023	209	67,9	51,5	10,0	4,0	2,3	2,8
2024	209	72,8	54,3	17,2	6,1	3,9	6,2

Nota: productividad en miles de euros corrientes por persona ocupada. Indicadores de IA en porcentaje de empresas. Muestra balanceada.




Figura 1: Adopción y usos de IA por año

4.2. Heterogeneidad sectorial descriptiva

La adopción de IA presenta diferencias claras entre sectores. Información y comunicación muestra el mayor promedio de adopción general, seguido por actividades profesionales, científicas y técnicas. En el extremo opuesto se ubican alojamiento y servicios de comida, construcción y transporte. La Tabla 3 y la Figura 2 resumen esta heterogeneidad.

Tabla 3: Adopción general de IA y productividad media por sector

Código	Sector	IA general	Prod. media
J	Información y comunicación	33,0	118,6
M	Actividades profesionales, científicas y técnicas	18,7	67,9
L	Actividades inmobiliarias	11,9	119,4
N	Actividades administrativas y servicios auxiliares	10,5	35,8
C	Industria manufacturera	8,9	94,2
G	Comercio mayorista y minorista	8,5	53,0
H	Transporte y almacenamiento	7,6	60,6
F	Construcción	5,0	52,8
I	Alojamiento y servicios de comida	4,7	28,4

Nota: IA general en porcentaje de empresas; productividad en miles de euros corrientes por persona ocupada. Promedios de la muestra balanceada.




Figura 2: Adopción general de IA por sector

La heterogeneidad en niveles también se hace visible al examinar la dispersión entre adopción y productividad para cada país y sector en el corte transversal de 2024 (Figura 3). En este gráfico se aprecia con nitidez la fuerte correlación positiva transversal: las unidades país-sector con mayor productividad laboral aparente (ubicadas en el sector de Información y Comunicación o en países de mayores ingresos) tienden a situarse sistemáticamente hacia la derecha en tasas de adopción, mientras que sectores tradicionales o de servicios personales se concentran en el cuadrante inferior izquierdo.




Figura 3: Relación transversal entre adopción de IA y productividad laboral por país y sector (2024)

4.3. Correlaciones en niveles y cambios

Las correlaciones en niveles entre indicadores de IA y log-productividad son positivas. Sin embargo, las correlaciones entre cambios de IA y cambios de log-productividad entre 2021 y 2024 son más débiles y, en varios casos, negativas. Esta diferencia sugiere que los sectores o países más productivos pueden adoptar más IA en promedio, sin que los aumentos recientes de adopción se traduzcan contemporáneamente en mayor crecimiento de productividad dentro de cada unidad observada.

Tabla 4: Correlaciones entre IA y productividad

Indicador	Obs.	r niveles	p	r cambios	p
Adopción general	627	0,564	<0,001	-0,217	0,002
Dos o más tecnologías	625	0,497	<0,001	-0,220	0,001
Tres o más tecnologías	615	0,463	<0,001	-0,209	0,003
Procesos y decisiones	624	0,533	<0,001	-0,059	0,399
Producción	597	0,504	<0,001	-0,135	0,061
Logística	590	0,418	<0,001	0,027	0,715
Marketing y ventas	603	0,414	<0,001	-0,268	<0,001
Seguridad informática	592	0,438	<0,001	-0,120	0,098

Nota: las correlaciones en niveles usan log-productividad. Las correlaciones de cambios corresponden a variaciones 2021–2024.




Figura 4: Matriz de correlaciones entre productividad e indicadores de IA

4.4. Modelo de panel

La especificación con efectos fijos de país-sector y país-año no arroja, en la estimación validada con `linearmodels`, coeficientes estadísticamente significativos para los indicadores de IA a niveles convencionales. La Tabla 5 reporta el modelo preferido. Para adopción general, el coeficiente estimado por un punto porcentual es aproximadamente -0,0011, con $n = 627$ observaciones y 209 clusters país-sector. Interpretado para un aumento de 10 puntos porcentuales, el efecto estimado equivale aproximadamente a -1,1 %, aunque no es estadísticamente distinguible de cero.

Tabla 5: Modelo M3: efectos fijos país-sector y país-año

Indicador	β 1 pp	EE	p	Efecto 10 pp	Obs.
Adopción general	-0,0011	0,0009	0,250	-1,1	627
Dos o más tecnologías	-0,0015	0,0010	0,120	-1,5	625
Tres o más tecnologías	-0,0019	0,0014	0,172	-1,9	615
Procesos y decisiones	-0,0003	0,0017	0,860	-0,3	624
Producción	-0,0011	0,0018	0,529	-1,1	597
Logística	0,0010	0,0082	0,901	1,0	590
Marketing y ventas	-0,0038	0,0021	0,078	-3,7	603
Seguridad informática	-0,0012	0,0024	0,610	-1,2	592

Nota: variable dependiente: logaritmo de productividad laboral aparente. Errores estándar agrupados por entidad país-sector. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

Este resultado no debe interpretarse como evidencia de que la IA reduzca productividad ni como prueba de que la IA sea ineficaz. Indica que, bajo controles exigentes y con el horizonte temporal disponible, no se observa una asociación temporal positiva robusta. El patrón es compatible con diferencias estructurales, costos de ajuste, maduración lenta, inversiones complementarias, causalidad inversa, shocks sectoriales o limitaciones de medición.

4.5. Heterogeneidad sectorial en el modelo de panel

Para evaluar si la relación temporal entre adopción y productividad difiere según la estructura productiva de cada actividad, se estimó la especificación con interacciones sectoriales definida en la metodología, tomando a la Industria Manufacturera (C) como sector base de referencia:

$$\ln(Productividad_{cst}) = \beta IA_{cst} + \sum_{s \neq C} \delta_s (IA_{cst} \times Sector_s) + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}. \quad (4)$$

La pendiente específica de cada sector s se obtiene calculando la combinación lineal $\beta_s = \beta + \delta_s$, cuyos errores estándar se derivan mediante el método delta agrupado por entidad país-sector. La Tabla 6 presenta las estimaciones de las pendientes sectoriales resultantes.

Tabla 6: Pendientes sectoriales del modelo de panel con efectos fijos (M3)

Código	Sector	β total	EE	t	p	Efecto 10 pp
C	Industria manufacturera (ref.)	-0,0095	0,0027	-3,58	<0,001	-9,1 %
G	Comercio mayorista y minorista	-0,0134	0,0022	-5,98	<0,001	-12,6 %
M	Actividades profesionales y científicas	-0,0028	0,0011	-2,46	0,014	-2,7 %
H	Transporte y almacenamiento	-0,0027	0,0033	-0,81	0,419	-2,7 %
J	Información y comunicación	-0,0009	0,0010	-0,86	0,390	-0,9 %
N	Actividades administrativas y auxiliares	-0,0010	0,0019	-0,51	0,613	-1,0 %
F	Construcción	0,0018	0,0040	0,45	0,652	+1,8 %
L	Actividades inmobiliarias	0,0040	0,0070	0,57	0,572	+4,0 %
I	Alojamiento y servicios de comida	0,0118	0,0046	2,59	0,010	+12,5 %

Nota: variable dependiente: logaritmo de productividad laboral aparente. Estimado con `linearmodels.iv.AbsorbingLS` ($n = 627, 209$ entidades). Errores estándar agrupados por entidad país-sector. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

La estimación con interacciones sugiere heterogeneidad sectorial que quedaba encubierta en el coeficiente agregado del modelo sin interacciones. Dado el panel corto, estos resultados deben leerse como exploratorios:

- En sectores con cadenas logísticas complejas e intensivos en capital físico, como la Industria Manufacturera (C) y el Comercio (G), las pendientes dentro de entidad son negativas y estadísticamente significativas al 1 % ($\beta = -0,0095$ y $\beta = -0,0134$, respectivamente). Este comportamiento es compatible, entre otras interpretaciones, con costos de ajuste y reorganización previstos por el marco de la curva J; sin embargo, el diseño observacional no mide esos costos ni permite separar ese mecanismo de shocks sectoriales concurrentes (como perturbaciones energéticas o cuellos de botella en insumos industriales).
- En el sector de Información y Comunicación (J), donde la penetración de herramientas de software y ciencia de datos es nativa y más extendida, el coeficiente es muy próximo a cero ($\beta = -0,0009$) y estadísticamente no significativo. Este coeficiente próximo a cero indica que, en la ventana temporal analizada, no se observa una asociación contemporánea estadísticamente significativa entre aumentos de adopción y productividad dentro de las unidades país-sector correspondientes a Información

y Comunicación. Una posible interpretación, consistente con su elevada intensidad digital previa, es que los costos de ajuste sean menores, aunque este mecanismo no puede identificarse directamente con los datos disponibles.

- En Actividades Profesionales, Científicas y Técnicas (M), se observa un coeficiente negativo leve pero significativo al 5 % ($\beta = -0,0028$), un patrón compatible, entre otras explicaciones, con tiempos de aprendizaje y adaptación en servicios intensivos en conocimiento.
- En Alojamiento y Servicios de Comida (I), el coeficiente resulta positivo y significativo ($\beta = 0,0118$, $p = 0,010$). Si bien este comportamiento podría estar influido por selección entre empresas adoptantes en un sector con baja adopción basal (4,7 % de empresas en promedio), su interpretación requiere especial cautela por coincidir con la fase de reapertura y normalización post-pandemia del turismo europeo entre 2021 y 2024.
- En Construcción (F), Inmobiliarias (L), Transporte (H) y Servicios Administrativos (N), las pendientes no son estadísticamente distinguibles de cero.

4.6. Robustez de la especificación principal

Como prueba de sensibilidad inicial, se reestimó el modelo M3 para adopción general bajo cuatro decisiones alternativas: muestra balanceada sin ponderar, muestra central completa sin exigir balance, muestra balanceada ponderada por personas ocupadas y muestra balanceada excluyendo extremos p1–p99 de productividad. La Tabla 7 resume los resultados.

Tabla 7: Robustez del modelo M3 para adopción general de IA

Escenario	β 1 pp	EE	p	Efecto 10 pp
Muestra balanceada, sin ponderar	-0,0011	0,0009	0,250	-1,1 %
Muestra central completa, sin ponderar	-0,0013	0,0009	0,154	-1,3 %
Muestra balanceada, ponderada por empleo	-0,0016	0,0008	0,038	-1,6 %
Muestra balanceada, sin extremos p1–p99	-0,0007	0,0009	0,391	-0,7 %

Nota: variable dependiente: logaritmo de productividad laboral aparente. Todos los modelos incluyen efectos fijos país–sector y país–año. Errores estándar agrupados por entidad país–sector. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

El signo del coeficiente de adopción general se mantiene cualitativamente negativo en los cuatro escenarios, resultando estadísticamente significativo al 5 % únicamente bajo la ponderación por empleo. Esta sensibilidad indica que la ausencia de una asociación temporal positiva agregada no depende de la exigencia de balancear el panel ni de la presencia de valores extremos de productividad.

5. Discusión

Los resultados obtenidos en este trabajo ofrecen elementos analíticos de relevancia para la discusión contemporánea sobre la difusión de la inteligencia artificial y su impacto económico, estructurándose en torno a cuatro ejes interpretativos.

5.1. El desacople entre niveles transversales y variaciones temporales

El hallazgo central radica en el marcado contraste entre la dimensión de corte transversal y la dimensión temporal dentro de cada unidad. En niveles, la correlación entre adopción de IA y productividad laboral aparente es sistemáticamente positiva y robusta ($r = 0,564$). No obstante, al explotar la variación temporal dentro de cada país-sector mediante efectos fijos que absorben factores estructurales invariables y perturbaciones macroeconómicas comunes por país y año, la asociación positiva se desvanece por completo.

Este patrón resulta conceptualmente compatible con la hipótesis de la **curva J de productividad** de [Brynjolfsson et al. \(2021\)](#), si bien debe enfatizarse que un diseño observacional con datos agregados no permite medir de forma contable los costos de ajuste ni el capital intangible a nivel de firma. La correlación en niveles captura que las economías y sectores más desarrollados y productivos (con mayor stock de capital humano, mejor infraestructura digital y mayor capacidad financiera) son precisamente los que lideran la adopción de tecnologías complejas. Sin embargo, en una ventana de observación corta (2021–2024), el incremento contemporáneo en el porcentaje de firmas que declaran adoptar IA no se traduce de manera mecánica en un aumento del valor agregado por persona. La literatura sugiere que la fase inicial de adopción exige destinar recursos empresariales a la reorganización de procesos, la redefinición de tareas y la formación de capacidades internas, gastos que la contabilidad nacional registra como costos corrientes y no como inversión en capital intangible, manteniendo transitoriamente deprimida la productividad observada.

5.2. Mecanismos económicos de la heterogeneidad sectorial

El análisis exploratorio de interacciones sectoriales profundiza la interpretación económica al revelar que la respuesta productiva no es homogénea entre actividades, si bien estos parámetros deben interpretarse con cautela debido a la reducida ventana temporal del panel ($T = 3$):

- **Sectores de alta inercia física y coordinación:** en la Industria Manufacturera y el Comercio Mayorista y Minorista, la adopción de IA puede requerir rediseñar cadenas de abastecimiento, integrar sistemas ciberfísicos o sincronizar almacenes au-

tomatizados. En el corto plazo, esos procesos podrían generar costos de aprendizaje y desajustes operativos temporales, lo que ofrece una hipótesis explicativa plausible para las pendientes negativas observadas. Asimismo, estos sectores enfrentaron de forma asimétrica presiones en costos energéticos y interrupciones logísticas durante el período 2022–2023, factores que también pudieron incidir en la dinámica del valor agregado nominal.

- **Sectores intensivos en información:** en Información y Comunicación, una posible explicación del coeficiente próximo a cero es que la infraestructura digital y las capacidades tecnológicas preexistentes reduzcan los costos de ajuste asociados a nuevas herramientas de IA. Esta interpretación es compatible con el patrón estimado, pero no puede distinguirse empíricamente de otros mecanismos con los datos disponibles.
- **Servicios con baja penetración basal:** en Alojamiento y Comida, el coeficiente positivo podría estar asociado tanto a patrones de selección entre adoptantes en un sector con baja penetración basal como a la fuerte recuperación cíclica posterior a la pandemia. Con el diseño observacional disponible no es posible separar ambos mecanismos.

5.3. La brecha de realización productiva y las fricciones de optimización

La evidencia reunida es consistente con la noción de una **brecha de realización productiva**: mientras la adopción declarada de IA aumenta con rapidez en las empresas europeas, no se observa en la ventana temporal analizada una asociación contemporánea positiva robusta con la productividad laboral aparente una vez absorbidas las diferencias estructurales y los shocks anuales.

Desde una perspectiva microeconómica, adoptar una tecnología no equivale a optimizar su uso dentro de la función de producción. Las empresas a menudo enfrentan fricciones sustanciales para reestructurar sus flujos de trabajo tradicionales:

1. **Inercia organizacional y capacitación:** la fuerza laboral requiere tiempo y entrenamiento continuo para incorporar eficazmente herramientas algorítmicas en sus tareas cotidianas. Sin capacitación adecuada, la adopción de software avanzado puede generar duplicación de tareas o resistencia al cambio en lugar de ahorro de tiempo.
2. **Asimetría de información y selección tecnológica:** muchas firmas adquieren licencias comerciales o soluciones estandarizadas por presión competitiva o imitación, sin contar con el diagnóstico técnico interno para acoplar la herramienta a sus cuellos de botella operativos reales.

3. **La necesidad de intermediación y gestión del cambio:** la materialización efectiva de ganancias de productividad demanda frecuentemente servicios especializados de consultoría, rediseño de procesos y gobernanza de datos que ayuden a las empresas a transitar la fase de aprendizaje.

Este resultado dialoga directamente con la evidencia de [Aldasoro et al. \(2026\)](#) y [Yilmaz \(2026\)](#), reforzando la conclusión de que la IA es una tecnología complementaria: su rendimiento depende críticamente de la calidad de gestión y de las inversiones intangibles que la acompañan.

Asimismo, es relevante destacar que la hipótesis de que los usos funcionales orientados al núcleo operativo (procesos y toma de decisiones, producción o logística) exhibirían una asociación más estrecha con la productividad que la adopción general no encuentra respaldo empírico en las estimaciones del modelo principal M3. Ninguno de estos coeficientes funcionales resulta estadísticamente significativo (con p -valores de 0,860 para procesos, 0,529 para producción y 0,901 para logística). Esta ausencia de significatividad contemporánea en las funciones analizadas es compatible con una etapa todavía incipiente de experimentación e integración tecnológica, aunque los datos disponibles no permiten observar directamente la profundidad de implementación ni determinar si las empresas han alcanzado una fase de optimización productiva.

5.3.1. De la adopción de herramientas genéricas a la resolución de cuellos de botella específicos

Una dimensión analítica de relevancia para la teoría de la firma radica en la naturaleza de las soluciones de software adoptadas. Históricamente, la difusión tecnológica en el tejido empresarial se ha canalizado predominantemente a través de modelos estandarizados de software como servicio (*Software as a Service*, SaaS). Si bien estas soluciones comerciales horizontales reducen las barreras de entrada y facilitan un acceso masivo, operan en la práctica como insumos tecnológicos homogéneos que rara vez generan ventajas competitivas sostenibles o resuelven las ineficiencias idiosincrásicas de cada unidad productiva.

La literatura sobre complementariedades organizacionales y tecnologías de propósito general ([Bresnahan et al., 2002](#)) y los desarrollos recientes en la frontera algorítmica destacan que la productividad no emerge del uso pasivo de herramientas genéricas no integradas, sino del rediseño adaptativo de los procesos productivos orientado a cuellos de botella específicos de la función de producción. En manufactura y logística, esto abarca el mantenimiento predictivo, la planificación dinámica de inventarios o la sincronización ciberfísica; en servicios, la automatización analítica de operaciones complejas o la reducción de tiempos en flujos documentales críticos. Cuando la adopción empresarial se limita a contratar licencias de software sin acoplar los modelos a los cuellos de botella reales de la firma,

la literatura económica predice que la tecnología puede incrementar los costos operativos corrientes sin traducirse en mejoras observables del valor agregado por persona. Este mecanismo se propone aquí como una hipótesis interpretativa y agenda de investigación microeconómica futura, dado que los datos de Eurostat registran la incidencia de adopción pero no la profundidad ni la personalización técnica de la implementación en cada empresa.

5.4. Límites metodológicos y cautela interpretativa

Es imperativo subrayar los límites del diseño econométrico implementado:

1. **Nivel de agregación y supuestos normativos:** la unidad de análisis es la entidad país-sector. Por consiguiente, los resultados no permiten diagnosticar si una empresa individual específica obtuvo un retorno de inversión positivo o negativo, ni evaluar la calidad técnica de sus decisiones de implementación. La presencia de costos de ajuste o fricciones organizativas constituye una hipótesis teórica compatible con los datos agregados, no una medición contable directa a nivel firma.
2. **Horizonte temporal:** con sólo tres olas comparables (2021, 2023 y 2024), la capacidad para identificar efectos dinámicos rezagados es limitada. Si los retornos productivos de la IA maduran con rezagos de varios años, el diseño actual podría estar capturando una etapa inicial compatible con costos de transición, pero no permite identificar empíricamente la trayectoria dinámica postulada por la curva J.
3. **Precios relativos y shocks sectoriales específicos:** la productividad laboral se calculó en miles de euros corrientes por persona ocupada. Si bien los efectos fijos país-año neutralizan la inflación agregada y los shocks macroeconómicos a escala nacional, no eliminan posibles variaciones en los precios relativos entre sectores dentro de un mismo país durante un período atravesado por la crisis energética y perturbaciones de costos de insumos industriales.
4. **Inferencia estadística con panel corto ($T = 3$):** al disponer de sólo tres períodos temporales, la variación intra-unidad proviene de fluctuaciones en el corto plazo. Por ello, las estimaciones sectoriales desagregadas deben concebirse como patrones exploratorios de heterogeneidad y no como parámetros estructurales definitivos de la función de producción de cada rama económica.

6. Conclusiones

Este Trabajo Final de Grado se propuso analizar cómo varían la adopción y los usos empresariales de inteligencia artificial entre sectores económicos de la Unión Europea y en qué medida dichas diferencias se asocian con niveles y variaciones de productividad laboral

aparente, mediante la construcción de una base de panel país–sector–año reproducible a partir de datos agregados oficiales de Eurostat para los años 2021, 2023 y 2024.

Los resultados alcanzados permiten extraer tres conclusiones principales:

1. **Divergencia entre corte transversal y dinámica temporal (hallazgo empírico central):** este resultado muestra que la asociación positiva observada en niveles está fuertemente condicionada por diferencias estructurales persistentes entre las unidades país–sector y que, con la variación temporal disponible, no se identifica una asociación contemporánea positiva robusta entre aumentos de adopción y productividad laboral aparente en el conjunto de la UE-27 ($r = 0,564$ en niveles frente a $\beta = -0,0011$ en el modelo con efectos fijos).
2. **Heterogeneidad estructural sectorial (evidencia exploratoria):** las estimaciones exploratorias muestran heterogeneidad sectorial en las asociaciones temporales observadas. Las actividades con alta complejidad física y de coordinación (manufactura y comercio) exhiben pendientes temporales negativas compatibles con costos de ajuste iniciales u otros shocks sectoriales concurrentes, mientras que en los servicios informáticos se observa una asociación contemporánea cercana a cero.
3. **La necesidad de activos complementarios:** la adopción declarada de IA no es condición suficiente para elevar la productividad agregada en el corto plazo. La materialización de mejoras en valor agregado exige tiempo de maduración, capacitación de personal y reorganización profunda de tareas.

En términos de implicancias de política económica y empresarial, estos hallazgos sugieren que las estrategias de digitalización no deben concentrarse exclusivamente en incentivar la adopción nominal o la adquisición acelerada de licencias de software, sino en fortalecer los activos complementarios: programas de formación continua en habilidades analíticas, apoyo a la reingeniería de procesos internos y modernización de la gobernanza de datos.

Como agenda futura, una vez que Eurostat consolide nuevas olas comparables de SBS y de la encuesta de TIC empresarial, resultará fundamental extender el horizonte temporal del panel para estimar estructuras de rezagos distribuidos que permitan verificar empíricamente en qué momento se produce el punto de inflexión ascendente de la curva J de productividad en el tejido productivo europeo.

7. Bibliografía

- Acemoglu, D. and Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. *American Economic Review*, 108(6):1488–1542.
- Aldasoro, I., Gambacorta, L., Pal, R., Revoltella, D., Weiss, C., and Wolski, M. (2026). Ai adoption, productivity and employment: Evidence from european firms. BIS Working Papers 1325, Bank for International Settlements. Consultado el 23 de septiembre de 2026.
- Anthropic (2026). Anthropic economic index: Cadences and the shift toward agentic tasks. Technical report, Anthropic. Consultado el 23 de septiembre de 2026.
- Bresnahan, T. F., Brynjolfsson, E., and Hitt, L. M. (2002). Information technology, workplace organization, and the demand for skilled labor: Firm-level evidence. *The Quarterly Journal of Economics*, 117(1):339–376.
- Brynjolfsson, E., Rock, D., and Syverson, C. (2021). The productivity j-curve: How intangibles complement general purpose technologies. *American Economic Journal: Macroeconomics*, 13(1):333–372.
- Czarnitzki, D., Fernández, G. P., and Rammer, C. (2023). Artificial intelligence and firm-level productivity. *Journal of Economic Behavior & Organization*, 211:188–205.
- Eurostat (2026a). Artificial intelligence: Additional enterprise indicators. https://ec.europa.eu/eurostat/databrowser/view/isoc_eb_ain2/default/table. Base de datos consultada para indicadores complementarios de inteligencia artificial; consultada el 23 de septiembre de 2026.
- Eurostat (2026b). Structural business statistics. <https://ec.europa.eu/eurostat/web/structural-business-statistics/database>. Fuente de valor agregado y personas ocupadas; consultada el 23 de septiembre de 2026.
- Eurostat (2026c). Use of artificial intelligence in enterprises. https://ec.europa.eu/eurostat/databrowser/view/isoc_eb_ai/default/table. Base de datos consultada para indicadores de adopción empresarial de inteligencia artificial; consultada el 23 de septiembre de 2026.
- Kádárová, J., Fiš, M., Sukopová, D., and Dúlová, M. (2026). Artificial intelligence adoption and labour productivity in slovakia and the eu27: Implications for sustainable economic growth. *Sustainability*, 18(4):2135.

- OpenAI (2026a). Enterprise signals: How frontier firms put ai to work. Technical report, OpenAI. Consultado el 23 de septiembre de 2026.
- OpenAI (2026b). Unlocking new ways of working: Task crossing and the recomposition of enterprise labor. Technical report, OpenAI. Consultado el 23 de septiembre de 2026.
- Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*. MIT Press, Cambridge, MA, 2 edition.
- Yilmaz, E. (2026). Ai adoption velocity, productivity and labour outcomes in europe: A country-sector dataset with the ai attribution wedge, 2021–2025. Consultado el 23 de septiembre de 2026.

Anexos

Anexo A: Diccionario de variables y fuentes de información

La Tabla [8](#) detalla las variables que componen la base de datos analítica, su definición conceptual, el código oficial de flujo en Eurostat y su rol en la estrategia empírica.

Tabla 8: Diccionario de variables de la base analítica

Variable	Definición	Tipo / Unidad	Fuente Eurostat	Nota metodológica
country_code	Código geográfico oficial	Texto	Eurostat	27 Estados miembros de la UE (Grecia utiliza EL).
sector_code	Sección de actividad NACE Rev. 2	Texto	Eurostat	9 sectores seleccionados: C, F, G, H, I, J, L, M y N.
year	Año de referencia	Entero	Eurostat	Olas comparables del panel: 2021, 2023 y 2024.
ai_any_pct	Empresas con al menos una tecnología de IA	% de empresas	isoc_eb_ain2: E_AI_TANY	Variable explicativa principal (adopción general).
ai_ge2_pct	Empresas con dos o más tecnologías de IA	% de empresas	isoc_eb_ain2: E_AI_TGE2	Medida de amplitud o intensidad tecnológica media.
ai_ge3_pct	Empresas con tres o más tecnologías de IA	% de empresas	isoc_eb_ain2: E_AI_TGE3	Medida de intensidad tecnológica alta.
ai_workflow_pct	IA en organización de procesos y decisiones	% de empresas	isoc_eb_ain2: E_AI_TPA	Uso funcional de gestión interna y flujos de trabajo.
ai_production_pct	IA aplicada a procesos productivos	% de empresas	isoc_eb_ain2: E_AI_PPP	Uso funcional en control y ejecución de producción.
ai_logistics_pct	IA aplicada a logística y suministros	% de empresas	isoc_eb_ain2: E_AI_PLOG	Uso funcional en transporte interno y cadena de valor.
ai_marketing_pct	IA aplicada a marketing y ventas	% de empresas	isoc_eb_ain2: E_AI_PMS	Uso comercial y perfilado de clientes.
ai_security_pct	IA aplicada a seguridad de TIC	% de empresas	isoc_eb_ain2: E_AI_PITS	Uso de soporte preventivo en ciberseguridad.
value_added_meur	Valor agregado a costo de factores	Millones de EUR	SBS: sbs_sc_ovw (AV_MEUR)	Agregado para empresas de 10 o más personas ocupadas.
persons_employed	Personas ocupadas totales	Personas	SBS: sbs_sc_ovw (EMP_NR)	Agregado para empresas de 10 o más personas ocupadas.
labour_productivity	Productividad laboral aparente	Miles EUR / pers.	Construcción propia	(Valor agregado × 1000) / Personas ocupadas.
core_complete	Complejidad de variables centrales	Indicador binario	Filtro analítico	Exige información conjunta de IA general y productividad.
balanced_entity	Entidad balanceada en los 3 años	Indicador binario	Filtro analítico	209 entidades observadas continuamente en 2021–2024.

Fuente: elaboración propia sobre la base de metadatos de Eurostat (isoc_eb_ai, isoc_eb_ain2 y sbs_sc_ovw).

Anexo B: Comparación completa de especificaciones econométricas (M1, M2 y M3)

La Tabla 9 compara los resultados de estimar las tres especificaciones alternativas de datos de panel sobre la muestra balanceada ($n = 627$ observaciones y 209 entidades):

- **Modelo M1:** mínimos cuadrados ordinarios agrupados con efectos fijos aditivos de país, sector y año. Compara niveles controlando por heterogeneidad observable media.
- **Modelo M2:** estimador intra-entidad con efectos fijos de país-sector (α_{cs}) y efectos fijos temporales comunes de año (γ_t).
- **Modelo M3 (preferido):** estimador intra-entidad con efectos fijos de país-sector (α_{cs}) y efectos fijos país-año (γ_{ct}), absorbiendo shocks macroeconómicos, inflación y perturbaciones específicas de cada país en cada año.

Tabla 9: Comparación de modelos M1, M2 y M3 para todos los indicadores de IA

Modelo	Indicador de IA	β 1 pp	EE agrup.	t	p -valor	Efecto 10 pp	R^2
Panel A: Modelo M1 (Efectos fijos de País + Sector + Año)							
M1	Adopción general	0,0039	0,0020	1,97	0,049	+3,9 %	0,860
M1	Dos o más tecnologías	0,0013	0,0022	0,59	0,553	+1,3 %	0,858
M1	Tres o más tecnologías	-0,0007	0,0033	-0,20	0,839	-0,7 %	0,858
M1	Procesos y decisiones	0,0117	0,0049	2,37	0,018	+12,4 %	0,862
M1	Producción	0,0038	0,0054	0,69	0,488	+3,8 %	0,855
M1	Logística	0,0380	0,0186	2,04	0,042	+46,3 %	0,856
M1	Marketing y ventas	-0,0011	0,0037	-0,30	0,763	-1,1 %	0,856
M1	Seguridad informática	0,0063	0,0060	1,05	0,294	+6,5 %	0,856
Panel B: Modelo M2 (Efectos fijos de Entidad País-Sector + Año)							
M2	Adopción general	-0,0017	0,0010	-1,60	0,109	-1,6 %	0,985
M2	Dos o más tecnologías	-0,0024	0,0011	-2,07	0,039	-2,3 %	0,985
M2	Tres o más tecnologías	-0,0037	0,0017	-2,20	0,029	-3,6 %	0,985
M2	Procesos y decisiones	0,0007	0,0019	0,39	0,698	+0,7 %	0,985
M2	Producción	-0,0042	0,0022	-1,93	0,054	-4,1 %	0,985
M2	Logística	0,0054	0,0087	0,62	0,535	+5,6 %	0,985
M2	Marketing y ventas	-0,0045	0,0019	-2,32	0,021	-4,4 %	0,985
M2	Seguridad informática	-0,0020	0,0025	-0,79	0,430	-2,0 %	0,985
Panel C: Modelo M3 (Efectos fijos de Entidad País-Sector + País-Año)							
M3	Adopción general	-0,0011	0,0009	-1,15	0,250	-1,1 %	0,989
M3	Dos o más tecnologías	-0,0015	0,0010	-1,56	0,120	-1,5 %	0,989
M3	Tres o más tecnologías	-0,0019	0,0014	-1,37	0,172	-1,9 %	0,989
M3	Procesos y decisiones	-0,0003	0,0017	-0,18	0,860	-0,3 %	0,989
M3	Producción	-0,0011	0,0018	-0,63	0,529	-1,1 %	0,989
M3	Logística	0,0010	0,0082	0,12	0,901	+1,0 %	0,989
M3	Marketing y ventas	-0,0038	0,0021	-1,77	0,078	-3,7 %	0,990
M3	Seguridad informática	-0,0012	0,0024	-0,51	0,610	-1,2 %	0,989

Nota: variable dependiente: logaritmo de productividad laboral aparente. Muestra balanceada ($n = 627$, 209 entidades). Errores estándar agrupados por entidad país-sector. Estimado con `linearmodels.iv.AbsorbingLS`.

Esta tabla pone de manifiesto el hallazgo econométrico metodológico central: en el Mo-

delo M1, la adopción general, los procesos y la logística exhiben coeficientes positivos y estadísticamente significativos. No obstante, tan pronto como se incorporan los efectos fijos de entidad (α_{cs}) en M2 y M3 para eliminar la heterogeneidad no observable permanente, dichos coeficientes se disipan y se vuelven no significativos. Este patrón indica que la correlación inicial es consistente con la presencia de factores estructurales preexistentes entre países y sectores, más que con una asociación temporal robusta dentro de cada unidad.

Anexo C: Cobertura geográfica (Estados miembros de la UE-27)

La Tabla 10 detalla los 27 Estados miembros de la Unión Europea que integran el panel empírico analizado.

Tabla 10: Estados miembros de la Unión Europea incluidos en el análisis

Código ISO	País	Código ISO	País
AT	Austria	IE	Irlanda
BE	Bélgica	IT	Italia
BG	Bulgaria	LT	Lituania
CY	Chipre	LU	Luxemburgo
CZ	Chequia	LV	Letonia
DE	Alemania	MT	Malta
DK	Dinamarca	NL	Países Bajos
EE	Estonia	PL	Polonia
EL	Grecia	PT	Portugal
ES	España	RO	Rumania
FI	Finlandia	SE	Suecia
FR	Francia	SI	Eslovenia
HR	Croacia	SK	Eslovaquia
HU	Hungría		

Nota: Grecia utiliza el código oficial de Eurostat EL.

Anexo D: Protocolo de reproducibilidad y código abierto

Con el propósito de asegurar la plena transparencia científica y reproducibilidad de los resultados, la totalidad de los datos procesados, scripts de estimación y rutinas de validación econométrica se encuentran disponibles en el repositorio público de GitHub:

https://github.com/Facundo-Diaz-Larrarte/TFG_Facundo_Diaz_Larrarte

El entorno analítico se ejecuta bajo Python 3.12 utilizando las bibliotecas científicas estándar `pandas` (v2.3), `numpy` (v2.5), `scipy` (v1.18), `statsmodels` (v0.15) y `linearmodels`

(v7.0).

El pipeline completo de reproducción se ejecuta desde la raíz del proyecto mediante el comando maestro:

```
python analysis/00_reproducir_todo.py
```

Este script ejecuta de manera secuencial:

1. `01_descriptivo.py`: genera las estadísticas descriptivas, tablas de cambios 2021–2024, matrices de correlación y las figuras de adopción y dispersión.
2. `02_modelos_panel.py`: realiza las estimaciones de panel por mínimos cuadrados agrupados con errores robustos.
3. `03_validacion_linearmodels.py`: replica y valida el modelo preferido M3 utilizando el algoritmo `AbsorbingLS`, verificando la coincidencia de los coeficientes a nivel de precisión de máquina.
4. `04_robustez_panel.py`: estima los cuatro escenarios de sensibilidad de muestra, ponderaciones por empleo y filtros de valores extremos.