



Universidad Nacional de Río Cuarto

Facultad de Ciencias Económicas

Usos empresariales de inteligencia artificial y productividad laboral: evidencia país–sector para la Unión Europea

Alumno:	Facundo Díaz Larrarte
DNI:	43.475.555
Registro Universitario:	*[completar]*
Email:	fdiazlarrarte@mail.com
Director:	Miguel Bosch
Fecha de presentación:	*[completar]*

Trabajo Final de Grado

Licenciatura en Economía

Ciudad de Río Cuarto, Argentina

Índice

Resumen **5**

1. Introducción **6**
1.1. Planteo del problema 6
1.2. Delimitación del tema y del área de estudio 6
1.3. Objetivo general 7
1.4. Objetivos específicos 7
1.5. Hipótesis de trabajo 8
1.6. Importancia del estudio 8
1.7. Limitaciones del estudio 8

2. Marco teórico y antecedentes **9**
2.1. Adopción tecnológica, enfoque de tareas y heterogeneidad funcional 9
2.2. Tecnologías de propósito general, costos de ajuste y desfases temporales . . 9
2.3. Fundamentos teóricos y medición econométrica de la productividad: el marco de Berndt y Eurostat 10
2.4. Evidencia empírica sobre IA y productividad en Europa 12
2.5. Margen extensivo, intensidad de uso y brecha de realización 12
2.6. Desafíos econométricos en datos de panel: de Efectos Aleatorios a Efectos Fijos 13
2.7. Aporte específico de este trabajo 13

3. Datos y metodología **14**
3.1. Fuentes de información y muestra analítica 14
3.2. Ficha metodológica de la encuesta y representatividad de la muestra 15
3.3. Sectores considerados 17
3.4. Variables 17
3.5. Estrategia descriptiva 18
3.6. Estrategia econométrica: de Pooled OLS y Efectos Aleatorios a Efectos Fijos 18
3.7. Heterogeneidad sectorial 19
3.8. Robustez 19

4. Resultados **20**
4.1. Evolución agregada 20
4.2. Heterogeneidad sectorial descriptiva 21
4.3. Correlaciones en niveles y cambios 23
4.4. Modelo de panel 24
4.5. Heterogeneidad sectorial en el modelo de panel 25

4.6. Robustez de la especificación principal 27
4.7. Validación de especificación: RE y restricciones Wald Mundlak/CRE . . . 28

5. Discusión **28**
5.1. El desacople entre niveles transversales y variaciones temporales 29
5.2. Mecanismos económicos de la heterogeneidad sectorial 29
5.3. La brecha de realización productiva y las fricciones de optimización 30
5.3.1. De la adopción de herramientas genéricas a la resolución de cuellos de botella específicos 31
5.4. Límites metodológicos y cautela interpretativa 32

6. Conclusiones **33**

7. Bibliografía **35**

Anexos **37**

Índice de tablas

1. Sectores incluidos en el análisis 17
2. Evolución de productividad e indicadores seleccionados de IA 20
3. Adopción general de IA y productividad media por sector 21
5. Correlaciones entre IA y productividad 23
6. Modelo M3: efectos fijos país–sector y país–año 25
7. Pendientes sectoriales del modelo de panel con efectos fijos (M3) 26
9. Robustez del modelo M3 para adopción general de IA 27
11. Diccionario de variables de la base analítica 37
12. Comparación de modelos M1, M2 y M3 para todos los indicadores de IA . 39
14. Estados miembros de la Unión Europea incluidos en el análisis 40
15. Modelos RE y restricciones Wald Mundlak/CRE por indicador de IA . . . 41

Índice de figuras

1. Adopción y usos de IA por año 21
2. Adopción general de IA por sector 22
3. Relación transversal entre adopción de IA y log-productividad laboral por país y sector (2024) 23
4. Matriz de correlaciones entre productividad e indicadores de IA 24

Resumen

El presente Trabajo Final de Grado analiza la relación entre los usos empresariales de inteligencia artificial y la productividad laboral aparente en sectores económicos de la Unión Europea. A partir de información secundaria de Eurostat, se construye una base país–sector–año que combina indicadores de adopción y usos de inteligencia artificial con datos de valor agregado y personas ocupadas provenientes de estadísticas estructurales empresariales. El objetivo es estudiar la heterogeneidad sectorial de la adopción tecnológica y estimar su asociación con la productividad, distinguiendo entre correlaciones en niveles y variaciones dentro de cada unidad país–sector.

El enfoque es cuantitativo, longitudinal, observacional y no experimental. La estrategia empírica propuesta utiliza modelos de datos de panel con efectos fijos, manteniendo una interpretación asociativa y evitando inferencias causales no respaldadas por el diseño. Los resultados muestran una asociación positiva entre adopción de inteligencia artificial y productividad en niveles, pero esa relación se debilita al controlar por diferencias permanentes entre unidades país–sector y shocks país–año. Esta diferencia sugiere la necesidad de distinguir entre adopción tecnológica y realización productiva, así como de considerar la heterogeneidad sectorial, los activos complementarios y las limitaciones de medición.

Palabras clave: inteligencia artificial; productividad laboral; adopción tecnológica; datos de panel; Unión Europea.

1. Introducción

1.1. Planteo del problema

La difusión reciente de tecnologías de inteligencia artificial (IA) ha reactivado el debate sobre su capacidad para modificar procesos productivos, reducir costos, mejorar la calidad de las decisiones empresariales y elevar la productividad. Sin embargo, la adopción de una tecnología y la obtención de resultados económicos observables son fenómenos diferentes. Una empresa puede declarar el uso de IA sin que ello implique necesariamente una transformación profunda de sus procesos, una mejora inmediata de eficiencia o un aumento medible de la productividad.

Desde la perspectiva económica, la incorporación de IA puede entenderse como una decisión de adopción tecnológica cuyo impacto depende de las tareas afectadas, la organización interna, las capacidades del personal, la infraestructura digital, la calidad de los datos, los costos de implementación y el horizonte temporal de maduración. La literatura sobre tecnologías de propósito general y difusión tecnológica sostiene que los beneficios de ciertas innovaciones complejas suelen observarse con demora, requiriendo inversiones complementarias, aprendizaje y reorganización de procesos internos antes de materializarse en ganancias observables de productividad (Bresnahan et al., 2002; Brynjolfsson et al., 2021).

La pregunta principal de este trabajo es: *¿cómo varían la adopción y los usos empresariales de inteligencia artificial entre los sectores económicos de la Unión Europea, y en qué medida esas diferencias se asocian con distintos niveles y variaciones de productividad laboral?*

Esta pregunta no busca demostrar que la IA cause por sí sola aumentos de productividad. El propósito es más acotado: reconstruir evidencia empírica comparable, estudiar patrones de adopción y usos funcionales, y evaluar si la asociación positiva que puede observarse entre unidades estructuralmente distintas se mantiene al analizar variaciones dentro de cada país–sector.

1.2. Delimitación del tema y del área de estudio

El trabajo se inscribe en la microeconomía aplicada, la economía de la empresa y la economía del cambio tecnológico. El análisis utiliza información secundaria de Eurostat para los 27 Estados miembros de la Unión Europea (UE-27), nueve sectores de actividad definidos según la Nomenclatura Estadística de Actividades Económicas en la Comunidad Europea (NACE Rev. 2) y los años 2021, 2023 y 2024.

La unidad de observación es la combinación país–sector–año. La adopción de IA se mide

mediante el porcentaje de empresas de diez o más personas ocupadas que declara utilizar al menos una tecnología de IA. Además, se consideran indicadores de intensidad y usos funcionales, tales como IA en organización de procesos o toma de decisiones, producción, logística, marketing y ventas, y seguridad informática.

La productividad laboral aparente nominal se construye como el cociente entre valor agregado y personas ocupadas:

$$\text{Productividad}_{cst} = \frac{\texttt{AV_MEUR}_{cst} \times 1000}{\texttt{EMP_NR}_{cst}}, \tag{1}$$

donde c identifica al país, s al sector y t al año. El resultado se expresa en miles de euros corrientes por persona ocupada. Este indicador construido no mide productividad total de los factores ni permite aislar por sí solo la contribución causal de la IA.

1.3. Objetivo general

Analizar cómo varían la adopción y los usos empresariales de inteligencia artificial entre sectores de la Unión Europea y estimar su asociación con la productividad laboral aparente, utilizando la adopción general como referencia y considerando la heterogeneidad productiva sectorial.

1.4. Objetivos específicos

- Integrar en una base país–sector–año indicadores de IA, valor agregado y personas ocupadas de Eurostat.
- Describir la evolución y heterogeneidad de la adopción de IA por país, sector y año.
- Calcular y comparar la productividad laboral aparente entre las unidades analizadas.
- Estimar una asociación de referencia entre adopción general de IA y productividad mediante modelos de datos de panel.
- Comparar la adopción general con usos empresariales específicos de IA.
- Examinar si la relación entre IA y productividad presenta heterogeneidad sectorial.
- Evaluar la sensibilidad de los resultados frente a especificaciones alternativas, ponderaciones y exclusión de valores extremos.
- Explicitar las limitaciones de medición e interpretación del diseño empírico.

1.5. Hipótesis de trabajo

La hipótesis de referencia sostiene que una mayor adopción empresarial de IA se asocia con una mayor productividad laboral aparente. La primera hipótesis central plantea que dicha asociación no es uniforme entre funciones empresariales: los usos vinculados con procesos internos, decisiones, producción y logística podrían relacionarse más estrechamente con productividad que la adopción general o que usos de apoyo y comercialización. La segunda hipótesis central sostiene que la asociación entre IA y productividad es heterogénea entre sectores debido a diferencias en tareas, tecnologías productivas y capacidades complementarias.

Estas hipótesis son asociativas. No se formulan como afirmaciones causales ni como resultados garantizados.

1.6. Importancia del estudio

El aporte del trabajo reside en construir una base reproducible con fuentes oficiales, distinguir entre adopción general y usos específicos de IA, comparar correlaciones en niveles con variaciones dentro de cada unidad país–sector y discutir la heterogeneidad sectorial de la relación IA–productividad. En una tesina de grado, la contribución esperada no consiste en resolver de manera definitiva la identificación causal, sino en presentar un análisis empírico transparente, metodológicamente defendible y prudente en su interpretación.

1.7. Limitaciones del estudio

El diseño permite estudiar asociaciones, pero no identifica de manera concluyente el efecto causal de la IA. Entre las principales limitaciones se encuentran el reducido número de años comparables, el nivel agregado país–sector, la posible causalidad inversa, la omisión de capacidades organizacionales no observadas y la medición de productividad mediante valor agregado monetario corriente.

Los datos no permiten determinar si una empresa concreta eligió la herramienta adecuada, si implementó bien la IA, cuánto gastó, cuánto ahorró o cuál fue su retorno económico. Por lo tanto, una combinación de elevada adopción y débil crecimiento de productividad puede sugerir una brecha de realización productiva compatible con distintos mecanismos, pero no demuestra por sí sola un uso incorrecto de la tecnología.

2. Marco teórico y antecedentes

2.1. Adopción tecnológica, enfoque de tareas y heterogeneidad funcional

La incorporación de inteligencia artificial en el ámbito empresarial se inscribe dentro de los procesos de adopción tecnológica analizados por la teoría económica. Desde la perspectiva de la firma, la decisión de adoptar una tecnología responde a una optimización intertemporal bajo incertidumbre, donde se contrastan los costos de adquisición, instalación, aprendizaje y reingeniería con los flujos de beneficios esperados derivados de ganancias de eficiencia o reducción de costos operativos.

En consonancia con la literatura contemporánea de economía laboral y del cambio tecnológico, la producción puede descomponerse en una secuencia de tareas cognitivas y manuales, rutinarias y no rutinarias (Acemoglu and Restrepo, 2018). Las herramientas de IA interactúan de forma diferenciada con tareas específicas: algunas son automatizables directamente (sustituyendo la intervención humana en procesos estandarizados), mientras que en otras la tecnología complementa o aumenta las capacidades de los trabajadores, incrementando la calidad o velocidad de ejecución.

Esta especificidad fundamenta la necesidad de examinar la heterogeneidad funcional de la adopción. No es esperable que cualquier uso de IA ejerza el mismo efecto sobre el desempeño productivo. En particular, conviene distinguir entre:

1. **Usos en el núcleo operativo (procesos, decisiones, producción y logística):** herramientas integradas en la optimización de flujos de trabajo, control de calidad y mantenimiento predictivo, que presentan un vínculo directo con la reducción de tiempos muertos y costos de coordinación.
2. **Usos periféricos o de apoyo (marketing, ventas y seguridad):** aplicaciones orientadas a la diferenciación comercial o a estándares básicos de TIC que no transforman necesariamente la eficiencia estructural interna.

2.2. Tecnologías de propósito general, costos de ajuste y desfases temporales

Diversos autores conceptualizan a la inteligencia artificial como una tecnología de propósito general (*General Purpose Technology* o GPT), caracterizada por su potencial difusión multisectorial y su capacidad para inducir innovaciones complementarias.

Una propiedad central de las tecnologías de propósito general es la desconexión temporal entre su difusión inicial y su impacto medible en las estadísticas agregadas de productividad. La literatura sobre adopción tecnológica enfatiza que la incorporación efectiva de

innovaciones complejas no opera de manera instantánea ni automática: requiere cuantiosas inversiones en activos complementarios intangibles, rediseño de procesos organizacionales, capacitación del capital humano, acumulación de datos interoperables y transformaciones sustantivas en las prácticas de gestión empresarial (Bresnahan et al., 2002; Brynjolfsson et al., 2021).

Durante las fases iniciales de difusión, una proporción sustantiva del tiempo y de los recursos empresariales se desvía hacia la reconfiguración organizativa y el aprendizaje técnico. Como advierte la literatura sobre desfases de productividad (Brynjolfsson et al., 2021), dado que las convenciones contables registran habitualmente estos esfuerzos como gastos corrientes de operación y no como acumulación de activos de capital intangible, la productividad aparente observada puede estancarse o declinar transitoriamente durante el período de ajuste. Solo cuando este proceso de aprendizaje madura y se articula plenamente con la operativa diaria pueden materializarse las mejoras de productividad esperadas. Este marco conceptual advierte que la ausencia de una asociación contemporánea positiva de corto plazo entre adopción y productividad no implica ineficacia tecnológica, sino que resulta enteramente compatible con costos de ajuste, reorganización de procesos y desfases temporales en la maduración de las innovaciones.

2.3. Fundamentos teóricos y medición econométrica de la productividad: el marco de Berndt y Eurostat

La delimitación conceptual de la variable dependiente reviste una importancia metodológica capital en este trabajo. Como advierte Berndt (1991, Caps. 2 y 9) en su obra canónica sobre econometría aplicada (*The Practice of Econometrics: Classic and Contemporary*), la medición de la productividad exige distinguir con rigor entre medidas de productividad multifactorial o total de los factores (PTF) y medidas de **productividad parcial de factores** (*partial factor productivity*).

En la teoría de la producción, una función de producción sectorial relaciona el producto con los factores primarios e intermedios: $Y = F(K, L, M, A)$, donde K representa el capital, L el trabajo, M los insumos intermedios y A el estado de la tecnología. La productividad laboral se define como una medida parcial que relaciona el producto con el insumo de trabajo:

$$PMe_L = \frac{VAB}{L}, \tag{2}$$

donde VAB es el Valor Agregado Bruto y L el personal ocupado.

Siguiendo a Berndt (1991, Cap. 2), la elección del Valor Agregado en lugar de la Producción Bruta total (Y) es obligada en el análisis sectorial: el producto bruto comete el error

de la doble contabilización al incorporar insumos intermedios adquiridos a otros sectores. El Valor Agregado ($VAB = Y - M$), en cambio, aísla la riqueza neta generada en el interior de las empresas del sector mediante la combinación de sus factores propios.

Asimismo, Berndt (1991) enfatiza que la productividad laboral es una medida "aparente". Al relacionar todo el valor generado con el insumo de trabajo, el cociente VAB/L no mide exclusivamente la destreza o eficiencia intrínseca de los trabajadores, sino que absorbe de manera preponderante la **intensidad de capital** (*capital deepening*, K/L) y las complementariedades tecnológicas organizacionales. Un sector intensivo en capital o infraestructura digital exhibirá niveles sistemáticamente más elevados de VAB/L con independencia de la productividad marginal pura del trabajo.

Para las olas de este estudio (2021, 2023 y 2024), la tabla SBS `sbs_sc_ovw` proporciona `AV_MEUR` (valor agregado, millones de euros) y `EMP_NR` (personas ocupadas) (Eurostat, 2026d,f). Desde 2021, `AV_MEUR` mide valor agregado nominal a precios básicos; esta definición marca una ruptura frente a la serie SBS previa a 2021, a costo de factores (Eurostat, 2026e,c). En consecuencia, el resultado utilizado en este trabajo es una construcción propia:

$$\text{Productividad}_{cst} = \frac{\texttt{AV_MEUR}_{cst} \times 1000}{\texttt{EMP_NR}_{cst}}, \tag{3}$$

expresada en miles de euros corrientes por persona ocupada. No se importa como un indicador derivado oficial: `V91110` corresponde a tablas SBS históricas, entre ellas `sbs_na_1a_se_r2` para 2005–2020, y no al código de los componentes 2021+ empleados aquí (Eurostat, 2026a).

Un punto metodológico crucial discutido extensamente por Berndt (1991, Caps. 2 y 9) refiere al tratamiento de los precios. El autor advierte sobre los severos sesgos y errores de medición (*measurement errors*) que se inducen al intentar deflactar variables empresariales utilizando índices de precios agregados inadecuados o construidos bajo universos metodológicos divergentes. En particular, la aplicación de deflactores macroeconómicos de Cuentas Nacionales (que cubren toda la economía, incluidas administraciones públicas y microempresas) sobre datos SBS de empresas de 10 o más ocupados generaría un descalce muestral e introduciría perturbaciones espurias.

Por este motivo, este trabajo construye una medida nominal a partir de componentes oficiales de Eurostat. Los efectos fijos país–año (γ_{ct}) eliminan de la variación usada para estimar β los componentes de inflación agregada y shocks macroeconómicos comunes a todos los sectores de cada país–año; no eliminan diferencias de precios relativos ni shocks específicos de cada sector.

2.4. Evidencia empírica sobre IA y productividad en Europa

La literatura empírica sobre IA y productividad se divide entre estudios a nivel de empresa (*firm-level*) y análisis agregados sectoriales. En el plano microeconómico, Czarnitzki et al. (2023) reportan para Alemania asociaciones positivas entre el uso o la intensidad de IA y resultados de producción medidos por ventas y valor agregado, en especificaciones con controles observados. Estos resultados no establecen un efecto causal ni un canal vinculado con las calificaciones laborales; los autores señalan que analizar esos canales requiere datos más detallados sobre la fuerza laboral y el capital humano. Asimismo, Aldasoro et al. (2026) combinan datos empresariales EIBIS–ORBIS (2019–2024) y, en la especificación con controles, estiman mediante una estrategia de emparejamiento e IV basada en firmas estadounidenses comparables un aumento de aproximadamente 4,1 % en el logaritmo de la facturación por empleado (con valor agregado por empleado como comprobación de robustez). Los autores interpretan esta estimación como causal bajo sus supuestos de identificación; es evidencia a nivel de empresa, no una explicación causal del panel sectorial de este trabajo.

A nivel sectorial, Kádárová et al. (2026) presentan una comparación descriptiva entre Eslovaquia y el agregado UE-27 basada en datos de Eurostat de 2021–2024: la adopción eslovaca de IA aumenta, pero permanece por debajo de la media UE-27; la productividad es volátil y no se observa una asociación agregada estable ni inmediata. Por su parte, el dataset de Yilmaz (2026) reúne 733 observaciones país–sector–año para la UE-27, siete sectores y las olas 2021, 2023, 2024 y 2025. Define la brecha de atribución de la IA (*AI Attribution Wedge*, AAW) como un indicador descriptivo de *screening* que combina adopción, productividad posterior y horas trabajadas, y declara expresamente que no es causal. Sin un estudio acompañante independiente verificable, el dataset no permite atribuirle resultados sobre correlatos contemporáneos de productividad ni sobre selección o agregación de firmas de frontera y rezagadas; tales mecanismos serían hipótesis no medidas, no hallazgos de Yilmaz.

2.5. Margen extensivo, intensidad de uso y brecha de realización

Las encuestas estadísticas oficiales capturan predominantemente el **margen extensivo** de la adopción: un indicador binario sobre si la firma utiliza al menos una tecnología de IA. Al respecto, los marcos conceptuales sobre tecnologías de la información (Bresnahan et al., 2002) y automatización basada en tareas (Acemoglu and Restrepo, 2018) sugieren teóricamente que el acceso formal o la mera adopción declarada no garantizan mejoras productivas si no se profundiza el **margen intensivo** (reorganización de flujos de trabajo e integración procedimental en tareas clave).

Esta distinción delimita el alcance de las métricas disponibles y permite formalizar una

cadena de transmisión conceptual:

Adopción nominal (Eurostat) ⟶ Intensidad de uso ⟶ Integración en procesos ⟶ Realización productiva

Las estadísticas de Eurostat capturan el primer eslabón del esquema. La realización efectiva de ganancias de productividad requiere transitar los eslabones intermedios de intensidad y reingeniería organizacional, lo que explica por qué la adopción general no exhibe necesariamente una correlación contemporánea positiva con el valor agregado por trabajador en el corto plazo.

2.6. Desafíos econométricos en datos de panel: de Efectos Aleatorios a Efectos Fijos

La estimación de la relación entre adopción de IA y productividad enfrenta desafíos clásicos de identificación (Wooldridge, 2010; Berndt, 1991):

1. **Endogeneidad por selección y causalidad inversa:** las empresas y sectores estructuralmente más productivos y con mayores recursos financieros enfrentan con mayor facilidad los costos fijos y el riesgo de experimentar con IA. Por ello, una regresión simple de mínimos cuadrados agrupados (*Pooled OLS*) es vulnerable a un sesgo positivo por selección que impide interpretar el coeficiente en niveles como un efecto causal directo.

2. **Restricción de ortogonalidad en Efectos Aleatorios:** el estimador RE descansa en una restricción de ortogonalidad entre la heterogeneidad no observada de cada unidad y los regresores. Esta es una hipótesis del modelo, no una conclusión que pueda establecerse por teoría. La formulación Mundlak/CRE permite examinar una restricción relacionada al introducir las medias temporales de los regresores.

3. **Elección de Efectos Fijos:** los efectos fijos país–sector (α_{cs}) eliminan de la variación usada para estimar β los efectos de unidad invariantes en el tiempo, y los efectos país–año (γ_{ct}), los componentes comunes a todos los sectores de cada país–año. No eliminan precios relativos ni shocks sectoriales dentro de ese país–año. Por ello M3 se adopta como especificación asociativa principal; no identifica causalidad ni resulta impuesta de forma única por un contraste RE/CRE.

2.7. Aporte específico de este trabajo

En el marco de la literatura expuesta, la presente tesina de grado se define como una replicación y extensión metodológica transparente. Su contribución se articula en cuatro

elementos:

- Reconstrucción abierta y reproducible de un panel país–sector–año no balanceado para la UE-27 a partir de fuentes oficiales armonizadas de Eurostat (SBS y TIC): la muestra *core* de productividad nominal y adopción general contiene $N = 667$ observaciones.
- Desagregación funcional de los indicadores de IA, evaluando la adopción general frente a usos en procesos, producción, logística, comercialización y seguridad.
- Contraste econométrico: comparación sistemática entre corte transversal en niveles (Pooled OLS), Efectos Aleatorios (RE) con restricciones Wald Mundlak/CRE y modelos de Efectos Fijos (FE) con controles por heterogeneidad permanente y shocks país–año.
- Análisis explícito de la heterogeneidad sectorial y pruebas de robustez predefinidas (ponderación por empleo y sensibilidad a extremos).

La discusión se estructura alrededor de la **brecha de realización productiva**: un patrón descriptivo compatible con costos de ajuste y maduración de intangibles, manteniendo una estricta cautela interpretativa y evitando inferir causalidad individual a partir de datos agregados sectoriales.

3. Datos y metodología

3.1. Fuentes de información y muestra analítica

El trabajo utiliza datos secundarios oficiales de la oficina estadística de la Unión Europea (Eurostat). Las fuentes principales son la base `isoc_eb_ai`, referida a la adopción empresarial de inteligencia artificial (Eurostat, 2026g); la base `isoc_eb_ain2`, con indicadores complementarios de usos específicos de IA (Eurostat, 2026b); y la tabla de Estadísticas Estructurales Empresariales (*Structural Business Statistics* - SBS) `sbs_sc_ovw`, de la que se obtienen `AV_MEUR` y `EMP_NR` (Eurostat, 2026d).

La grilla teórica de cobertura comprende 27 países de la UE, nueve sectores NACE Rev. 2 y tres olas temporales (2021, 2023 y 2024), totalizando $27 \times 9 \times 3 = 729$ combinaciones país–sector–año. En los registros oficiales de Eurostat, 62 celdas no tienen valores observables: 53 sin datos de SBS y 15 sin datos de encuesta TIC, con 6 omisiones simultáneas. Las fuentes documentan estados de secreto estadístico o no disponibilidad del relevamiento; las causas de cada ausencia no se infieren más allá de esos estados de fuente.

La **muestra analítica central (*core*)** reúne las 667 observaciones no balanceadas de productividad nominal y adopción general de IA completas, estructuradas en 233 unidades

país–sector. No constituye una muestra completa para todos los indicadores secundarios de IA. Para cada indicador secundario, los modelos emplean su muestra de casos completos específica, no balanceada, de $n = 626$–662; la ausencia observable de un indicador se mantiene como tal, sin atribuirle una causa adicional. El escenario balanceado *core* de adopción general contiene 627 observaciones de 209 entidades; para los indicadores secundarios, las muestras balanceadas específicas abarcan $n = 590$–625. Forzar el balanceo del *core* exige descartar 40 observaciones válidas de entidades que no aparecen en las tres olas. Los estimadores de panel operan sobre paneles desbalanceados, por lo que el escenario balanceado se utiliza exclusivamente como control de sensibilidad.

Las marcas de estado de la fuente SBS se preservan como información de calidad y no como un filtro automático. Para `status=b` (ruptura de serie), se agregan las marcas de `AV_MEUR` y `EMP_NR` entre las cuatro clases de tamaño hacia la misma observación país–sector–año. El reporte reproducible registra 258 marcas fuente, todas en 2021, y 35 observaciones *core* afectadas en seis países; la muestra principal conserva esas observaciones. Este tratamiento es coherente con la documentación SBS, que identifica cambios de serie desde 2021, y separa la marca de una prueba de error del dato (Eurostat, 2026e,f).

3.2. Ficha metodológica de la encuesta y representatividad de la muestra

Para comprender la naturaleza de las variables explicativas es fundamental precisar el diseño metodológico de la encuesta europea de uso de TIC en empresas (*Community survey on ICT usage and e-commerce in enterprises*):

- **Unidad de relevamiento:** la unidad estadística es la **empresa** (*enterprise*), no el trabajador individual ni el hogar.
- **Informante clave:** el cuestionario es respondido formalmente a nivel corporativo por el responsable del área de Sistemas/TIC (CIO/CTO) o la dirección general de la firma, capturando adopción institucional en los procesos de negocio y no usos personales esporádicos.
- **Módulo temático y delimitación conceptual de la IA:** si bien el relevamiento marco de Eurostat monitorea anualmente el uso de tecnologías de la información y la comunicación (TIC) en sentido amplio, este trabajo explota exclusivamente el **módulo específico y armonizado de Inteligencia Artificial** introducido en las olas 2021, 2023 y 2024 (series oficiales `isoc_eb_ai` e `isoc_eb_ain2`). Dicho módulo adopta la definición internacional de IA de la OCDE y la Comisión Europea, indagando el uso productivo de tecnologías avanzadas tales como aprendizaje automático (*machine learning*), redes neuronales, procesamiento de lenguaje natural

y minería de texto, visión artificial, reconocimiento de voz y automatización inteligente de flujos de trabajo. Esta delimitación conceptual excluye explícitamente paquetes ofimáticos genéricos, software administrativo tradicional o herramientas de gestión estándar sin algoritmos de inferencia o aprendizaje.

- **Población objetivo y métrica (`PC_ENT`):** cubre a empresas formales con 10 o más personas ocupadas. Los institutos nacionales de estadística aplican un diseño probabilístico estratificado por sector y tramo de tamaño (10–49, 50–249, 250+ empleados), incorporando factores de expansión muestral (*sampling weights*). Por ende, el indicador `ai_any_pct` mide el porcentaje del universo total de empresas de ese sector y país que ha adoptado la tecnología.
- **Tratamiento de la heterogeneidad de escala y dispersión de tamaño:** un desafío metodológico recurrente en paneles internacionales radica en la disparidad de escala física entre economías de gran dimensión (como Alemania, Francia o Italia) y economías de menor escala demográfica o insular (como Malta, Chipre o Luxemburgo). Este desafío se neutraliza formalmente en tres niveles complementarios:

  1. *Normalización matemática por variables intensivas:* el modelo econométrico no compara volúmenes agregados absolutos (como valor agregado bruto total o número absoluto de empresas con IA), sino ratios intensivos normalizados: el valor agregado por persona ocupada (VAB/L) y la tasa porcentual de empresas adoptantes sobre el universo del sector (`PC_ENT`). Al dividir por el empleo y el universo empresarial de cada entidad, se atenúa el efecto mecánico del tamaño bruto del mercado sobre los niveles de las variables, si bien subsisten posibles diferencias estructurales en composición.

  2. *Identificación intra-unidad mediante Efectos Fijos:* el estimador *within* con efectos fijos de entidad (α_{cs}) garantiza que la identificación no compare a Malta contra Alemania en corte transversal, sino a cada sector contra su propia trayectoria temporal. Toda diferencia estructural permanente vinculada al tamaño del mercado interno o la escala geográfica queda absorbida por α_{cs}.

  3. *Inferencia agrupada y prueba WLS:* en el plano inferencial, los errores estándar basales se agrupan por entidad (*cluster-robust*), permitiendo dependencia residual y heterocedasticidad arbitrarias dentro de cada país–sector bajo una aproximación asintótica en el número de entidades; no constituyen una corrección garantizada de esos procesos. Además, en la muestra empírica ninguna celda carece de masa crítica (el sector más pequeño supera los 1.000 empleados y la mediana muestral es de 140.000 ocupados). Complementariamente, como análisis de sensibilidad frente a diferencias de tamaño relativo entre celdas, se reestima la especificación principal mediante Mínimos Cuadrados Ponderados

(*Weighted Least Squares* - WLS) ponderando por personas ocupadas, evaluando si el estimando se modifica al otorgar mayor peso a las observaciones con mayor masa laboral.

3.3. Sectores considerados

El análisis empírico abarca nueve secciones de actividad económica clasificadas según la nomenclatura NACE Rev. 2, presentadas en la Tabla 1. Estas ramas representan el núcleo del sector empresarial no financiero cubierto por las estadísticas estructurales armonizadas de Eurostat.

Tabla 1: Sectores incluidos en el análisis

Código	**Sector**
C	Industria manufacturera
F	Construcción
G	Comercio mayorista y minorista
H	Transporte y almacenamiento
I	Alojamiento y servicios de comida
J	Información y comunicación
L	Actividades inmobiliarias
M	Actividades profesionales, científicas y técnicas
N	Actividades administrativas y servicios auxiliares

3.4. Variables

La variable dependiente es el logaritmo natural de la productividad laboral aparente nominal construida como $\ln(\texttt{AV_MEUR} \times 1000/\texttt{EMP_NR})$, expresada en miles de euros corrientes por persona ocupada. La transformación logarítmica estabiliza la varianza, mitiga la influencia de valores atípicos y permite interpretar los coeficientes aproximadamente como semi-elasticidades porcentuales.

Las variables explicativas de IA se expresan como porcentaje de empresas adoptantes. La adopción general se mide con `ai_any_pct`. Como indicadores complementarios se consideran la intensidad tecnológica (adopción de dos o más y tres o más herramientas) y los usos funcionales en procesos y decisiones, producción, logística, marketing y ventas, y seguridad informática. Cada variable se evalúa en modelos separados para evitar multicolinealidad. La adopción general usa la muestra *core* de $n = 667$; cada indicador complementario usa casos completos para ese indicador ($n = 626$–662 en el panel no balanceado y $n = 590$–625 en el escenario balanceado). Para un indicador dado, M1, M2 y M3 se estiman sobre la

misma muestra de casos completos; el tamaño muestral no varía por la especificación de efectos fijos.

3.5. Estrategia descriptiva

La primera etapa del análisis examina la evolución temporal de la adopción y de la productividad nominal por año y rama de actividad sobre el panel no balanceado. Asimismo, compara las correlaciones en niveles con las correlaciones de variaciones entre 2021 y 2024 para las entidades con información en ambas olas, contrastando la dimensión de corte transversal frente a la dinámica temporal intra-unidad.

3.6. Estrategia econométrica: de Pooled OLS y Efectos Aleatorios a Efectos Fijos

La estrategia econométrica se articula en una secuencia metodológica progresiva:

1. **MCO Agrupado (*Pooled OLS*):** estima la asociación en niveles como punto de referencia transversal:

$$\ln(\text{Productividad}_{cst}) = \beta_0 + \beta_1 \text{IA}_{cst} + \varepsilon_{cst}. \tag{4}$$

2. **Efectos Aleatorios (*Random Effects* - RE):** asume que la heterogeneidad no observada de cada unidad país–sector (α_{cs}) es ortogonal a los regresores, cumpliéndose $\text{Cov}(\alpha_{cs}, \text{IA}_{cst}) = 0$. Se estima mediante Mínimos Cuadrados Generalizados (GLS) con errores agrupados por entidad.

3. **Restricción Wald Mundlak/CRE:** en una regresión RE que incorpora la media temporal de entidad $\bar{\text{IA}}_{cs}$ (`ai_mean`), se contrasta exactamente H_0 : `ai_mean` $= 0$. El resultado sin controles temporales y el resultado con dummies globales de año corresponden a esas dos regresiones, no a M3 con efectos país–año. Bajo los supuestos del modelo, el rechazo aporta evidencia contra la restricción RE/CRE correspondiente; no es una prueba clásica de diferencias FE–RE, ni prueba causalidad o sesgo cuantificado.

4. **Modelos de Efectos Fijos (*Fixed Effects*):** se estiman tres especificaciones dentro de entidad:

$$\text{M1 (País + Sector + Año):} \quad \ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \mu_c + \eta_s + \lambda_t + \varepsilon_{cst}, \tag{5}$$

$$\text{M2 (Entidad + Año):} \quad \ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \alpha_{cs} + \lambda_t + \varepsilon_{cst}, \tag{6}$$

$$\text{M3 (Entidad + País–Año):} \quad \ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}. \tag{7}$$

El modelo M3 constituye la especificación asociativa principal. Los efectos fijos país–sector (α_{cs}) eliminan de la variación utilizada los efectos de unidad invariantes en el tiempo; los efectos país–año (γ_{ct}), los componentes comunes a todos los sectores del país en ese año. No eliminan precios relativos ni shocks sectoriales dentro de un país–año. La identificación condicional de β proviene de la variación residual y no identifica causalidad. La inferencia canónica T60 agrupa por entidad país–sector y aplica la corrección CR1 de rango efectivo $\frac{G}{G-1}\frac{N-1}{N-\text{rank}(X)}$, con referencia t_{G-1}. La agrupación bidimensional entidad–país–año se presenta sólo como sensibilidad con la convención de covarianza propia de `AbsorbingLS`; no es una elevación directa del error estándar canónico ni un estimador preferido.

3.7. Heterogeneidad sectorial

La heterogeneidad sectorial se examina descriptivamente y mediante un modelo con interacciones completas sobre la especificación M3:

$$\ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \sum_{s \neq C} \delta_s (\text{IA}_{cst} \times \text{Sector}_s) + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}, \tag{8}$$

donde la Industria Manufacturera (C) actúa como categoría base y la pendiente sectorial específica se obtiene como $\beta + \delta_s$.

3.8. Robustez

Las pruebas de robustez incluyen: (i) contrastar el *core* no balanceado de adopción general ($n = 667$) con su escenario balanceado ($n = 627$); para los indicadores secundarios, las muestras correspondientes son específicas por indicador ($n = 626$–662 no balanceadas y $n = 590$–625 balanceadas); (ii) ponderar por personas ocupadas (*Weighted Least Squares* - WLS); (iii) excluir valores extremos en los percentiles p1–p99 de productividad; (iv) validar coeficientes con `linearmodels.iv.AbsorbingLS`, cuya convención de covarianza no define los EE ni p canónicos T60; y (v) dos sensibilidades a las marcas SBS: excluir sólo las filas *core* marcadas o todas las olas de las entidades afectadas. Estas dos últimas

son escenarios de sensibilidad; no redefinen la muestra principal ni convierten una marca de ruptura en un error automático.

4. Resultados

4.1. Evolución agregada

La exploración inicial indica que la adopción general media de IA en la muestra principal no balanceada ($n = 667$) aumenta de 9,2 % en 2021 a 17,0 % en 2024. En el mismo período, la productividad laboral aparente nominal media pasa de 62,0 a 72,1 miles de euros corrientes por persona ocupada (y la mediana de 44,2 a 54,3 miles de euros). La Tabla 2 resume estos indicadores.

Tabla 2: Evolución de productividad e indicadores seleccionados de IA

Año	Obs.	Prod. media	Prod. mediana	IA general	Procesos	Producción	Marketing
2021	220	62,0	44,2	9,2	3,9	1,9	2,6
2023	224	67,3	51,8	9,9	3,9	2,3	2,8
2024	223	72,1	54,3	17,0	6,1	3,9	6,2

Nota: productividad en miles de euros corrientes por persona ocupada. Adopción general: muestra *core* no balanceada ($n = 667$, 233 entidades). Los indicadores secundarios se calculan con sus observaciones disponibles por indicador; los modelos listwise correspondientes abarcan $n = 626$–662.

La Figura 1 ilustra la evolución temporal agregada de estos indicadores, evidenciando que el incremento en la adopción general en 2024 estuvo acompañado por una difusión simultánea en usos de gestión, producción y comercialización.

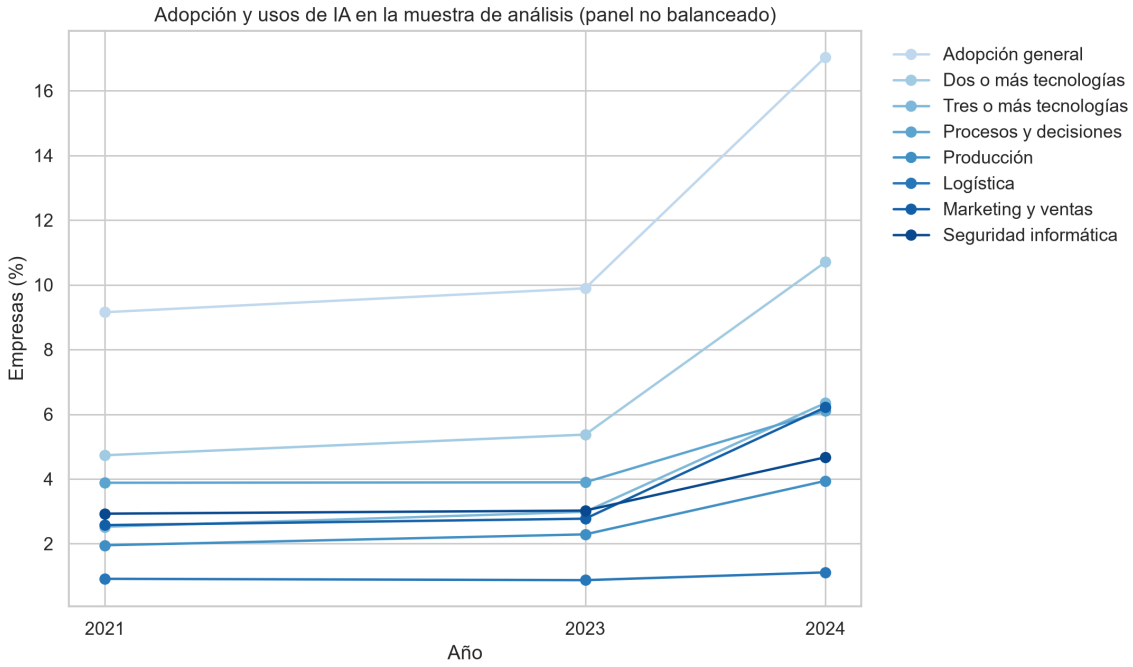


Figura 1: Adopción y usos de IA por año

4.2. Heterogeneidad sectorial descriptiva

La adopción de IA presenta diferencias claras entre sectores. Información y comunicación muestra el mayor promedio de adopción general, seguido por actividades profesionales, científicas y técnicas. En el extremo opuesto se ubican alojamiento y servicios de comida, construcción y transporte. La Tabla 3 y la Figura 2 resumen esta heterogeneidad.

Tabla 3: Adopción general de IA y productividad media por sector

Código	**Sector**	**IA general**	**Prod. media**
J	Información y comunicación	33,6	118,6
M	Actividades profesionales, científicas y técnicas	18,5	67,0
L	Actividades inmobiliarias	11,0	110,6
N	Actividades administrativas y servicios auxiliares	10,3	35,4
C	Industria manufacturera	8,9	94,2
G	Comercio mayorista y minorista	8,5	53,0
H	Transporte y almacenamiento	7,6	61,0
F	Construcción	4,7	52,4
I	Alojamiento y servicios de comida	4,6	28,0

Nota: IA general en porcentaje de empresas; productividad en miles de euros corrientes por persona ocupada. Promedios de la muestra principal no balanceada ($n = 667$, 233 entidades).

La Figura 2 complementa esta comparación ordenando los sectores según su tasa de adopción general de IA, ilustrando gráficamente la brecha entre las actividades intensivas en información y el resto de la estructura productiva.

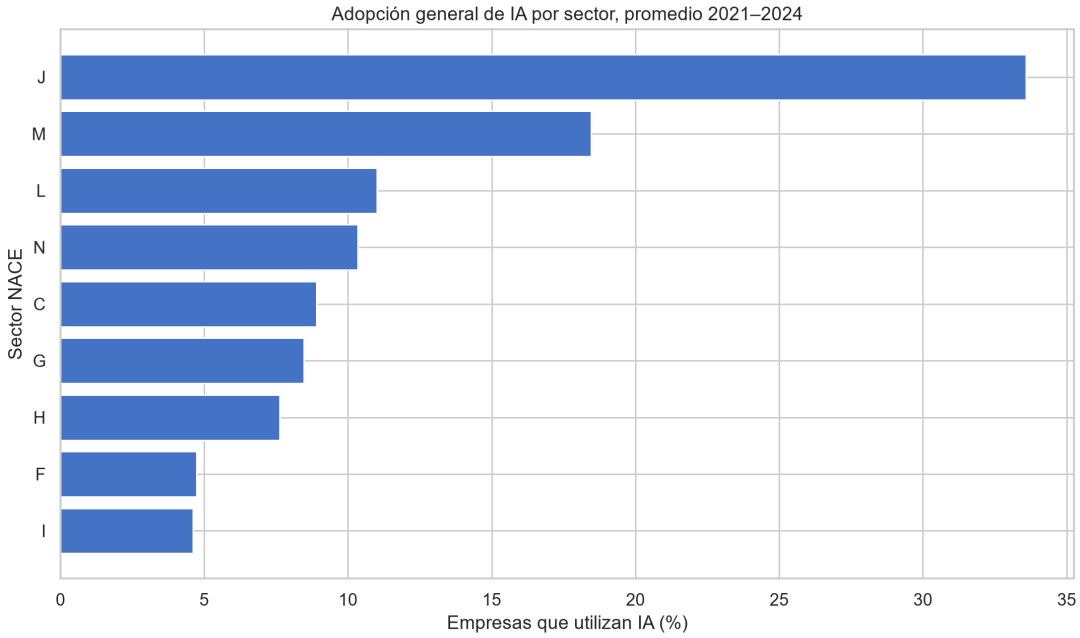


Figura 2: Adopción general de IA por sector

La heterogeneidad en niveles también se hace visible al examinar la dispersión entre adopción y log-productividad para cada país y sector en el corte transversal de 2024 (Figura 3). El uso de log-productividad reduce la influencia visual de valores extremos y mantiene consistencia con las correlaciones y modelos econométricos reportados. En este gráfico se aprecia con nitidez la fuerte correlación positiva transversal: las unidades país–sector con mayor productividad laboral aparente (ubicadas en el sector de Información y Comunicación o en países de mayores ingresos) tienden a situarse sistemáticamente hacia la derecha en tasas de adopción, mientras que sectores tradicionales o de servicios personales se concentran en el cuadrante inferior izquierdo.

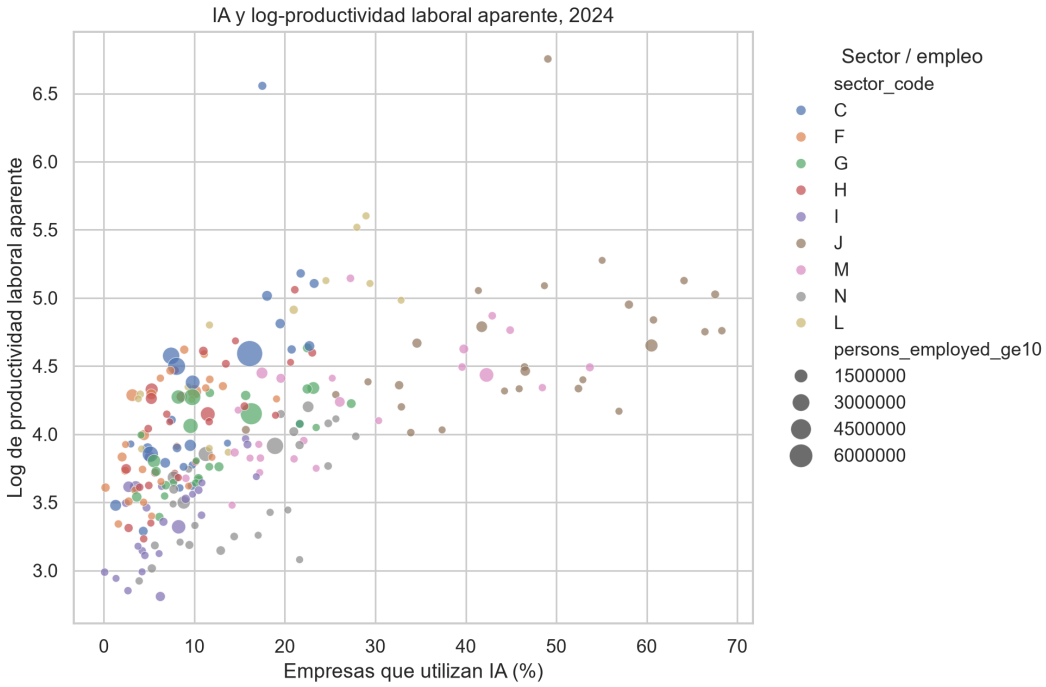


Figura 3: Relación transversal entre adopción de IA y log-productividad laboral por país y sector (2024)

4.3. Correlaciones en niveles y cambios

Las correlaciones en niveles entre indicadores de IA y log-productividad son marcadamente positivas ($r = 0,558$ para adopción general). Sin embargo, las correlaciones entre cambios de IA y cambios de log-productividad entre 2021 y 2024 son débiles o negativas ($r = -0,229$, $p < 0,001$ para adopción general). Esta discrepancia sugiere que los sectores o países más productivos adoptan más IA en promedio, sin que los aumentos recientes de adopción se traduzcan contemporáneamente en mayor crecimiento de productividad dentro de cada unidad observada.

Tabla 5: Correlaciones entre IA y productividad

Indicador	**Obs.**	r **niveles**	p	r **cambios**	p
Adopción general	667	0,558	<0,001	-0,229	<0,001
Dos o más tecnologías	662	0,489	<0,001	-0,226	0,001
Tres o más tecnologías	653	0,457	<0,001	-0,215	0,002
Procesos y decisiones	662	0,522	<0,001	-0,073	0,291
Producción	631	0,499	<0,001	-0,145	0,043
Logística	627	0,416	<0,001	0,015	0,831
Marketing y ventas	640	0,412	<0,001	-0,274	<0,001
Seguridad informática	626	0,439	<0,001	-0,131	0,069

Nota: las correlaciones en niveles usan log-productividad ($n = 626$–667). Las correlaciones de cambios corresponden a variaciones 2021–2024 ($n = 193$–213 entidades).

La estructura de interdependencia lineal entre todas las variables analizadas se resume visualmente en la matriz de correlaciones de la Figura 4, donde se destaca la elevada correlación interna entre los diferentes indicadores de intensidad y funciones de IA.

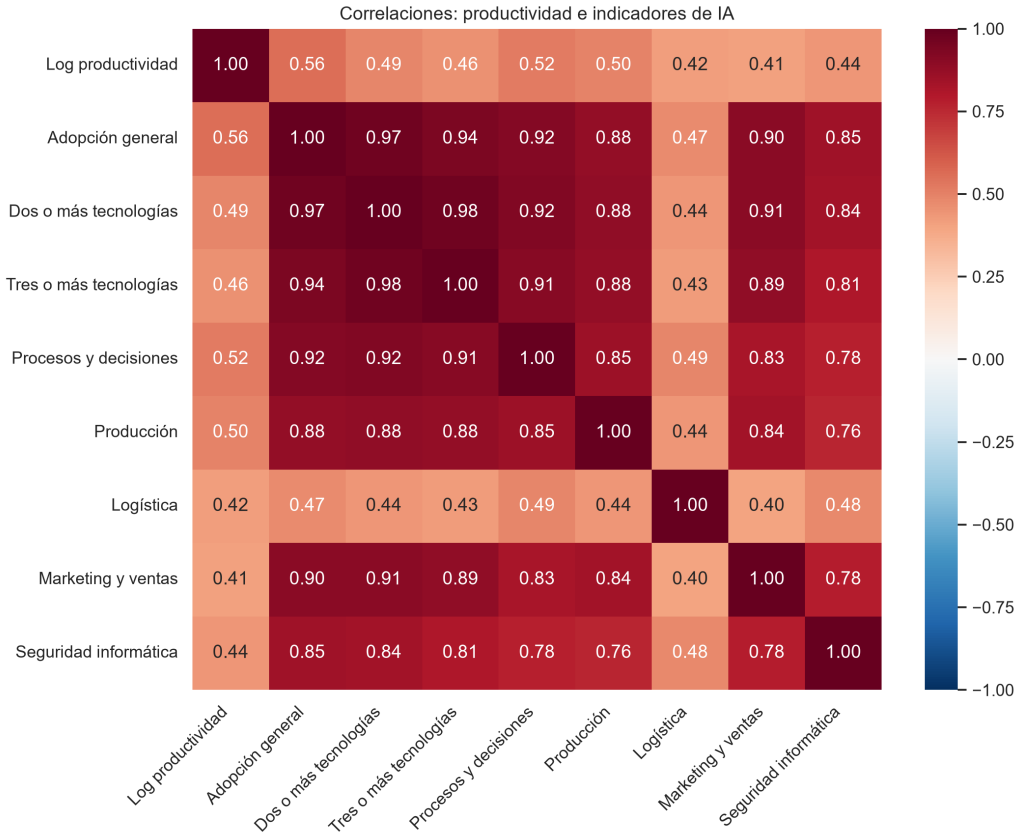


Figura 4: Matriz de correlaciones entre productividad e indicadores de IA

4.4. Modelo de panel

La especificación con efectos fijos de país–sector y país–año (M3) no arroja coeficientes estadísticamente significativos para los indicadores de IA a niveles convencionales. Para adopción general se estima sobre la muestra *core* no balanceada ($n = 667$, $G = 233$ entidades); los indicadores secundarios se estiman en sus muestras de casos completos específicas ($n = 626$–662). La Tabla 6 reporta la inferencia canónica T60. Para adopción general, el coeficiente por un punto porcentual es $\beta = -0,001263116$ ($\text{rank}(X) = 288$, $EE = 0,001171453$, $p = 0,282043$, IC 95 % $[-0,00357116;\ 0,00104493]$), aplicando CR1 de rango efectivo y referencia t_{232}. Para 10 puntos porcentuales, el cambio estimado es $-1,3$ %; el intervalo incluye asociaciones negativas y positivas.

Tabla 6: Modelo M3: efectos fijos país–sector y país–año

Indicador	β **1 pp**	**EE**	p	**Efecto 10 pp**	**Obs.**
Adopción general	-0,0013	0,0012	0,282	-1,3	667
Dos o más tecnologías	-0,0017	0,0013	0,192	-1,6	662
Tres o más tecnologías	-0,0020	0,0017	0,244	-2,0	653
Procesos y decisiones	-0,0007	0,0021	0,740	-0,7	662
Producción	-0,0014	0,0022	0,519	-1,4	631
Logística	-0,0011	0,0104	0,917	-1,1	627
Marketing y ventas	-0,0038	0,0027	0,151	-3,8	640
Seguridad informática	-0,0019	0,0031	0,542	-1,8	626

Nota: variable dependiente: logaritmo de productividad laboral aparente. Adopción general: muestra *core* no balanceada ($n = 667$, $G = 233$ entidades); indicadores secundarios: casos completos específicos ($n = 626$–662). Para cada indicador, M1, M2 y M3 usan la misma muestra de casos completos. EE y p canónicos T60: agrupación por entidad, CR1 $\frac{G}{G-1}\frac{N-1}{N-\mathrm{rank}(X)}$ y referencia t_{G-1}. `AbsorbingLS` valida coeficientes, pero usa una convención de covarianza distinta. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

Este resultado no debe interpretarse como evidencia de que la IA reduzca productividad ni como prueba de que la IA sea ineficaz. Indica que, bajo controles exigentes y con el horizonte temporal disponible, no se observa una asociación temporal positiva robusta. El patrón es compatible con diferencias estructurales, costos de ajuste, maduración lenta, inversiones complementarias, causalidad inversa, shocks sectoriales o limitaciones de medición.

4.5. Heterogeneidad sectorial en el modelo de panel

Para evaluar si la relación temporal entre adopción y productividad difiere según la estructura productiva de cada actividad, se estimó la especificación con interacciones sectoriales definida en la metodología, tomando a la Industria Manufacturera (C) como sector base de referencia:

$$\ln(\text{Productividad}_{cst}) = \beta \text{IA}_{cst} + \sum_{s \neq C} \delta_s (\text{IA}_{cst} \times \text{Sector}_s) + \alpha_{cs} + \gamma_{ct} + \varepsilon_{cst}. \tag{9}$$

La pendiente específica de cada sector s se obtiene calculando la combinación lineal $\beta_s = \beta + \delta_s$. Sus errores estándar usan la matriz de varianzas y covarianzas agrupada por entidad país–sector; los contrastes de cada pendiente se evalúan asintóticamente mediante Wald $\chi^2(1)$. La Tabla 7 presenta las estimaciones de las pendientes sectoriales resultantes.

Tabla 7: Pendientes sectoriales del modelo de panel con efectos fijos (M3)

Código	Sector	β total	EE	z	p crudo	p Holm	Efecto 10 pp
C	Industria manufacturera (ref.)	−0,0098	0,0026	-3,81	0,000137	0,00110	-9,4 %
G	Comercio, mayorista y minorista	−0,0136	0,0021	-6,39	0,000000000168	0,00000000151	-12,8 %
M	Actividades profesionales y científicas	−0,0029	0,0011	-2,70	0,006912	0,04838	-2,8 %
H	Transporte y almacenamiento	−0,0025	0,0033	-0,76	0,448787	1,00000	-2,5 %
J	Información y comunica-	−0,0011	0,0009	-1,18	0,237313	1,00000	-1,1 %

La estimación con interacciones es exploratoria. Las nueve pendientes forman una única familia de pruebas, por lo que se informan los p crudos y la corrección de Holm. Tras Holm, las asociaciones de Manufactura (C, $p = 0,00110$), Comercio (G, $p = 0,00000000151$) y Actividades profesionales, científicas y técnicas (M, $p = 0,04838$) permanecen por debajo de 0,05. La pendiente positiva de Alojamiento y comida (I) tiene p crudo 0,013261, pero p Holm 0,07957 y no alcanza el 5 %. Las restantes pendientes no alcanzan ese umbral tras la corrección. Estos patrones no identifican mecanismos ni efectos causales; sólo son compatibles con hipótesis como ajuste, composición o shocks concurrentes.

4.6. Robustez de la especificación principal

Como prueba de sensibilidad de la especificación principal (M3), se reestimó el modelo para adopción general bajo cuatro criterios metodológicos alternativos: la muestra principal no balanceada sin ponderar ($n = 667$), la muestra principal ponderada por personas ocupadas (WLS), la muestra principal excluyendo valores extremos en los percentiles p1–p99 de productividad ($n = 653$), y la muestra restringida a entidades balanceadas en los tres períodos ($n = 627$). La Tabla 9 resume estos resultados.

Adicionalmente, se evaluó una sensibilidad de covarianza con `AbsorbingLS`, sin modificar estimando, muestra ni efectos fijos de M3. Con su convención propia, la agrupación por entidad arroja $EE = 0,000884369$, $p = 0,15410$ e IC 95 % $[-0,00300241;\ 0,00047618]$; la agrupación bidimensional entidad–país–año arroja $EE = 0,000939258$, $p = 0,17955$ e IC 95 % $[-0,00311036;\ 0,00058413]$, con $\beta = -0,001263116$ en ambas. Son resultados de una convención de covarianza distinta y no una comparación de aumento de EE frente al resultado canónico T60 ($EE = 0,001171453$, $p = 0,282043$). La sensibilidad sigue siendo aproximada con 27 países y tres olas.

Tabla 9: Robustez del modelo M3 para adopción general de IA

Escenario	β **1 pp**	**EE**	p	**Efecto 10 pp**	**Obs.**
Muestra principal no balanceada, sin ponderar	-0,0013	0,0012	0,282	-1,3 %	667
Muestra principal, ponderada por empleo (WLS)	-0,0016	0,0007	0,032	-1,6 %	667
Muestra principal, sin extremos p1–p99	-0,0010	0,0008	0,250	-1,0 %	653
Sensibilidad a balanceo: muestra balanceada	-0,0011	0,0009	0,250	-1,1 %	627

Nota: variable dependiente: logaritmo de productividad laboral aparente. Todos los modelos incluyen efectos fijos país–sector y país–año. Errores estándar agrupados por entidad país–sector. Efecto 10 pp calculado como $100 \times (\exp(10\beta) - 1)$.

Como análisis de sensibilidad complementario de las marcas SBS, la estimación M3 de adopción general conserva las 667 observaciones *core* en la muestra principal. Las exclu-

siones de filas o entidades marcadas describen sensibilidad a la cobertura de rupturas; no identifican un efecto causal ni justifican excluir automáticamente las observaciones marcadas.

El signo del coeficiente de adopción general se mantiene negativo en los cuatro escenarios de robustez. En la muestra principal no ponderada, la inferencia canónica T60 no es estadísticamente significativa ($p = 0,282$); los restantes escenarios se interpretan como sensibilidades y no como selección de especificación. Este resultado refleja un cambio de estimando: al otorgar mayor ponderación a las celdas con mayor masa de empleo agregado, la pendiente asociativa dentro de unidad se vuelve más negativa. Cabe notar que, sin una descomposición formal reproducible entre componentes intra e intersectoriales, atribuir esta mayor magnitud específicamente a costos de reestructuración sectoriales constituye una conjetura interpretativa y no un mecanismo cuantitativamente descompuesto. En ningún escenario se detecta una asociación contemporánea positiva.

4.7. Validación de especificación: RE y restricciones Wald Mundlak/CRE

Se estimó RE por mínimos cuadrados generalizados (GLS) y, en `analysis/03_validacion_linearmodel` regresiones Mundlak/CRE con la media temporal de adopción por entidad (`ai_mean`). Los contrastes son Wald sobre la restricción exacta H_0 : `ai_mean` $= 0$; no son pruebas clásicas basadas en la diferencia entre coeficientes FE y RE.

En RE sobre la muestra completa ($n = 667$), la adopción general exhibe $\beta_{RE} = 0,0111$ ($EE = 0,0009$, $p < 0,001$), una asociación que incorpora variación entre entidades. El Wald Mundlak/CRE sin controles temporales da $\chi^2(1) = 69,10$ ($p = 1,11 \times 10^{-16}$). Al añadir dummies globales de año a esa regresión CRE, la misma restricción da $\chi^2(1) = 108,98$ ($p < 0,001$). No existe una salida CRE/Wald reproducible con los efectos fijos país–año de M3. Bajo los supuestos de cada RE/CRE, estos rechazos aportan evidencia contra su restricción de ortogonalidad correspondiente; no prueban causalidad, no cuantifican sesgo ni hacen a M3 la única especificación posible. M3 se adopta como especificación asociativa principal porque absorbe heterogeneidad país–sector y país–año.

5. Discusión

Los resultados obtenidos en este trabajo ofrecen elementos analíticos de relevancia para la discusión contemporánea sobre la difusión de la inteligencia artificial y su impacto económico, estructurándose en torno a cuatro ejes interpretativos.

5.1. El desacople entre niveles transversales y variaciones temporales

El hallazgo central radica en el marcado contraste entre la dimensión de corte transversal y la dimensión temporal dentro de cada unidad. En niveles, la correlación entre adopción de IA y productividad laboral aparente es sistemáticamente positiva y robusta ($r = 0,558$). No obstante, al explotar la variación temporal dentro de cada país–sector mediante efectos fijos que absorben factores estructurales invariables y perturbaciones macroeconómicas comunes por país y año, la asociación contemporánea deja de ser estadísticamente significativa y el parámetro estimado pasa a ser levemente negativo y no distinguible de cero.

Este patrón resulta conceptualmente consistente con la hipótesis general de costos de ajuste y desfases en la maduración de tecnologías de propósito general desarrollada teórica y empíricamente para intangibles en EE.UU. por Brynjolfsson et al. (2021) y en tecnologías de la información por Bresnahan et al. (2002). No obstante, debe delimitarse con rigor que dicho marco opera aquí como una hipótesis interpretativa compatible y no como una relación causal identificada empíricamente en este panel europeo, dado que un diseño observacional con datos agregados de Eurostat no permite medir contablemente los costos de transición, el capital intangible ni la reorganización a nivel de firma. La correlación en niveles captura que las economías y sectores más desarrollados y productivos (con mayor stock de capital humano, mejor infraestructura digital y mayor capacidad financiera) son precisamente los que lideran la adopción de tecnologías complejas. Sin embargo, en una ventana de observación corta (2021–2024), el incremento contemporáneo en el porcentaje de firmas que declaran adoptar IA no se traduce de manera mecánica en un aumento del valor agregado por persona. La literatura sugiere que la fase inicial de adopción exige destinar recursos empresariales a la reorganización de procesos, la redefinición de tareas y la formación de capacidades internas, gastos que la contabilidad nacional registra como costos corrientes y no como inversión en capital intangible, manteniendo transitoriamente deprimida la productividad observada.

5.2. Mecanismos económicos de la heterogeneidad sectorial

El análisis exploratorio de interacciones sectoriales profundiza la interpretación económica al revelar que la respuesta productiva no es homogénea entre actividades, si bien estos parámetros deben interpretarse con cautela debido a la reducida ventana temporal del panel ($T = 3$):

- **Sectores de alta inercia física y coordinación:** en la Industria Manufacturera y el Comercio Mayorista y Minorista, la adopción de IA puede requerir rediseñar cadenas de abastecimiento, integrar sistemas ciberfísicos o sincronizar almacenes au-

tomatizados. En el corto plazo, esos procesos podrían generar costos de aprendizaje y desajustes operativos temporales, lo que ofrece una hipótesis explicativa plausible para las pendientes negativas observadas. Asimismo, estos sectores enfrentaron de forma asimétrica presiones en costos energéticos y disrupciones logísticas durante el período 2022–2023, factores que también pudieron incidir en la dinámica del valor agregado nominal.

- **Sectores intensivos en información:** en Información y Comunicación, la pendiente estimada es $\beta = -0,0011$ y no alcanza el 5 % tras Holm. La infraestructura digital previa y los costos de ajuste son hipótesis compatibles, pero los datos no distinguen esos mecanismos de otras explicaciones.
- **Servicios con baja penetración basal:** en Alojamiento y Comida, el coeficiente positivo podría estar asociado tanto a patrones de selección entre adoptantes en un sector con baja penetración basal como a la fuerte recuperación cíclica posterior a la pandemia. Con el diseño observacional disponible no es posible separar ambos mecanismos.

5.3. La brecha de realización productiva y las fricciones de optimización

La evidencia reunida es consistente con la noción de una **brecha de realización productiva**: mientras la adopción declarada de IA aumenta con rapidez en las empresas europeas (alcanzando el 17,0 % en 2024), no se observa en la ventana temporal analizada una asociación contemporánea positiva con la productividad laboral aparente una vez absorbidas las diferencias estructurales permanentes y los shocks macroeconómicos anuales comunes a cada país. Este desacople se verifica de forma sistemática tanto en el panel no balanceado como en el balanceado, así como bajo especificaciones ponderadas por empleo.

Desde una perspectiva microeconómica, adoptar una tecnología no equivale a optimizar su uso dentro de la función de producción. Las empresas a menudo enfrentan fricciones sustanciales para reestructurar sus flujos de trabajo tradicionales:

1. **Inercia organizacional y capacitación:** la fuerza laboral requiere tiempo y entrenamiento continuo para incorporar eficazmente herramientas algorítmicas en sus tareas cotidianas. Sin capacitación adecuada, la adopción de software avanzado puede generar duplicación de tareas o resistencia al cambio en lugar de ahorro de tiempo.
2. **Asimetría de información y selección tecnológica:** muchas firmas adquieren licencias comerciales o soluciones estandarizadas por presión competitiva o imitación, sin contar con el diagnóstico técnico interno para acoplar la herramienta a sus cuellos de botella operativos reales.

3. **La necesidad de intermediación y gestión del cambio:** la materialización efectiva de ganancias de productividad demanda frecuentemente servicios especializados de consultoría, rediseño de procesos y gobernanza de datos que ayuden a las empresas a transitar la fase de aprendizaje.

Este resultado dialoga con Yilmaz (2026). Por su parte, Aldasoro et al. (2026), a nivel de empresa, encuentran las interacciones positivas más fuertes con la inversión en software/datos y capacitación; ese resultado no demuestra un mecanismo de calidad de gestión ni explica causalmente las estimaciones del panel sectorial de este trabajo.

La hipótesis de que los usos funcionales orientados al núcleo operativo presenten una asociación más estrecha con la productividad no recibe apoyo en M3: los p canónicos son $0,739894$ para procesos y decisiones, $0,518866$ para producción y $0,917087$ para logística. En este horizonte corto no se observa evidencia estadística de una asociación contemporánea positiva para esos indicadores; ello no identifica procesos operativos ni mecanismos.

5.3.1. De la adopción de herramientas genéricas a la resolución de cuellos de botella específicos

Una dimensión analítica de relevancia para la teoría de la firma radica en la naturaleza de las soluciones de software adoptadas. Históricamente, la difusión tecnológica en el tejido empresarial se ha canalizado predominantemente a través de modelos estandarizados de software como servicio (*Software as a Service*, SaaS). Si bien estas soluciones comerciales horizontales reducen las barreras de entrada y facilitan un acceso masivo, operan en la práctica como insumos tecnológicos homogéneos que rara vez generan ventajas competitivas sostenibles o resuelven las ineficiencias idiosincrásicas de cada unidad productiva.

La literatura sobre complementariedades organizacionales y tecnologías de propósito general (Bresnahan et al., 2002) y los desarrollos recientes en la frontera algorítmica destacan que la productividad no emerge del uso pasivo de herramientas genéricas no integradas, sino del rediseño adaptativo de los procesos productivos orientado a cuellos de botella específicos de la función de producción. En manufactura y logística, esto abarca el mantenimiento predictivo, la planificación dinámica de inventarios o la sincronización ciberfísica; en servicios, la automatización analítica de operaciones complejas o la reducción de tiempos en flujos documentales críticos. Cuando la adopción empresarial se limita a contratar licencias de software sin acoplar los modelos a los cuellos de botella reales de la firma, la literatura económica predice que la tecnología puede incrementar los costos operativos corrientes sin traducirse en mejoras observables del valor agregado por persona. Este mecanismo se propone aquí como una hipótesis interpretativa y agenda de investigación microeconómica futura, dado que los datos de Eurostat registran la incidencia de adopción pero no la profundidad ni la personalización técnica de la implementación en cada

empresa.

5.4. Límites metodológicos y cautela interpretativa

Es imperativo subrayar los límites del diseño econométrico implementado:

1. **Nivel de agregación y supuestos normativos:** la unidad de análisis es la entidad país–sector. Por consiguiente, los resultados no permiten diagnosticar si una empresa individual específica obtuvo un retorno de inversión positivo o negativo, ni evaluar la calidad técnica de sus decisiones de implementación. La presencia de costos de ajuste o fricciones organizativas constituye una hipótesis teórica compatible con los datos agregados, no una medición contable directa a nivel firma.

2. **Horizonte temporal:** con sólo tres olas comparables (2021, 2023 y 2024), la capacidad para identificar efectos dinámicos rezagados es limitada. Si los retornos productivos de la IA maduran con rezagos de varios años, el diseño actual podría estar capturando una etapa inicial compatible con costos de transición, pero el número reducido de períodos impide modelar estructuras complejas de rezagos distribuidos.

3. **Precios relativos y shocks sectoriales específicos:** la productividad laboral se mide en términos nominales estandarizados por Eurostat SBS. Los efectos fijos país–año eliminan de la variación utilizada los componentes comunes de inflación agregada y perturbaciones macroeconómicas nacionales, pero no las divergencias de precios relativos ni shocks entre sectores dentro de un mismo país. Como fundamenta Berndt (1991), la separación rigurosa de variaciones de precios y cantidades a nivel desagregado requeriría deflactores construidos sobre los mismos microdatos de empresa, una vía que excede el alcance de las series agregadas oficiales disponibles.

4. **Inferencia estadística con panel corto ($T = 3$):** al disponer de sólo tres períodos temporales, la variación intra-unidad proviene de fluctuaciones en el corto plazo. Por ello, las estimaciones sectoriales desagregadas deben concebirse como patrones exploratorios de heterogeneidad y no como parámetros estructurales definitivos de la función de producción de cada rama económica.

5. **Rupturas SBS:** las marcas `b` se concentran en 2021, por lo que el panel no permite contrastar dentro de la muestra el quiebre con la serie anterior. Los efectos fijos país–año absorben componentes comunes a los sectores de un país y año, pero no cambios diferenciales por sector. Las sensibilidades reportadas son informativas, no una prueba de que las observaciones marcadas sean erróneas ni una corrección de comparabilidad.

6. Conclusiones

Este Trabajo Final de Grado se propuso analizar cómo varían la adopción y los usos empresariales de inteligencia artificial entre sectores económicos de la Unión Europea y en qué medida dichas diferencias se asocian con niveles y variaciones de productividad laboral aparente, mediante la construcción de una base de panel país–sector–año reproducible a partir de datos agregados oficiales de Eurostat para los años 2021, 2023 y 2024.

Los resultados alcanzados permiten extraer tres conclusiones principales:

1. **Divergencia entre corte transversal y dinámica temporal (hallazgo empírico central):** el contraste entre la asociación positiva observada en niveles y la estimación temporal es compatible con heterogeneidad estructural correlacionada entre sectores y países, pero no cuantifica su contribución ni establece causalidad. Para adopción general, M3 da $\beta = -0,001263116$, $EE = 0,001171453$, $p = 0,282043$ e IC95 % $[-0,00357116;\ 0,00104493]$ ($n = 667$, $G = 233$, CR1 de rango efectivo y t_{232}). El Wald de Mundlak rechaza la ortogonalidad de la especificación RE evaluada ($\chi^2 = 69,10$, $p < 0,001$), sin corroborar causalmente una explicación de la correlación en niveles.

2. **Heterogeneidad estructural sectorial (evidencia exploratoria):** las nueve pendientes son una única familia exploratoria. Tras Holm, C ($p = 0,00110$), G ($p = 0,00000000151$) y M ($p = 0,04838$) permanecen bajo 0,05; I pasa de p crudo $0,013261$ a $p_{Holm} = 0,07957$ y no alcanza ese umbral. Los resultados son asociaciones exploratorias, compatibles con hipótesis como ajuste o shocks concurrentes, no mecanismos identificados.

3. **La necesidad de activos complementarios:** en la ventana temporal analizada, la adopción formal de IA no se asocia de forma automática con mejoras contemporáneas de productividad. Si bien el diseño observacional no mide de manera directa la capacitación ni la reingeniería interna, la literatura económica sugiere como mecanismos teóricos plausibles que la realización de beneficios productivos requiere activos complementarios e inversiones organizacionales que maduran con rezago.

En términos de implicancias tentativas de política económica y gestión empresarial —derivadas del marco conceptual complementario y de la ausencia observada de ganancias inmediatas, y no como un efecto causal directo derivado de M3—, estos hallazgos sugieren que las estrategias públicas y corporativas de digitalización no deberían limitarse a subsidiar la adopción nominal o la adquisición acelerada de licencias de software. Por el contrario, la literatura de complementariedades destaca la conveniencia de fortalecer los activos intangibles de soporte: programas de formación continua en habilidades analíticas, asistencia técnica para la reingeniería de procesos internos y modernización de la gober-

nanza de datos, reconociendo que la transferibilidad de estas recomendaciones depende de las capacidades basales de cada tejido productivo.

Como agenda futura, una vez que Eurostat consolide nuevas olas comparables de SBS y de la encuesta de TIC empresarial, resultará fundamental extender el horizonte temporal del panel para estimar estructuras de rezagos distribuidos que permitan verificar empíricamente en qué momento y bajo qué condiciones sectoriales comienzan a materializarse retornos positivos de productividad en el tejido productivo europeo. Una extensión especialmente relevante para el contexto nacional consistiría en adaptar este enfoque al caso argentino, combinando información sectorial o empresarial sobre adopción digital e inteligencia artificial con indicadores de valor agregado, empleo y productividad. Este tipo de ejercicio permitiría evaluar si las restricciones de capacidades complementarias, escala, financiamiento, infraestructura digital y volatilidad macroeconómica modifican la relación entre adopción tecnológica y productividad en economías emergentes como la Argentina.

7. Bibliografía

Acemoglu, D. and Restrepo, P. (2018). The race between man and machine: Implications of technology for growth, factor shares, and employment. *American Economic Review*, 108(6):1488–1542.

Aldasoro, I., Gambacorta, L., Pal, R., Revoltella, D., Weiss, C., and Wolski, M. (2026). Ai adoption, productivity and employment: Evidence from european firms. BIS Working Papers 1325, Bank for International Settlements. Consultado el 23 de septiembre de 2026.

Berndt, E. R. (1991). *The Practice of Econometrics: Classic and Contemporary*. Addison-Wesley, Reading, MA.

Bresnahan, T. F., Brynjolfsson, E., and Hitt, L. M. (2002). Information technology, workplace organization, and the demand for skilled labor: Firm-level evidence. *The Quarterly Journal of Economics*, 117(1):339–376.

Brynjolfsson, E., Rock, D., and Syverson, C. (2021). The productivity j-curve: How intangibles complement general purpose technologies. *American Economic Journal: Macroeconomics*, 13(1):333–372.

Czarnitzki, D., Fernández, G. P., and Rammer, C. (2023). Artificial intelligence and firm-level productivity. *Journal of Economic Behavior & Organization*, 211:188–205.

Eurostat (2026a). Annual enterprise statistics by special aggregates and legal forms (`sbs_na_1a_se_r2`). https://ec.europa.eu/eurostat/databrowser/view/sbs_na_1a_se_r2__custom_9128690/default/table. Tabla histórica SBS de 2005–2020 que contiene el código `V91110`; consultada el 5 de noviembre de 2026.

Eurostat (2026b). Artificial intelligence: Additional enterprise indicators. https://ec.europa.eu/eurostat/databrowser/view/isoc_eb_ain2/default/table. Base de datos consultada para indicadores complementarios de inteligencia artificial; consultada el 23 de septiembre de 2026.

Eurostat (2026c). Ict sector statistics: Metadata. https://ec.europa.eu/eurostat/cache/metadata/en/isoc_se_esms.htm. Documenta la medición SBS desde 2021 a precios básicos y la ruptura con la serie previa; consultado el 5 de noviembre de 2026.

Eurostat (2026d). Structural business statistics overview (`sbs_sc_ovw`). https://ec.europa.eu/eurostat/databrowser/view/sbs_sc_ovw/default/table. Tabla usada para `AV_MEUR` y `EMP_NR`; consultada el 5 de noviembre de 2026.

Eurostat (2026e). Structural business statistics (sbs): Metadata. https://ec.europa.eu/eurostat/cache/metadata/en/sbs_esms.htm. Metadatos SBS consultados el 5 de noviembre de 2026.

Eurostat (2026f). Structural business statistics: Variable correspondence from 2021. https://ec.europa.eu/eurostat/cache/metadata/Annexes/sbs_esms_an_1.pdf. Define `AV_MEUR` como valor agregado en millones de euros y `EMP_NR` como personas ocupadas; consultado el 5 de noviembre de 2026.

Eurostat (2026g). Use of artificial intelligence in enterprises. https://ec.europa.eu/eurostat/databrowser/view/isoc_eb_ai/default/table. Base de datos consultada para indicadores de adopción empresarial de inteligencia artificial; consultada el 23 de septiembre de 2026.

Kádárová, J., Fiľo, M., Sukopová, D., and Dúlová, M. (2026). Artificial intelligence adoption and labour productivity in slovakia and the eu27: Implications for sustainable economic growth. *Sustainability*, 18(4):2135.

Mundlak, Y. (1978). On the pooling of time series and cross section data. *Econometrica*, 46(1):69–85.

Wooldridge, J. M. (2010). *Econometric Analysis of Cross Section and Panel Data*. MIT Press, Cambridge, MA, 2 edition.

Yilmaz, E. (2026). Ai adoption velocity, productivity and labour outcomes in europe: A country-sector dataset with the ai attribution wedge, 2021–2025. Consultado el 23 de septiembre de 2026.

Anexos

Anexo A: Diccionario de variables y fuentes de información

La Tabla 11 detalla las variables que componen la base de datos analítica, su definición conceptual, el código oficial de flujo en Eurostat y su rol en la estrategia empírica.

Tabla 11: Diccionario de variables de la base analítica

Variable	Definición	Tipo / Unidad	Fuente Eurostat	Nota metodológica
`country_code`	Código geográfico oficial	Texto	Eurostat	27 Estados miembros de la UE (Grecia utiliza `EL`).
`sector_code`	Sección de actividad NACE Rev. 2	Texto	Eurostat	9 sectores seleccionados: C, F, G, H, I, J, L, M y N.
`year`	Año de referencia	Entero	Eurostat	Olas comparables del panel: 2021, 2023 y 2024.
`ai_any_pct`	Empresas con al menos una tecnología de IA	% de empresas	`isoc_eb_ain2`: `E_AI_TANY`	Variable explicativa principal (adopción general).
`ai_ge2_pct`	Empresas con dos o más tecnologías de IA	% de empresas	`isoc_eb_ain2`: `E_AI_TGE2`	Medida de amplitud o intensidad tecnológica media.
`ai_ge3_pct`	Empresas con tres o más tecnologías de IA	% de empresas	`isoc_eb_ain2`: `E_AI_TGE3`	Medida de intensidad tecnológica alta.
`ai_workflow_pct`	IA en organización de procesos y decisiones	% de empresas	`isoc_eb_ain2`: `E_AI_TPA`	Uso funcional de gestión interna y flujos de trabajo.
`ai_production_pct`	IA aplicada a procesos productivos	% de empresas	`isoc_eb_ain2`: `E_AI_PPP`	Uso funcional en control y ejecución de producción.
`ai_logistics_pct`	IA aplicada a logística y suministros	% de empresas	`isoc_eb_ain2`: `E_AI_PLOG`	Uso funcional en transporte interno y cadena de valor.
`ai_marketing_pct`	IA aplicada a marketing y ventas	% de empresas	`isoc_eb_ain2`: `E_AI_PMS`	Uso comercial y perfilado de clientes.
`ai_security_pct`	IA aplicada a seguridad de TIC	% de empresas	`isoc_eb_ain2`: `E_AI_PITS`	Uso de soporte preventivo en ciberseguridad.
`value_added_meur_ge10`	Valor agregado a precios básicos	Millones de EUR corrientes	SBS: `sbs_sc_ovw` (`AV_MEUR`)	SBS 2021+; empresas con ≥ 10.

Variable	Definición	Tipo / Unidad	Fuente Eurostat	Nota metodológica
`persons_employed_ge10`	Personas ocupadas totales	Personas	SBS: `sbs_sc_ovw` (`EMP_NR`)	Agregado para empresas de 10 o más personas ocupadas.
`labour_productivity_keur`	Productividad laboral aparente nominal	Miles EUR corrientes / pers.	Construcción propia	Cálculo propio: `AV_MEUR` × 1000 / `EMP_NR`.
`core_complete`	Completitud de variables centrales	Indicador binario	Filtro analítico	Exige información conjunta de IA general y productividad.
`balanced_entity`	Entidad balanceada en los 3 años	Indicador binario	Filtro analítico	209 entidades observadas en las tres olas temporales del panel (2021, 2023 y 2024).

Fuente: elaboración propia sobre la base de metadatos de Eurostat (`isoc_eb_ai`, `isoc_eb_ain2` y `sbs_sc_ovw`).

Anexo B: Comparación completa de especificaciones econométricas (M1, M2 y M3)

La Tabla 12 compara las tres especificaciones alternativas de datos de panel. Para adopción general, la muestra *core* no balanceada contiene $n = 667$ observaciones y 233 entidades; para cada indicador secundario, la muestra de casos completos correspondiente contiene $n = 626$–662. Dentro de un indicador, M1, M2 y M3 usan la misma muestra de casos completos.

- **Modelo M1:** mínimos cuadrados ordinarios agrupados con efectos fijos aditivos de país, sector y año. Compara niveles controlando por heterogeneidad observable media.
- **Modelo M2:** estimador intra-entidad con efectos fijos de país–sector (α_{cs}) y efectos fijos temporales comunes de año (γ_t).
- **Modelo M3 (preferido):** estimador intra-entidad con efectos fijos de país–sector (α_{cs}), que eliminan efectos de unidad invariantes, y país–año (γ_{ct}), que eliminan componentes comunes a sus sectores. No elimina precios relativos ni shocks sectoriales dentro de país–año.

Tabla 12: Comparación de modelos M1, M2 y M3 para todos los indicadores de IA

Modelo	Indicador de IA	β 1 pp	EE agrup.	t	p-valor	Efecto 10 pp	R^2
Panel A: Modelo M1 (Efectos fijos de País + Sector + Año)							
M1	Adopción general	0,0032	0,0019	1,69	0,091	+3,2 %	0,853
M1	Dos o más tecnologías	0,0004	0,0020	0,19	0,851	+0,4 %	0,850
M1	Tres o más tecnologías	-0,0016	0,0029	-0,56	0,579	-1,6 %	0,851
M1	Procesos y decisiones	0,0107	0,0046	2,35	0,019	+11,3 %	0,855
M1	Producción	0,0037	0,0049	0,75	0,452	+3,7 %	0,846
M1	Logística	0,0403	0,0177	2,28	0,023	+49,7 %	0,849
M1	Marketing y ventas	-0,0012	0,0036	-0,34	0,732	-1,2 %	0,851
M1	Seguridad informática	0,0070	0,0055	1,29	0,198	+7,3 %	0,849
Panel B: Modelo M2 (Efectos fijos de Entidad País–Sector + Año)							
M2	Adopción general	-0,0020	0,0010	-1,97	0,050	-1,9 %	0,985
M2	Dos o más tecnologías	-0,0025	0,0011	-2,31	0,021	-2,5 %	0,985
M2	Tres o más tecnologías	-0,0039	0,0015	-2,50	0,013	-3,8 %	0,985
M2	Procesos y decisiones	0,0002	0,0018	0,10	0,921	+0,2 %	0,985
M2	Producción	-0,0044	0,0020	-2,14	0,033	-4,3 %	0,985
M2	Logística	0,0039	0,0085	0,46	0,643	+4,0 %	0,985
M2	Marketing y ventas	-0,0047	0,0019	-2,54	0,011	-4,6 %	0,986
M2	Seguridad informática	-0,0024	0,0024	-1,00	0,317	-2,4 %	0,985
Panel C: Modelo M3 (Efectos fijos de Entidad País–Sector + País–Año)							
M3	Adopción general	-0,0013	0,0012	-1,08	0,282	-1,3 %	0,990
M3	Dos o más tecnologías	-0,0017	0,0013	-1,31	0,192	-1,6 %	0,990
M3	Tres o más tecnologías	-0,0020	0,0017	-1,17	0,244	-2,0 %	0,990
M3	Procesos y decisiones	-0,0007	0,0021	-0,33	0,740	-0,7 %	0,990
M3	Producción	-0,0014	0,0022	-0,64	0,519	-1,4 %	0,990
M3	Logística	-0,0011	0,0104	-0,11	0,917	-1,1 %	0,990
M3	Marketing y ventas	-0,0038	0,0027	-1,43	0,151	-3,8 %	0,990
M3	Seguridad informática	-0,0019	0,0031	-0,61	0,542	-1,8 %	0,990

Nota: variable dependiente: logaritmo de productividad laboral aparente. Adopción general: muestra *core* no balanceada ($n = 667$, 233 entidades). Los indicadores secundarios usan su muestra de casos completos ($n = 626$–662); para cada indicador, M1, M2 y M3 comparten esa misma muestra. Para M3, EE y p son canónicos T60: agrupación por entidad, CR1 de rango efectivo y referencia t_{G-1}. `AbsorbingLS` valida coeficientes con una convención de covarianza distinta.

Esta tabla muestra que, al pasar de M1 a M2 y M3, los coeficientes cambian. Para adopción general en M3, el intervalo canónico 95 % incluye asociaciones negativas y positivas. El patrón es compatible con diferencias de especificación y factores estructurales preexistentes, pero no cuantifica su contribución ni establece causalidad.

Anexo C: Cobertura geográfica (Estados miembros de la UE-27)

La Tabla 14 detalla los 27 Estados miembros de la Unión Europea que integran el panel empírico analizado.

Tabla 14: Estados miembros de la Unión Europea incluidos en el análisis

Código Eurostat	País	Código Eurostat	País
AT	Austria	IE	Irlanda
BE	Bélgica	IT	Italia
BG	Bulgaria	LT	Lituania
CY	Chipre	LU	Luxemburgo
CZ	Chequia	LV	Letonia
DE	Alemania	MT	Malta
DK	Dinamarca	NL	Países Bajos
EE	Estonia	PL	Polonia
EL	Grecia	PT	Portugal
ES	España	RO	Rumania
FI	Finlandia	SE	Suecia
FR	Francia	SI	Eslovenia
HR	Croacia	SK	Eslovaquia
HU	Hungría		

Nota: los códigos corresponden a la nomenclatura oficial de Eurostat (basada en ISO 3166-1 alfa-2, excepto para Grecia, que utiliza el identificador oficial comunitario `EL` en lugar de `GR`).

Anexo D: Protocolo de reproducibilidad y código abierto

Con el propósito de asegurar la plena transparencia científica y reproducibilidad de los resultados, la totalidad de los datos procesados, scripts de estimación y rutinas de validación econométrica se encuentran disponibles en el repositorio público de GitHub:

https://github.com/Facundo-Diaz-Larrarte/TFG_Facundo_Diaz_Larrarte

El entorno analítico se ejecuta bajo Python 3.12 o superior utilizando las bibliotecas científicas estándar `pandas` (v2.3), `numpy` (v2.5), `scipy` (v1.18), `statsmodels` (v0.15) y `linearmodels` (v7.0).

El pipeline completo de reproducción se ejecuta desde la raíz del proyecto mediante el comando maestro:

```
python analysis/00_reproducir_todo.py
```

Este script ejecuta de manera secuencial:

1. `01_descriptivo.py`: genera las estadísticas descriptivas, tablas de cambios 2021–2024, matrices de correlación y las figuras de adopción y dispersión.

2. `02_modelos_panel.py`: realiza las estimaciones de panel por mínimos cuadrados agrupados con errores robustos.

3. `03_validacion_linearmodels.py`: replica y valida el modelo preferido M3 utilizando el algoritmo `AbsorbingLS`, verificando la coincidencia de los coeficientes a nivel de precisión de máquina.

4. `04_robustez_panel.py`: estima los cuatro escenarios de sensibilidad de muestra, ponderaciones por empleo y filtros de valores extremos.

Anexo E: Estimación RE y restricciones Wald Mundlak/CRE

La Tabla 15 presenta estimaciones RE con errores estándar agrupados por entidad país–sector y restricciones Wald Mundlak/CRE calculadas en `analysis/03_validacion_linearmodels.py`. Para cada indicador, la regresión CRE sin controles temporales contrasta H_0 : `ai_mean` = 0. El rechazo de esa restricción aporta evidencia contra la restricción de ortogonalidad RE/CRE correspondiente bajo los supuestos del modelo; no demuestra causalidad, sesgo cuantificado ni que M3 sea obligatorio. M3 se utiliza como especificación asociativa principal por sus efectos fijos país–sector y país–año.

Tabla 15: Modelos RE y restricciones Wald Mundlak/CRE por indicador de IA

Indicador	β_{RE}	**EE**	p_{RE}	**Wald CRE** χ^2	p**-valor**	**Obs.**
Adopción general	0,0111	0,0009	<0,001	69,10	<0,001	667
Dos o más tecnologías	0,0121	0,0011	<0,001	56,86	<0,001	662
Tres o más tecnologías	0,0152	0,0017	<0,001	48,97	<0,001	653
Procesos y decisiones	0,0194	0,0024	<0,001	44,31	<0,001	662
Producción	0,0190	0,0029	<0,001	76,28	<0,001	631
Logística	0,0375	0,0084	<0,001	35,92	<0,001	627
Marketing y ventas	0,0153	0,0016	<0,001	43,73	<0,001	640
Seguridad informática	0,0237	0,0033	<0,001	20,44	<0,001	626

Nota: variable dependiente: logaritmo de productividad laboral aparente. RE se estima por GLS con errores estándar agrupados por entidad país–sector. La columna Wald CRE corresponde a una regresión CRE sin controles temporales y contrasta exactamente H_0 : `ai_mean` = 0, distribuida asintóticamente como $\chi^2(1)$, siguiendo Mundlak (1978) y Wooldridge (2010). Para adopción general, al añadir dummies globales de año, la misma restricción da $\chi^2(1) = 108,98$ ($p < 0,001$). No hay salida CRE reproducible con efectos país–año; los rechazos son evidencia contra las restricciones RE/CRE correspondientes bajo sus supuestos, no una selección obligatoria de M3.